


Introduction: 为什么现在的 NLP 既是技术革命，也是考试里的总地图

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

AI/NLP 历史脉络 → Neural networks 与 transformer paradigm shift → Why now: 架构、数据、算力、自监督 → Scaling 的加速与边界 → 语言与模态覆盖扩张 → Frontier tasks 与评估升级 → 经济影响与 ROI 落差 → Safety、security 与 meaning crisis → ATNLP 的技术-评估-伦理课程地图

AI and NLP

Neural Networks led to **paradigm shift** in NLP



Maturing transformer architectures, massive scaling and commercialization – NLP from niche to ubiquitous

这节课一句话

L01 的核心不是行政介绍，而是给整门 ATNLP 定调：现代 NLP 因 transformers、自监督生成模型、数据与算力规模化而从小众任务变成无处不在的基础设施，但真正高级的问题已经从“模型能不能变大”转向“模型是否可靠、可评估、可部署、可负责”。

1. NLP 的 paradigm shift: 从小众语言处理到通用基础设施

AI and NLP

Neural Networks led to **paradigm shift** in NLP




Figure from <https://medium.com/@astonebois/a-brief-history-of-natural-language-processing-part-3-f5c175de37>

Maturing transformer architectures, massive scaling and commercialization – NLP from niche to ubiquitous

Alexandra Birch

ATNLP Week 1/ Lecture 1

School of
informatics

5

原 PPT 第 5 页

人话直觉

可以把早期 NLP 想成一间专门修语言机器的小作坊：分词、翻译、问答，各做各的。slide 5 讲的是这间作坊突然被接进了发电厂——neural networks、transformers、massive scaling 和 commercialization 让 NLP 从“某些任务上的算法”变成每天都在搜索、写作、客服、编程和教育里出现的基础设施。考试里不要只说“模型变大了”，要说 paradigm shift：表示学习、端到端训练、预训练-适配，以及语言能力被产品化。

精确定义 / 机制：这页把 AI and NLP 的历史线压缩成一个重要判断：神经网络带来了 NLP 的范式变化，而 mature transformer architectures、massive scaling 和 commercialization 使 NLP 从 niche to ubiquitous。传统 NLP 往往依赖任务特定特征、规则或小模型；现代 NLP 则更依赖大规模预训练模型学习通用表示，再通过 prompting、fine-tuning、RAG、agents 等方式适配任务。这里的“ubiquitous”很关键：NLP 不再只是处理自然语言文本的学术子领域，而是许多 AI 应用的人机接口、知识接口和行动接口。

考试问法：如果题目问现代 NLP 为什么重要，答案要包含两层：技术层是 neural/transformer/scaling/self-supervised pretraining 改变了建模方式；社会层是 commercialization 让 NLP 进入真实 workflow，因此必须同时关心 performance、evaluation、safety、ethics 和 deployment。

2. Why now: 四个条件同时成熟，才有今天的生成式 NLP

Why now?

- **Architectures**: especially transformers capture long-range dependencies
- **Computational power** and large-scale **datasets**
- **Generative models**: self-supervised learning from raw text
- **Scaling** to larger models

原 PPT 第 6 页

人话直觉

现代 NLP 爆发像一场火：transformer 是能让火烧得远的炉膛，算力是氧气，大规模数据是燃料，自监督生成模型是点火方式。少一个都不够：只有架构没有数据，会饿；只有数据没有算力，烧不动；只有 supervised labels，又太贵太窄。slide 6 的考试价值在于，它逼你把“ChatGPT 为什么突然出现”拆成可解释的机制链。


精确定义 / 机制：slide 6 列出四个关键因素：第一，transformers 尤其擅长捕捉 long-range dependencies，使模型能在长上下文中建模 token 间关系；第二，computational power 与 large-scale datasets 让训练巨大模型成为可能；第三，generative models 通过 self-supervised learning 从 raw text 中学习，不需要为每个任务人工标注海量数据；第四，scaling to larger models 在一段时期内持续带来能力提升。这里的 self-supervision 是核心：模型从文本自身构造训练信号，例如预测下一个 token，而不是等待人工给每句话贴标签。

Modern NLP capability $\approx f(\text{architecture, compute, data, self-supervision, scale})$

考试问法：常见问法是“Why has NLP advanced rapidly recently?”标准答法应按 architecture、compute、data、self-supervised generative training、scaling 四点组织，并解释每点的作用；不要写成“因为有更多数据和更大模型”这种单因果答案。

3. Scaling 的力量与边界：大不是答案本身

Future of Scaling



Sara Hooker (2025) [On the Slow Death of Scaling](#)

Alexandra Birch

ATNLP Week 1 / Lecture 1

School of Informatics

8

原 PPT 第 8 页

人话直觉


前几年大家像在玩“堆积木”：参数更多、数据更多、算力更多，模型常常就更强。但 slide 8 的提醒很重要：堆得高不等于建筑稳。一个 4B 模型可能在某个任务上打败 27B 模型，说明能力不是只由 parameter count 决定；数据配方、训练目标、后训练、推理策略、任务匹配都会改变结果。

精确定义 / 机制：slide 7 先给出 scaling 加速：dataset size 与 training compute size 的 doubling time 很短；slide 8 随即用“many large models perform worse than smaller models”和 Qwen3-4B vs Gemma-27B 的例子打断线性神话。这体现了课程对 scaling 的成熟态度：scale 是现代 NLP 的重要 driver，但它不是充分条件。随着成本、数据质量、benchmark saturation、deployment constraints 和 alignment/safety 风险出现，研究重点会转向如何更有效地训练、压缩、适配、评估和解释模型。

考试问法：若考 scaling，不能极端回答“scaling 已死”或“越大越好”。高分答案应说：scaling historically drives capability gains, 但 marginal returns、data/compute constraints、evaluation mismatch 和 small efficient models 的表现说明 scaling law 之外还需要 architecture、data quality、post-training、reasoning methods 与 deployment-aware evaluation。

4. 多语言与多模态：NLP 的对象正在扩大

Cover far more languages and modalities



原 PPT 第 9 页

人话直觉


以前说 NLP，脑子里常是英文文本：句子进、标签出。slide 9 把这个想象打碎：Google Translate 从 English-Arabic 走到 243 languages including dialects and language varieties；multimodal LLMs 让文字、图像、声音和视觉推理混在同一个系统里。也就是说，语言技术不再只服务“标准英文文本”，而要面对真实世界的语言多样性和感知输入。

精确定义 / 机制：这页为后续 multilingual NLP 和 multimodal models 铺路。语言覆盖扩大带来 transfer learning、low-resource languages、dialect variation、evaluation fairness 等问题；模态覆盖扩大则带来 image-text alignment、vision-language grounding、multimodal reasoning 和安全风险。关键机制是 shared representations：模型学习把不同语言或不同模态的信息映射到可交互的表示空间，但这也会暴露数据不平衡、文化偏差、低资源语言质量差、模态幻觉等问题。

考试问法：如果题目问为什么多语言/多模态是 advanced NLP 的核心，不要只说“应用更多”。要答：真实用户和真实任务本来就是 multilingual and multimodal；模型需要跨语言迁移、处理低资源场景、对齐不同模态，并用更公平的 evaluation 检查不同群体和语言上的表现。

5. Frontier tasks: 评估从背题转向开放世界能力

Frontier tasks



原 PPT 第 11 页

人话直觉


老 benchmark 像期末选择题：题型固定、答案短、训练集和测试集长得像。frontier tasks 更像让模型当研究助理：去找信息、看图、用工具、多步推理，还要给出唯一可验证的答案。GAIA 和 ARC-AGI-2 的共同信号是：真正难的不是把互联网上某句话复述出来，而是在新情境里组合能力。

精确定义 / 机制： slide 11 用 GAIA 和 ARC-AGI-2 展示评估前沿。GAIA questions 强调 real-world and challenging questions，需要 browsing、multi-modality、tool use 或 multi-step reasoning，并且答案 unambiguous、可自动验证、通常不能直接从训练数据中背出。ARC-AGI-2 则强调抗 overfitting and memorization，关注 fluid intelligence、抽象规则发现和最少先验知识。它们说明 evaluation 正从静态文本匹配转向测量复杂行动序列、泛化、工具使用和推理可靠性。

考试问法： 若问 frontier benchmark 与传统 NLP benchmark 的区别，要答：传统任务多为封闭数据集上的分类/生成；frontier tasks 更强调开放世界、多步、工具/多模态、抗记忆、答案可验证。也要指出分数提升不等于全面智能，因为 benchmark 仍可能被策略、工具链或数据泄漏影响。

6. Economic impact: demo 到 production 中间有一条深沟

Economic Impact: real returns on investment still low



Challapally et al. [The GenAI Divide STATE OF AI IN BUSINESS 2025](#)

Alexandra Birch

ATNLP Week 1 / Lecture 1

School of
informatics

15

原 PPT 第 14 页

人话直觉

这页最适合纠正“AI 很强，所以公司马上赚钱”的直觉。做一个炫酷 demo 像在实验室里让机器人倒一杯水；把它放进医院、银行、客服、法律流程里每天稳定工作，是另一回事。slide 14 的 80% investigated、60% piloted、5% successfully implemented 说明：从探索到真实 ROI 会出现断崖。

精确定义 / 机制： slide 14 的 GenAI divide 区分 general-purpose LLMs 与 embedded or task-specific GenAI，并指出大量公开 AI initiatives 停留在 generic tools、demos、brittle workflows，未能交付 ROI；少数成功案例则 design for friction，把系统嵌入 high-value workflows，带有 memory 与 learning loops。这里的 friction 包括 human friction、organization friction 和 technical friction：用户不信或不愿改流程，组织政策与责任不清，系统缺少学习、监控和集成能力。课程因此不会只教模型本身，也强调 evaluation、error analysis、adaptation 和 deployment。

考试问法： 如果考 AI economic impact 或 deployment challenges，要避免空泛说“AI 会提高效率”。
应答： investment and interest are high，但 successful implementation 取决于 workflow integration、task specificity、memory/learning loops、human adoption、policy constraints、technical reliability 和 ROI evaluation。

7. Safety and security: 语言能力也会放大攻击能力

Safety and Security Risks

- **Cyber-attacks**: tailored phishing methods or replicating malware.
- **Increased digital vulnerabilities**: new attack surfaces eg. prompt injection
- **Political and societal influence**: increase the scale, persuasiveness and frequency of disinformation
- **Insecure use and misuse**: integration into critical systems leading to biased and discriminatory systems
- **Erosion of trust in information**: pollution of the public information - hyper-realistic bots and deepfakes

<https://www.gov.uk/government/publications/frontier-ai-capabilities-and-risks-discussion-paper/safety-and-security-risks-of-generative-artificial-intelligence-to-2025-annex-b>

Alexandra Birch

ATNLP Week 1 / Lecture 1

School of Informatics

18

原 PPT 第 16 页

人话直觉

当 NLP 系统只会做情感分类时，风险多半是分类错；当系统能写邮件、调用工具、生成代码、影响舆论时，风险就变成“它可以被用来行动”。slide 16 的 cyber-attacks、prompt injection、disinformation、biased critical systems 和 deepfakes 不是五个孤立例子，而是在说：生成式 NLP 把语言变成了低成本、大规模、可个性化的影响工具。

精确定义 / 机制：这页列出 generative AI 到 2025 的 safety and security risks: tailored phishing 或 malware replication 体现 malicious capability amplification; prompt injection 等新 attack surfaces 体现系统集成后的 vulnerability; political and societal influence 体现 disinformation 的规模、说服力和频率提升; insecure use and misuse 指模型进入 critical systems 后可能产生 biased and discriminatory outcomes; erosion of trust in information 指 hyper-realistic bots and deepfakes 污染公共信息环境。它们共同要求课程中的 evaluation 不只测 accuracy，还要测 robustness、misuse resistance、fairness 和 provenance。

考试问法：若题目问 NLP safety risks，最好按 threat categories 组织：cyber misuse、new vulnerabilities such as prompt injection、disinformation and influence operations、biased deployment in critical systems、erosion of trust。再补一句：这些风险来自 capability、scale、automation、personalization 和 system integration 的结合。

8. ATNLP 的学习目标：会解释、会实现、会评估、会批判

Goals of ATNLP

- **Analyse** linguistic, machine learning, and ethical challenges in real-world NLP systems
- **Understand** and explain state-of-the-art NLP models and algorithms
- **Design, implement**, and adapt modern NLP systems for specific tasks
- **Evaluate** models rigorously, using error analysis to compare pros and cons of different approaches

原 PPT 第 19 页

人话直觉


L01 后半看起来像课程说明，但 slide 19 其实是考试路线图。它不是说你要背 30 个模型名，而是要训练四种能力：看懂真实 NLP 系统的问题，讲清 SOTA 模型为什么这样工作，把方法改造成具体任务系统，再用严谨 evaluation 和 error analysis 判断它到底哪里好、哪里坏。

精确定义 / 机制：Goals of ATNLP 包括：分析 real-world NLP systems 中 linguistic、machine learning 和 ethical challenges；理解并解释 SOTA NLP models and algorithms；设计、实现和适配 modern NLP systems；用 rigorous evaluation 与 error analysis 比较不同方法的 pros and cons。这四点构成课程后续所有主题的共同评分标准。例如 RAG 不只是架构图，还要问 hallucination 和 attribution；PEFT 不只是 LoRA 公式，还要问何时省资源、何时失效；multilingual 不只是多语言覆盖，还要问低资源语言和公平性。

考试问法：如果考试问“what does it mean to evaluate an NLP system rigorously?”可以回到这页：不仅报告单一平均分，还要做 task-appropriate metrics、baselines、ablation、error analysis、subgroup/language analysis、pros/cons comparison，并联系 real-world constraints。

9. Responsible innovation: 技术价值由真实世界后果决定

Overview



Alexandra Birch

ATNLP Week 1 / Lecture 1

School of Informatics

25

原 PPT 第 22 页

人话直觉

这页给整门课加了刹车和方向盘。刹车是：不要因为模型能做就直接部署；方向盘是：技术应该让人的生活更好。fairness、transparency、impact 和 evaluation 不是“伦理附录”，而是判断 NLP 系统是否值得构建的核心标准。

精确定义 / 机制：slide 22 引用 Centre for Technomoral Futures 的观点：technology's value lies in its power to transform our world in ways that enable better lives。课程目的包括 responsible innovation、attention to fairness/transparency/real-world impact、focusing on evaluation to detect and mitigate harms，以及 combining technical and critical reflection。这解释了为什么 ATNLP 同时覆盖 data、evaluation、PEFT、distillation、long context、reasoning、RAG、multimodal、multilingual、interpretability、parsing、safety、security 和 ethics：这些主题共同回答“如何构建强大且负责任的 NLP 系统”。

考试问法：若题目要求评价一个现代 NLP 应用，高分结构是：先说明技术机制和目标，再讨论 evaluation evidence，然后分析 fairness、transparency、safety、security、real-world impact 与 deployment constraints。不要把 ethical reflection 写成最后一句口号。

考试速记版

- L01 的主线：现代 NLP 从 niche 走向 ubiquitous，但能力、评估、部署和责任必须一起讨论。
- Why now 四因素：transformer architecture、compute/data、self-supervised generative learning、scaling。
- Transformers 的关键意义是更好建模 long-range dependencies，并成为大规模预训练的基础架构。
- Self-supervision 让模型从 raw text 自动构造学习信号，降低对任务标注的依赖。
- Scaling historically drives capability gains，但模型大小不是充分条件；数据质量、训练方法和任务适配同样关键。
- 现代 NLP 扩展到 multilingual、dialects、language varieties 和 multimodal LLMs，因此 evaluation 也必须覆盖更真实的人群与输入。
- Frontier tasks 如 GAIA/ARC-AGI-2 强调开放世界、多步推理、工具使用、多模态和抗记忆。

- Economic impact 不能只看 investment; 从 pilot 到 production 的 ROI 取决于 workflow integration、memory、learning loops 和组织摩擦。
- Safety/security 风险包括 cyber misuse、prompt injection、disinformation、biased critical systems 和 information trust erosion。
- ATNLP 的能力目标是 analyse、explain、design/implement/adapt、evaluate with error analysis。
- Responsible innovation 要把 fairness、transparency、real-world impact 和 harm mitigation 放进技术判断。
- 考试答题总模板：机制是什么、为什么现在重要、如何评估、真实部署有什么风险与限制。

一段稳妥考场回答

Lecture 1 frames modern NLP as both a technical paradigm shift and a real-world responsibility problem. The recent acceleration of NLP comes from the convergence of transformer architectures that model long-range dependencies, large-scale compute and datasets, self-supervised generative training on raw text, and scaling to larger models. These factors moved NLP from niche language-processing tasks to ubiquitous systems used across translation, summarisation, QA, agents, multilingual and multimodal applications. However, the lecture also warns against a simple “bigger is always better” story: smaller models can outperform larger ones on some tasks, frontier benchmarks increasingly test tool use, multimodality, multi-step reasoning and resistance to memorisation, and real economic value depends on production integration rather than impressive demos. Therefore ATNLP studies not only algorithms, but also rigorous evaluation, error analysis, adaptation, safety, security, ethics and responsible innovation. A strong NLP system must be technically capable, well evaluated, robust in deployment, fair and transparent enough for its real-world context, and designed to improve human outcomes rather than merely maximise benchmark scores.