

Machine Translation

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

MT as meaning-preserving cross-lingual generation → Ambiguity, morphology, word order and accuracy make translation hard → Parallel text as the fuel for supervised MT → Web-scale data extraction and low-resource imbalance → Translation modelling as conditional generation → From phrase-based feature engineering to neural encoder-decoder models → Multilingual NMT and LLM prompting change the training/deployment paradigm → Evaluation via adequacy, fluency, ChrF, COMET and error spans → Final caveat: MT is powerful, useful and still not solved

Difficulty of MT task

Ambiguity

English: bank



English: run

这节课一句话

这节课的核心不是把机器翻译理解成“把词典逐词替换”，而是看清 MT 为什么难、为什么需要平行语料、模型如何从 phrase-based 走到 NMT/LLM，以及为什么翻译系统最后必须用 human/automatic metrics 谨慎评估。

1. 先拆掉词典神话：MT 的敌人叫语境

Difficulty of MT task

Ambiguity

English: bank



English: run

Alexandra Birch

ATNLP Week 1/ Lecture 2

School of
informatics

8

原 PPT 第 8 页

人话直觉

如果翻译只是查词典，机器翻译早就结束了。真正麻烦的是，一个词像演员一样会换角色：bank 可以是银行，也可以是河岸；run 可以是跑步、经营、运行、竞选。模型必须先看懂这句话里它扮演的是哪一个角色，再决定目标语言里该用哪个词。

精确定义 / 机制： Slide 8 用 lexical ambiguity 说明 MT 的基本困难：source token 到 target token 不是一对一映射，而是受上下文、领域、搭配和语义角色约束的选择问题。英语 bank 翻到法语可能是 banque，也可能是 rive；这要求模型利用句内甚至篇章信息做 word sense disambiguation。对现代模型来说，这一步不是显式查规则，而是在条件概率 $p(T|S)$ 中通过上下文表示、attention 或 LLM hidden states 体现出来。

考试问法： 如果问“为什么 MT difficult”，第一点不要答成泛泛的“语言不同”。要具体说 ambiguity：同一个 source word 在不同 context 下有不同 target translations；系统需要根据上下文消歧，否则会产生意义错误。

2. 词形和词序：不是每种语言都把意思装进同样的盒子

Difficulty of MT task

Word Order

English: *He wrote a letter to a friend*

Japanese: *tomodachi ni tegami-o kaita*
friend to letter wrote

Arabic: *katabt risāla li šadq*
wrote letter to friend

原 PPT 第 10 页

人话直觉

英语像把零件按一种顺序摆好，日语可能把同样零件倒过来，还把介词变成后置词；芬兰语则可能把“在购物中心里”压进一个长词里。MT 不是搬运单词，而是在两套语法包装系统之间重新打包意思。

精确定义 / 机制：讲义连续用 morphology 和 word order 强调 structural divergence。形态丰富语言会把格、数、时态、地点等信息编码进词形，例如 Finnish ostoskeskuksessa 对应 English in the shopping center。词序上，English He wrote a letter to a friend 与 Japanese tomodachi ni tegami-o kaita 的论元顺序和介词/后置词位置不同；Spanish bruja verde 与 English green witch 又展示 noun-adjective order 差异。这些现象要求 MT 同时处理 morphology generation、syntactic reordering 和 agreement，而不是逐词替换。

考试问法：考试常把 ambiguity、morphology、word order 分开问。推荐答法：morphology 影响一个词内部包含多少语法信息；word order 影响句子成分如何重排；二者都会让 source-target alignment 变得非线性。

3. 平行语料：机器翻译的燃料不是语言本身，而是对齐过的翻译例子

Parallel data from Crawls

Danish: det er næsten en personlig rekord for mig dette efterår .
German: das ist für mich fast persönlicher rekord in diesem herbst .
Greek: πρόκειται για το προσωπικό μου ρεκόρ αυτό το φθινόπωρο .
English: that is almost a personal record for me this autumn !
Spanish: es la mejor marca que he alcanzado este otoño .
Finnish: se on melkein minun ennätyskeni tänä syksynä !
French: c ' est pratiquement un record personnel pour moi , cet automne !
Italian: e ' quasi il mio record personale dell ' autunno .
Dutch: dit is haast een persoonlijk record deze herfst .
Portuguese: é quase o meu recorde pessoal deste semestre !
Swedish: det är nästan personligt rekord för mig denna höst !

Koehn P. (2005). Europarl: A Parallel Corpus for Statistical Machine Translation. MTSummit

- Hansard Corpus, Europarl, UN

Q: Why sentences?

Alexandra Birch

ATNLP Week 1/ Lecture 2

School of informatics

17

原 PPT 第 17 页

人话直觉

训练 MT 像教学生看双语对照本：左边一句 Danish，右边同一句 English，再旁边还有 German、French、Spanish。模型不是被告知抽象语法规则，而是从成千上万对“同义不同语”的句子中学会怎么搬运意义。

精确定义 / 机制： Parallel text 是 supervised MT 的核心资源：同一内容在两个或多个语言中的句子级对齐版本。Slide 17 的 Europarl/Hansard/UN 例子展示了多语言机构文本为什么历史上重要，因为它们天然包含同一会议或文件的多语翻译。对 statistical MT 和 neural MT 来说，构建一个新 language pair 的系统很大程度取决于 parallel texts 是否可得、规模是否足够、质量是否稳定。低资源语言往往不是“模型不想学”，而是高质量可对齐数据太少。

考试问法：如果问“为什么 parallel corpus important”，答：它提供 source sentence 与 target sentence 的监督信号，使模型能估计 $p(T|S)$ 或学习翻译函数；但数据覆盖、噪声和低资源不平衡会限制系统质量。

4. Web-scale 数据不是免费午餐：CommonCrawl 进模型前要过很多关

Parallel data from web at scale

- Take large web crawl eg. CommonCrawl
- Language Identification: What languages are these?

ndiyahamba (I'm going)
This is lekker bru (This is lovely)

- Cleaning, document alignment, sentence splitting, sentence alignment, deduplication and filtering
- Q: what tends to happen in low-resource languages?

Alexandra Birch

ATNLP Week 1/ Lecture 2

School of informatics

18

原 PPT 第 18 页

人话直觉

别把网页爬虫想成一个干净语料库。它更像一仓库混杂文件：有英文、有南非英语、有拼写噪声、有重复页面、有错配翻译。真正的数据工程，是把这堆杂物筛成可以训练 MT 的双语句对。

精确定义 / 机制： Slide 18 给出从 web crawl 抽取 parallel data 的流水线：language identification 判断文本语言，cleaning 去掉垃圾和格式噪声，document alignment 找到互为翻译的文档，sentence splitting 切句，sentence alignment 对齐句子，deduplication and filtering 去重并过滤低质量样本。低资源语言常见问题是：网页数据少、语言识别更不可靠、被高资源语言污染、噪声比例高、可对齐翻译少。因此 web scale 解决了规模问题，却没有自动解决代表性、公平性和质量问题。

考试问法：如果考 low-resource MT/data，别只说“数据少”。要补充：语言识别难、alignment 噪声更大、domain 覆盖差、重复或机器翻译污染可能更严重，最终导致模型对这些语言表现不稳。

5. NMT 的一句话公式：目标句是一步一步条件生成出来的

Machine Translation

Decomposition of the translation problem:

- A source sentence S of length m is a sequence $x_1, \dots, x_m$
- A target sentence T of length n is a sequence $y_1, \dots, y_n$

$$\begin{aligned} T^* &= \arg \max_T p(T|S) \\ p(T|S) &= p(y_1, \dots, y_n | x_1, \dots, x_m) \\ &= \prod_{i=1}^n p(y_i | y_0, \dots, y_{i-1}, x_1, \dots, x_m) \end{aligned}$$

Alexandra Birch

ATNLP Week 1 / Lecture 2

School of Informatics

20

原 PPT 第 20 页

人话直觉

翻译时模型不是一次性从天上掉下一整句译文，而是像打字一样一个词一个词写：写第 i 个词时，它既看原句，也看自己前面已经写了什么。前面写错了，后面可能被带偏；前面写对了，后面才能保持连贯。


精确定义 / 机制： Slide 20 把 translation modelling 写成 conditional generation。给定 source sentence $S = x_1, \dots, x_m$ ，目标是找最可能的 target sentence $T = y_1, \dots, y_n$ ，即 $T^* = \operatorname{argmax}_T p(T|S)$ 。神经模型进一步把整句概率分解为每个目标 token 的自回归乘积：第 i 个 y_i 依赖特殊起始符/历史 $y_0, \dots, y_{i-1}$ 和完整源句 $x_1, \dots, x_m$ 。这解释了为什么 decoder 需要 target history，也解释了 exposure/search errors：翻译质量不只是局部词选择，还取决于整条生成路径。

$$T^* = \operatorname{argmax}_T p(T | S), \quad p(T | S) = p(y_1, \dots, y_n | x_1, \dots, x_m) = \prod_{i=1}^n p(y_i | y_0, \dots, y_{i-1}, x_1, \dots, x_m)$$

考试问法：如果问 NMT 如何 formulate translation problem，必须写出 $p(T|S)$ 和 autoregressive factorisation，并用一句话解释：模型最大化给定源句时目标句的条件概率。

6. 从 phrase-based 到 encoder-decoder: 少写人工特征, 多学连续表示

Encoder Decoder Translation



Vaswani et al. (2017) Attention is all you need

原 PPT 第 24 页

人话直觉

早期 phrase-based MT 像一台由很多人工齿轮拼起来的机器: 短语表、重排序规则、语言模型、稀疏特征, 每个齿轮都要调。NMT 更像训练一个可微函数: encoder 读源句, decoder 写目标句, cross-attention 让 decoder 随时回头看源句哪个位置重要。

精确定义 / 机制: 讲义先指出 phrase-based MT 的问题: manual feature engineering 费时、specific、incomplete; log-linear sparse features 带来学习和搜索困难; 语义表示和长期历史捕捉有限。NMT 的改变是从 bitext 中端到端学习向量函数, 输出 conditioned on full source text and target history, 并使用 continuous representations。Slide 24 的 encoder-decoder transformer 是标准架构: encoder 用 transformer blocks 编码源句; decoder 使用 masked self-attention 看已生成目标历史, 并通过 cross-attention 访问所有 encoder words。

考试问法: 若比较 phrase-based MT 与 NMT, 答: phrase-based 依赖人工特征和短语/重排序模型, 语义和长距离依赖弱; NMT 端到端学习连续表示, 能对完整源句和目标历史建模, 但仍需要大量数据和计算。

7. LLM 翻译的新范式：预训练先学语言，prompt 再指定任务

Case Study: EuroLLM

- Most models still primarily trained on English > 90%
- Want a model that truly supports European citizens, researchers, businesses and governments and is open source and transparent
- 9B base and instruct model – downloaded > 300k times on Huggingface (also 1.7B and 22B)
- Base model for 6 submissions in WMT 2025 competition
- Covers 24 Official European Languages and 11 other strategic languages

Martins et al. (2025). EuroLLM-9b: Technical Report

Alexandra Birch

ATNLP Week 1/ Lecture 2

School of
informatics

30

原 PPT 第 29 页

人话直觉

传统 MT 像给每个语言方向单独训练一个翻译专员；LLM 更像一个读过海量文本的通才，你在考场上告诉它“把这句翻成法语”，甚至给一两个例子，它就临时切换到翻译模式。强大，但也受预训练语言分布牵着走。

精确定义 / 机制： Slide 28-29 把 translation with LLMs 描述为 pre-train and prompt paradigm。Generative AI 通过 next-word prediction 学到一种或多种语言的 latent features，之后可通过 supervised/instruction fine-tuning 适配任务，再用 prompt、zero-shot/one-shot/few-shot examples 完成翻译。GPT-3 表格显示即使 93% 训练语料是 English，模型仍能在 DE/FR/RO 翻译上表现出 few-shot 能力，尤其翻译 into English 时受强 English LM 能力帮助。但这不等于监督 MT 被完全取代：parallel data 是否被加入预训练、目标语言覆盖、tokenisation fertility、数据 mix 和 post-training 都会影响多语言与翻译质量。
考试问法： 如果问 LLM 与传统 NMT 的区别，答：传统 NMT 多为特定 language direction 或 multilingual supervised translation；LLM 通过大规模预训练形成通用生成能力，再由 prompt/examples/instructions 调用翻译行为。优势是灵活，风险是语言覆盖不均、幻觉、prompt 敏感和低资源弱势。

8. 评估翻译：好译文要既保意思，又像目标语言的人话

Human Evaluation

Adequacy		Fluency	
5	all meaning	5	flawless English
4	most meaning	4	good English
3	much meaning	3	non-native English
2	little meaning	2	dis-fluent English
1	none	1	incomprehensible

原 PPT 第 38 页

人话直觉

翻译评分不能只问“顺不顺”，也不能只问“有没有逐字对应”。一句话可以很流利但翻错意思，也可以意思大致对但读起来像机器硬拼。Adequacy 和 fluency 就是两把尺子：一把量意义有没有带过去，一把量目标语言像不像人说的。

精确定义 / 机制：Human evaluation 仍是 MT evaluation 的 gold standard。Adequacy 关注 output 是否 convey the same meaning as input, 有无丢失、添加或扭曲信息；fluency 关注 target output 是否语法正确、用词自然、符合 idiom。Slide 39 的 1-5 scale 是典型评分方式，但 slide 41-42 也提醒 evaluators often disagree，因此现代评估会用 error span annotation 标出 major/minor errors，并由这些错误支持更可靠的 direct assessment score。

考试问法：若问 human evaluation，先定义 adequacy 和 fluency，再指出人工评价贵、慢、主观且 annotators may disagree；error span/MQM 类标注能提高诊断性，但成本更高。

9. 自动指标：ChrF 数表面重合，COMET 学人类判断

Trained metric: COMET

- Transformers can be used to encode, decode and evaluate!
- Have > 15 years of human evaluation data from WMT tasks - labelled training data
- COMET: Crosslingual Optimized Metric for Evaluation of Translation.
- Pretrain cross-lingual language model
- Fine-tune on human evaluations eg. Direct Assessments
- SOTA results for correlation with human judgements WMT 2019 Metrics shared task
- Trained on human evaluations for a number of language pairs - evidence that it generalises, but certainly less reliable

原 PPT 第 44 页

人话直觉

自动评估像给翻译装一个快速体温计。ChrF 看译文和参考译文在字符片段上有多像，便宜、稳定、适合快速比较；COMET 则像训练一个小评审，学着模仿人类评分，但它的判断也受训练数据和语言覆盖限制。

精确定义 / 机制： Automatic evaluation 的典型用例是评估系统 incremental changes，因为大规模人工评估太贵。ChrF 是 character F-score: chrP 衡量 hypothesis 中字符 n-grams 有多少出现在 reference, chrR 衡量 reference 中字符 n-grams 有多少被 hypothesis 覆盖，并用加权 F-score 合并，常设 $\beta=2$ 让 recall 权重更高。相较 word-level BLEU, ChrF 对 morphology-rich languages 更鲁棒，因为词形变化会被字符片段部分捕捉。COMET 则使用 pretrained cross-lingual language model，并在 WMT 等人类评价数据上 fine-tune 来预测 direct assessment 或 ranking，通常与人类判断相关性更高，但对未覆盖语言对、domain shift 和参考/源句质量仍需谨慎。

$$\text{chrF}_\beta = (1 + \beta^2) \frac{\text{chrP} \cdot \text{chrR}}{\beta^2 \text{chrP} + \text{chrR}}, \quad \text{chrF}_2 = 5 \frac{\text{chrP} \cdot \text{chrR}}{4 \text{chrP} + \text{chrR}}$$

考试问法： 如果考 automatic metrics，答题结构可为：为什么需要 automatic evaluation → ChrF 的字符 n-gram precision/recall/F-score → BLEU 词级匹配局限 → COMET 作为 trained metric 更接近人类判断但不是绝对可靠。

考试速记版

- MT 不是 dictionary lookup；核心是 meaning-preserving generation across languages.
- Ambiguity: bank/run 这类词必须靠 context 决定目标词，否则会翻错意义。
- Morphology: 有些语言把 case/number/location 等信息压进词形，目标语言可能要拆开表达。
- Word order: 不同语言的 verb/object/preposition/adjective 顺序可能不同，翻译需要 reordering。
- Parallel text 是 supervised MT 的燃料；新 language pair 的难点常是高质量 bitext 是否可得。
- Web-scale parallel data extraction 包括 language ID、cleaning、document alignment、sentence splitting/alignment、deduplication、filtering。
- Low-resource languages 的问题不只是数据少，还包括识别难、噪声高、覆盖差和 alignment 更不可靠。
- NMT 把翻译建模为 $T^* = \text{argmax}_T p(T|S)$ ，并把目标句概率自回归分解。
- Phrase-based MT 依赖人工特征和稀疏 log-linear models；NMT 端到端学习 continuous representations。
- Encoder-decoder transformer: encoder 编码源句，decoder 用 target history 和 cross-attention 生成译文。
- LLM 翻译属于 pretrain-prompt paradigm: 预训练学语言，prompt/few-shot 调出翻译行为。
- Multilingual MT 可能有 positive transfer，但需要更大模型、参数共享和合理 data mix。
- Human evaluation 看 adequacy 和 fluency；人工仍是 gold standard，但贵、慢且评审会 disagree。

- ChrF 是 character n-gram F-score，通常比 word-level BLEU 更适合形态丰富语言。
- COMET 是 trained metric，用跨语言模型和人类评价数据学习预测翻译质量；强但仍需注意泛化限制。
- 总结句：MT 已从 phrase-based 到 NMT/LLM 大幅进步，但 data、low-resource、evaluation 和 hallucination/accuracy 说明它不是 solved task。

一段稳妥考场回答

Machine Translation 的目标是给定源句 S 生成意义等价、目标语言自然的译文 T ，而不是逐词查词典。它困难主要因为语言之间存在 ambiguity、morphology、word order 和 accuracy 要求：例如 bank 需要根据上下文翻成 banque 或 rive，芬兰语可能把“在购物中心里”编码进一个复杂词形，英语、日语、阿拉伯语等语言的论元和介词/后置词顺序也不同。监督式 MT 的关键资源是 parallel text，即源句和目标句的对齐翻译例子；从 web crawl 构建 bitext 还需要 language identification、cleaning、document/sentence alignment、deduplication 和 filtering，低资源语言尤其受数据规模和噪声影响。现代 NMT 把翻译形式化为条件生成： $T^* = \operatorname{argmax}_T p(T|S)$ ，并将 $p(T|S)$ 分解为每个目标 token 在源句和已生成目标历史条件下的概率。与 phrase-based MT 的人工特征和稀疏 log-linear 模型相比，encoder-decoder transformer 端到端学习连续表示，encoder 编码源句，decoder 通过 self-attention 和 cross-attention 生成译文。LLM 又把翻译推进到 pretrain-prompt paradigm：模型先在大规模多语言/英语主导数据上预训练，再通过 prompt、zero-shot 或 few-shot examples 完成翻译，但语言覆盖、数据 mix、tokenisation 和 low-resource bias 仍会影响结果。评估方面，human evaluation 关注 adequacy 和 fluency，仍是 gold standard 但昂贵且评审不一致；automatic metrics 如 ChrF 用字符 n-gram precision/recall/F-score 快速比较系统，COMET 则用跨语言模型和人类评价数据学习更接近人类判断的分数。总之，MT 已从 phrase-based 系统发展到 NMT 和 LLM 翻译，但由于数据、建模和评估的限制，它仍然是一个强大但未完全解决的 NLP 任务。