

Summarisation: 把长文压短, 不是删字, 而是决定什么值得留下

图文讲义版: 用原 PPT 作为视觉锚点, 按“概念故事线 + 直觉解释 + 考试速记”整理。

Summarisation as compression with faithfulness → Four system decisions: type, data, model, evaluation → Single-document vs multi-document → Extractive vs abstractive → Extractive as sentence-level binary labelling → Pointer-generator as generate-copy mixture → CNN/DailyMail, XSum and LEAD-3 baseline → ROUGE and BERTScore as imperfect automatic metrics → Human/LLM evaluation and modern long-context summarisation

Four components in summarisation

When someone comes to develop a new summarisation system, they need to decide on:

- The type of summarisation to apply
- Data to learn
- Model and learning
- Evaluation

这节课一句话

这节课的核心不是“让模型写短一点”, 而是把 summarisation 拆成一条完整工程链: 先定义摘要任务类型, 再选择 extractive 或 abstractive 建模方式, 接着看数据集与强 baseline, 最后用 ROUGE、BERTScore、人类/LLM 评价和长文本策略判断摘要到底好不好。

1. 摘要系统的四个旋钮：类型、数据、模型、评价

Four components in summarisation

When someone comes to develop a new summarisation system, they need to decide on:

- The type of summarisation to apply
- Data to learn
- Model and learning
- Evaluation

人话直觉

先别急着问“用哪个模型”。摘要像给一篇长文章做行李打包：你要先知道是打包一篇文章还是一堆文章，是只准带原句还是可以改写，是给所有人看的通用摘要还是围绕某个问题的定制摘要。slide 6 的四个 components 就是这门课的地图：任务设定决定你压缩什么，数据决定你学到什么，模型决定你怎么压，评价决定你是否真的压对了。

精确定义 / 机制： Summarisation 的目标是把一个或多个较长文档压缩成更短、连贯的文本，同时保留 essential information、themes 和 main points。开发系统时需要同时决定四件事：第一，type of summarisation，例如 single-document/multi-document、extractive/abstractive、generic/query-focused/controllable、supervised/unsupervised、single-modal/multi-modal；第二，data to learn，包括是否有 document-summary pairs、句子级标签或参考摘要；第三，model and learning，例如句子分类、seq-to-seq、pointer-generator 或当代 LLM prompting/finetuning；第四，evaluation，包括自动指标、人类评价或 LLM-as-a-judge。

考试问法：如果考“设计 summarisation system 要考虑什么”，不要只列模型。高分答案按 slide 6 四件事组织：type、data、model/learning、evaluation，并各举一个例子。还要强调摘要质量不只是短，而是 concise、coherent、informative、faithful。

2. Single vs Multi-document: 一篇文章压缩 vs 多份证词合并

Multi-document versus single document

- Single document summarisation use a single source, for example, a news article
- Multi document summarisation uses multiple sources or documents for the summary (all sources are related to a theme or topic)

Food for thought: Which is easier and why?

人话直觉

单文档摘要像把一篇新闻改成短讯；多文档摘要像你收到十篇关于同一事件的报道，要写一段综合说明。难点立刻升级：同一个事实会被反复说，不能在摘要里重复三遍；不同来源可能时间不同、立场不同、细节冲突；而且材料变长后，模型更容易顾头不顾尾。

精确定义 / 机制： Single-document summarisation 基于一个 source document 生成摘要。Multi-document summarisation 基于多个与同一 theme/topic 相关的 sources 生成综合摘要。MDS 通常更难，因为它要处理 redundancy problem（多个文档的信息重叠，摘要要去重）、consistency problem（不同文档可能观点、时间线或事实不一致，摘要要保持内部一致），以及 longer context problem（输入更长，计算成本和上下文窗口压力增加，LLM 也更容易遗漏中间信息）。

考试问法：典型问法是“为什么 multi-document summarisation harder?”答三点：overlap/redundancy、inconsistency/conflicting views or times、more text/longer context。不要只说“文档更多所以更难”，要说明系统具体要解决什么。

3. Extractive vs Abstractive: 剪报纸和写社论的差别

Query-focused summarisation and controllable summarisation

Both use an additional input or parameter to summarise

Query-focused:

- Summarise a document based on a specific query

Controllable:

- Control parameters such as length, aspect, sentiment

Can be formulated as part of the prompt, or as additional information we condition on, or part of the encoding in an encoder-decoder summariser

人话直觉

Extractive 像拿荧光笔在原文里圈句子，再把圈出来的句子拼成摘要；abstractive 像你读懂后重新用自己的话讲给别人。前者不够优雅，可能衔接生硬，但它有一个巨大优点：句子来自原文，事实风险低。后者更像人类写摘要，能合并、压缩、改写，但一旦模型“自由发挥”，hallucination 就来了。

精确定义 / 机制： Extractive summarisation 输出是原文句子的 subset；abstractive summarisation 输出不受原文 exact wording 约束，可以生成新的表达。Extractive 的价值在于 high precision：新闻、法律、医疗等场景宁可摘要朴素，也不希望模型编造原文没有的信息。Abstractive 更灵活，能生成更连贯、更高度概括的文本，但模型必须同时做 content selection、compression、paraphrasing 和 factual control，因此难度更高，也更依赖评价与事实一致性检查。

考试问法： 比较题要先定义，再谈 trade-off：extractive = original sentences, higher factual precision, less flexible/coherent；abstractive = generated wording, more natural/compact, higher hallucination risk。若问为什么 LLM 时代还需要 extractive，答 high precision 和可追溯。

4. 抽取式摘要的朴素建模：给每个句子贴 0/1 标签

First Shot at Modelling Extractive Summarisation

We have a document $d = (s_1, \dots, s_n)$ with n sentences

Use classification: $y_i = 1$ if s_i should be in the (extractive) summary, and 0 if not

Quite simple and indeed serves as the basic model for many summarisers... but presents some challenges

人话直觉

把 extractive summarisation 想成挑队员：文档里每个句子都来面试，模型给它打一个“进摘要/不进摘要”的标签。问题是老师通常只给你最终摘要，不会告诉你“第 3 句该选、第 9 句不该选”。于是 naive 方法就拿 ROUGE 当临时裁判：哪个原文句子和参考摘要词面重合高，就先把它当正例。

精确定义 / 机制：给定文档 $d = (s_1, \dots, s_n)$ ，可以把每个句子 s_i 建模为二分类标签 $y_i \in \{0, 1\}$ ，其中 $y_i = 1$ 表示该句应进入 extractive summary。训练难点有两个：labels 从哪里来、objective 用什么。naive way 是计算文章中每个句子与人工参考摘要之间的 ROUGE 分数，选择最高分句子作为正标签，再用 binary classification objective 最大化数据 log-likelihood。这个方法简单有效，但也有错位：ROUGE 偏词面重合，逐句分类也不直接优化摘要整体的 coverage、redundancy、coherence 和 length。

$$d = (s_1, \dots, s_n), \quad y_i \in \{0, 1\}, \quad \max_{\theta} \sum_i \log p_{\theta}(y_i | s_i, d)$$

考试问法：如果题目问“如何把 extractive summarisation 建模成 binary labelling”，写 $d = (s_1, \dots, s_n)$ 、 $y_i = 1/0$ ，并解释伪标签可由 ROUGE against reference summary 得到。高分点是指出局限：单句标签与最终摘要整体质量不完全一致。

5. Pointer-Generator: 一半会写，一半会抄

Summarisation as Binary Labelling

Two main questions we will discuss:

- Where do we get the labels to train the model?
- What objective do we choose to train with?

人话直觉

纯生成模型像闭着眼写摘要，容易把人名、地名、数字写错；纯复制模型又像只会剪贴，表达不够自然。Pointer-generator 的聪明之处是给 decoder 一个旋钮 p_{gen} ：现在这个词到底应该从词表里生成，还是从原文注意力指向的位置复制？遇到“£625,000”“Whippingham”这种专有细节，复制比硬生成靠谱得多。

精确定义 / 机制：Abstractive summarisation 可以视为 text generation。See et al. (2017) 的 pointer-generator network 以 seq-to-seq 为基础，在每个时间步 t 把普通 vocabulary distribution 与从 source tokens 复制的 attention distribution 混合。 p_{gen} 越大，模型越倾向从 $P_{vocab}(w)$ 生成； $1 - p_{gen}$ 越大，模型越倾向按 attention weights a_i^t 从原文中复制所有等于 w 的位置。coverage mechanism 进一步累计过去 attention，提醒模型哪些源文位置已经看过，从而减少早期 seq-to-seq 摘要常见的重复生成。

$$P(w) = p_{gen}P_{vocab}(w) + (1 - p_{gen}) \sum_{i: w_i=w} a_i^t, \quad c^t = \sum_{t'=0}^{t-1} a^{t'}$$

考试问法：考 pointer-generator 时必须说清 generate-copy mixture： p_{gen} 控制从词表生成还是从源文复制；复制项由 attention weights 给出；coverage 用过去 attention 累计避免 repetition。不要只说“它处理 OOV”，要联系摘要中的人名、数字、关键短语和重复问题。

6. 数据集与 LEAD-3: 强 baseline 会暴露数据偏置

Abstractive summarisation

Treat the problem of summarisation as a text generation problem (rather than extracting sentences as before)

See et al. (2017) use a pointer-generator network as follows:

- The base is a sequence-to-sequence model

人话直觉

如果你发明了一个很复杂的新闻摘要模型，结果只比“取前三句”好一点点，那就很尴尬：也许不是模型真的会总结，而是新闻本来就把最重要的信息放在开头。LEAD-3 像一个朴素但刺耳的考官，专门提醒我们别把数据集的位置偏置误当成智能。

精确定义 / 机制：CNN/DailyMail 由新闻文章和 story highlights 组成，CNN 约 100k 对、Daily Mail 约 200k 对；文章平均约 800 words，摘要通常 3-4 句、约 56 words。由于新闻常采用 inverted pyramid 结构，直接取文章前 3 句作为候选摘要的 LEAD-3 baseline 表现很强。XSum 则更偏 extreme summarisation，通常要求用单句高度概括整篇 BBC 文章，比 CNN/DailyMail 更抽象、更难用开头句解决。不同数据集对应不同摘要目标，所以评价模型时必须同时看 dataset bias 和 baseline。

考试问法：如果问 LEAD-3，定义是 taking the first three sentences as summary；如果问为什么重要，答新闻位置偏置使它很强，是复杂模型必须超过的 baseline。若比较 CNN/DailyMail 和 XSum，前者较长、多 highlights、容易受 lead bias 影响；后者更短、更抽象、更考验概括。

7. ROUGE: 数覆盖率很有用，但它不懂反话

Some results

Models	ROUGE		
	1	2	L
seq-to-seq+attn	31.33	11.81	28.83
pointer-generator	36.44	15.66	33.42
pointer-generator + coverage	39.53	17.28	36.38
lead-3 baseline	40.34	17.70	36.57
BERTSUMABS	41.72	19.39	38.76

What is LEAD-3? Taking the first three sentences in the document as the candidate summary

人话直觉

ROUGE 像拿参考摘要当购物清单，看候选摘要买回来了多少清单上的东西。它特别关心 recall：重要信息有没有被覆盖？但它也很“眼神不好”：如果候选摘要和参考摘要词很像，却把 interesting 改成 boring，词面重合仍然高，事实和语义却完全反了。

精确定义 / 机制： ROUGE-N (Recall-Oriented Understudy for Gisting Evaluation) 计算候选摘要匹配到参考摘要中多少 n-grams。分子是 reference summaries 中被 candidate 匹配的 n-gram counts，分母是 reference summaries 中全部 n-gram counts，因此天然强调 recall。摘要评价重 recall 是因为我们想知道 candidate 是否覆盖 reference 中的重要信息；但只看 recall 或词面重合会低估合理 paraphrase，也可能高估事实错误但词面相近的摘要。ROUGE-L 则基于最长公共子序列，ROUGE 也可计算 F1 版本。

$$\text{ROUGE-N} = \frac{\sum_{S \in \text{ref}} \sum_{\text{gram}_n \in S} \text{count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \text{ref}} \sum_{\text{gram}_n \in S} \text{count}(\text{gram}_n)}$$

考试问法：公式题写清分子分母：matched n-grams over reference n-grams。解释题强调 recall-oriented，因为摘要要覆盖参考中的关键信息。局限题答 lexical overlap、paraphrase 不友好、不能保证 faithfulness 或 informativeness。

8. BERTScore、人类评价与 LLM Judge：从词面相似到质量判断

Datasets

Many datasets are available for training and testing summarisation models, including:

XWikis (Perez-Beltrachini and Lapata, 2021), cross-lingual document-summary pairs in 4 languages derived from Wikipedia
MLSUM (Scialom et al., 2020), document-summary pairs, 5 languages news outlets
XSum (Narayan et al., 2018), 227K BBC articles with single-sentence summaries
NewsRoom (Grusky et al., 2018), 1.3M article-summary pairs written by editors
arXiv, **PubMed** (Cohan et al., 2018), abstract and paper body (113K and 215K)
BigPatent (Sharma et al., 2019) 1.3 million US patents with human summaries
WikiHow (Koupaei and Wang, 2018) 200K instructions with single-sentence summaries
Reddit TIFU (Kim et al., 2019) 129K stories with descriptive summaries

人话直觉

BERTScore 比 ROUGE 更聪明一点：它不要求两个词完全一样，而是看 embedding 里有没有语义相近的词。但它仍然像在局部配对 token，不等于真正读懂摘要是否有用。最后，摘要评价绕不开人的标准：相关吗？流畅吗？连贯吗？忠实吗？够简洁吗？LLM-as-a-judge 只是把这件事自动化了一部分，不是把问题消灭了。

精确定义 / 机制： BERTScore 用 contextual embeddings 计算 reference x 与 candidate $\hat{x}$ 的 soft overlap，分别定义 recall、precision 和 F1：reference 中每个 token 找 candidate 中最相似 token，对应 recall；candidate 中每个 token 找 reference 中最相似 token，对应 precision。它比 ROUGE 更能处理同义改写，但仍偏 token-level similarity，难以完整评价信息组织和事实忠实性。Human evaluation 可采用 pairwise ranking、absolute scoring 或 question-based evaluation，关注 relevance、fluency、coherence、faithfulness 和 conciseness。LLM-as-a-judge 模仿这些评价方式，但会受 prompt sensitivity、surface features 和 consistency 问题影响。

$$R = \frac{1}{|x|} \sum_i \max_j x_i^T \hat{x}_j, \quad P = \frac{1}{|\hat{x}|} \sum_j \max_i x_i^T \hat{x}_j, \quad F = \frac{2PR}{P+R}$$


考试问法：若比较 ROUGE 和 BERTScore：ROUGE 是 hard n-gram overlap，BERTScore 是 embedding-based soft overlap。若问为什么还需要 human evaluation：自动指标无法可靠判断事实正确、信息选择和整体可读性。若问 LLM-as-a-judge：优点是可扩展、评价可能比生成容易；缺点是 prompt 敏感、不稳定、可能偏表面质量。

9. 当代 LLM 摘要：短文很强，长文仍会漏中间

Illustration of BERTScore

Every cell in the matrix corresponds to dot product of the form

$$\hat{x}_i^T \hat{x}_j$$



Shay Cohen

ATNLP Lecture 3

26/35

原 PPT 第 33 页

人话直觉

今天的商业 LLM 做中等长度摘要已经像熟练助教：给它一篇文章，prompt 一下，通常能写得很顺。但别把这当成 summarisation 已经毕业了。长文本像一本书塞进窗口，模型可能记住开头和结尾，却把中间关键章节忘掉；抽象生成还会 hallucinate；自动指标也经常跟人类偏好对不上。

精确定义 / 机制：现代 summarisation 从专门任务逐渐转向通用 LLM prompting 和 adaptation。LLMs 对 papers、reports、articles 等 medium-length texts 表现很好，也天然支持 query-focused summarisation，例如只总结与某个问题相关的部分。但核心问题仍在：hallucination、long-text coverage、lost-in-the-middle、评价不可靠。长文本可用 hierarchical-style summarisation：先把 document 切成 chunks，分别摘要，再把局部摘要拼接成新文档继续摘要；它缓解上下文限制，但早期遗漏的信息很难恢复，也可能破坏全局一致性。当前社区重点转向 multilingual data 和更 fine-grained evaluation。

考试问法：如果问“summarisation these days”，答 LLM prompting 对中等长度文本很强，但仍有 hallucination 和 long context 问题；query-focused summarisation 可通过 prompt/conditioning 实现；研究重点包括 multilingual data 和 fine-grained evaluation。若问 long-text challenge，提 hierarchical summarisation 与 lost-in-the-middle。

考试速记版

- Summarisation 是压缩长文并保留关键信息，不等于机械缩短。
- 设计摘要系统先答四件事：type、data、model/learning、evaluation。
- Multi-document summarisation 难在 redundancy、consistency 和 longer context。
- Extractive 选原文句子，precision/faithfulness 较高；abstractive 生成新表达，更灵活但更易 hallucinate。
- Extractive 可建模为 sentence-level binary labelling： $d = (s_1, \dots, s_n)$ ， $y_i = 1$ 表示选入摘要。

- 没有句子级标签时，可用句子与参考摘要的 ROUGE 造伪标签，但它偏词面重合。
- Pointer-generator 用 p_{gen} 混合 vocabulary generation 和 source copying，适合保留专有名词、数字和关键短语。
- Coverage mechanism 累计过去 attention，主要减少 seq-to-seq 摘要重复生成。
- CNN/DailyMail 是新闻文章与 highlights 数据集；LEAD-3 因新闻开头位置偏置而很强。
- XSum 更像单句极限摘要，比 CNN/DailyMail 更抽象、更难靠抽取解决。
- ROUGE-N 是 reference-based n-gram recall，优点简单可复现，缺点是不懂改写和事实忠实。
- BERTScore 用 contextual embeddings 做 soft overlap，但仍不能完全评价 coherence、faithfulness 和 usefulness。
- Human evaluation 常看 relevance、fluency、coherence、faithfulness、conciseness。
- LLM-as-a-judge 可扩展但 prompt-sensitive，可能过度依赖表面特征且一致性不足。
- 长文本摘要会遇到上下文限制、lost-in-the-middle 和信息遗漏；hierarchical summarisation 能缓解但会传播早期遗漏。
- 当代 LLM 对中等长度摘要很强，但 hallucination、多语言数据和细粒度评价仍是核心研究问题。

一段稳妥考场回答

Summarisation 是把一个或多个长文档压缩成更短、连贯的摘要，同时保留核心信息、主题和观点。设计摘要系统时要同时考虑四件事：任务类型、训练数据、模型与学习方法、评价方式。任务类型上，single-document summarisation 只总结一个源文档；multi-document summarisation 要整合多个相关文档，因此更难处理重复信息、冲突观点/时间线和更长上下文。另一个核心区分是 extractive 与 abstractive：extractive summarisation 从原文中选择句子，通常事实 precision 较高、幻觉少，但表达不够灵活；abstractive summarisation 生成新的语言表达，更自然、更能压缩和概括，但更容易遗漏或产生 hallucination。抽取式摘要可建模为句子级二分类：文档 $d = (s_1, \dots, s_n)$ ，对每个句子预测 $y_i \in \{0, 1\}$ ，其中 $y_i = 1$ 表示该句进入摘要；没有人工句子标签时，可用句子与参考摘要的 ROUGE 分数构造伪标签，再用 binary log-likelihood 训练，但这种目标不直接优化摘要整体的冗余、连贯和覆盖。生成式摘要可用 pointer-generator network，把从词表生成和从源文复制结合起来： p_{gen} 控制生成/复制的混合，attention-based copy 项帮助保留人名、数字和关键词，coverage mechanism 用累计 attention 减少重复。数据与 baseline 也很关键：CNN/DailyMail 提供新闻文章和 highlights，但新闻开头常包含重点，使 LEAD-3（取前三句）成为很强 baseline；XSum 更短、更抽象，更考验真正概括能力。评价方面，ROUGE-N 计算候选摘要覆盖参考摘要中多少 n-gram，是 recall-oriented 的词面重合指标，但会低估合理改写，也可能高估事实错误摘要；BERTScore 用上下文 embedding 做 soft overlap，能处理部分语义相似，但仍不能完全判断信息组织和忠实性。因此人类评价仍重要，常看 relevance、fluency、coherence、faithfulness 和 conciseness；LLM-as-a-judge 可扩展但受 prompt、表面特征和一致性问题影响。现代 LLM 通过 prompting 已能很好总结中等长度文本，也能做 query-focused summarisation，但仍会 hallucinate，长文本还会有上下文限制和 lost-in-the-middle；hierarchical summarisation 可把长文切块逐级摘要，但早期遗漏信息难以恢复。