

Question Answering: 让机器从“会读文字”走向“会找证据并回答问题”

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

QA 的任务定义与问题类型 → 为什么 QA 是语言理解 test bed → Reading Comprehension: P,Q 到 A → Extractive span answer → SQuAD 与 EM/F1 评价 → Neural RC: start/end prediction → BiDAF 到 BERT fine-tuning → Open-Domain QA 与 retrieval → Natural Questions 与真实搜索问题 → Fusion-in-Decoder 与现代 RAG 前身

What is Question Answering?



In question answering, we aim to build systems that can **automatically** answer questions posed by humans in **natural language**.

What type of questions?

Factoid vs. Non-Factoid; Open-Domain vs. Closed-Domain; Simple vs. Compositional; Natural vs. Cloze-style; ...

What type of answers?

Short text; Paragraph; List; Yes/No; Multiple Choice

这节课一句话

这节课的主线是：QA 不是简单生成一句话，而是把自然语言理解压缩成一个可检验任务——先理解问题，再在给定 passage 或大型知识库中定位证据，最后抽取或生成答案。

1. QA 到底在考机器什么

What is Question Answering?



In question answering, we aim to build systems that can **automatically** answer questions posed by humans in **natural language**.

What type of questions?

Factoid vs. Non-Factoid; Open-Domain vs. Closed-Domain; Simple vs. Compositional; Natural vs. Cloze-style; ...

What type of answers?

Short text; Paragraph; List; Yes/No; Multiple Choice

原 PPT 第 5 页

人话直觉

先别把 QA 想成“聊天机器人随口答一句”。它更像一场语言理解综合测验：问题本身要读懂，背景文本或知识源要读懂，还要把问题和证据对齐。人问“Beyoncé 什么时候开始走红？”系统不能只知道 Beyoncé 是歌手，而要知道问题要的是时间，并在文本里找到“late 1990s”这种答案。

精确定义 / 机制： Question Answering 指构建能自动回答人类自然语言问题的系统。slide 5 同时提醒我们，QA 不是单一任务族：问题可以是 factoid 或 non-factoid、open-domain 或 closed-domain、simple 或 compositional、natural 或 cloze-style；答案也可以是短文本、段落、列表、yes/no 或 multiple choice。QA 之所以重要，是因为许多 NLP 任务都能改写成“给定一个问题，输出一个答案”：翻译可以问“这句话用西班牙语怎么说”，信息抽取可以问“Obama 毕业于哪里”，词性标注可以问“runs 在句中是什么词性”。
考试问法：如果考“什么是 QA”或“为什么 QA 是 test bed”，先给定义，再强调它同时测试 question understanding、context/knowledge understanding 和 answer grounding。分类题要能举例：factoid 常是实体、日期、地点；non-factoid 常要解释或长答案；open-domain 不限定小段文本，closed-domain 限定领域或材料。

2. Reading Comprehension: 开卷题的基本形状

Reading Comprehension

Comprehend a passage of text, and answer questions about its content.

$$(P, Q) \rightarrow A$$

Where:

P is the Paragraph

Q is the Question

A is the Answer

Extractive QA: extract answer word for word from context

原 PPT 第 14 页

人话直觉

Reading Comprehension 就像考试卷上已经把文章贴在题目前面：你不需要上网搜资料，关键是读懂这段材料，然后把问题指向的那一小块信息找出来。extractive QA 更严格——答案必须是文章里原封不动的一段文字，好处是可追溯，坏处是文章里没这么写就很难答。

精确定义 / 机制：Machine Reading Comprehension 的形式化输入输出是 paragraph P 和 question Q ，输出 answer A ，即 P, Q 到 A 。Extractive QA 是其中一种重要设置：答案逐字来自给定 context，通常是一个连续 span。slides 15-17 的 Beyoncé 例子展示了同一段 passage 可以被不同问题触发出不同 span：时间、活动类型、城市州名。系统的核心操作不是“凭常识发挥”，而是把问题语义映射到 passage 中对应证据位置。

$$P, Q \rightarrow A$$

考试问法：如果考 Reading Comprehension，必须写出给定 passage 和 question 后输出 answer；如果问 extractive QA，要写答案来自 context 中的 span，并说明优点是 grounded/easy to evaluate，局限是不能很好处理答案不在原文、需要总结、多证据融合或生成解释的场景。

3. SQuAD: 把阅读理解变成可训练的赛道

Stanford Question Answering Dataset (SQuAD)

- 100k annotated *passage-question-answer* triples
- Large-scale supervised datasets were instrumental for training effective neural RC models
- Passages are selected from the English Wikipedia
- Crowdsourced questions
- Each answer is a short segment of text (*span*) in the passage.
- It does not include questions where the answer are not mentioned in the span, and *unanswerable questions*

SQuAD was very popular (2016-2018) — today is considered “almost solved” since neural models exceed human performance

In meteorology, precipitation is any product of the condensation of atmospheric water vapor that falls under **gravity**. The main forms of precipitation include drizzle, rain, sleet, snow, **graupel** and hail... Precipitation forms as smaller droplets coalesce via collision with other rain drops or ice crystals **within a cloud**. Short, intense periods of rain in scattered locations are called “showers”.

What causes precipitation to fall?

gravity

What is another main form of precipitation besides drizzle, rain, snow, sleet and hail?

graupel

Where do water droplets collide with ice crystals to form precipitation?

within a cloud

Alexandra Birch

ATNLP Week 2 / Lecture 4

School of Informatics

18

原 PPT 第 18 页

人话直觉

SQuAD 的作用有点像给阅读理解装上跑道和计时器：大家用同一种数据格式训练，用同一套指标比较，模型进步一下子变得可见。它的强大也正是它的限制——题目通常配好了短 passage，答案也在原文 span 里，这比真实用户搜索干净太多。

精确定义 / 机制：SQuAD 是 Stanford Question Answering Dataset, 包含约 100k 个 passage-question-answer triples。passages 来自 English Wikipedia, questions 通过 crowdsourcing 得到, 每个 answer 是 passage 中的短文本 span。它推动了 2016-2018 年 neural reading comprehension 的快速发展, 也让 BiDAF、BERT 等模型可以被系统比较。但原始 SQuAD 不包含答案不在 span 中的问题, 也不包含 unanswerable questions; 后来模型在该基准上接近或超过 human performance, 并不等于真正解决了 QA, 因为真实 QA 还有检索、歧义、长文档、无答案和多证据融合。

考试问法：考“SQuAD 的贡献与局限”时, 贡献写大规模监督数据、Wikipedia passage、crowdsourced questions、span answers、推动 neural RC; 局限写 short passage、extractive span、缺少检索、缺少无答案和真实歧义。不要把“SQuAD almost solved”误写成“QA solved”。

4. EM 与 F1: QA 评价为什么没那么简单

Evaluation

Metrics: **Exact Match** (EM; 0 or 1) and **F1** (partial credit)

- Multiple valid answers for each question
- Take the score which is the maximum across alternatives
- Normalisation: remove articles (a, an, the) and punctuation
- We then average EM and F1 over the whole dataset.

Q: What did Tesla do in December 1878?

EM: $\max\{0, 0\} = 0$

A: {left Graz, left Graz and severed all relations with his family}

Precision: 2/4, 4/4

Recall: 2/2, 2/9

Prediction: *left Graz and severed*

F1: $\max\{0.67, 0.61\} = 0.67$

Alexandra Birch

ATNLP Week 2 / Lecture 4

School of
informatics

19

原 PPT 第 19 页

人话直觉

QA 评分最麻烦的地方是：一个答案可能有多种说法。学生写“left Graz”，另一个写“left Graz and severed all relations with his family”，前者短但抓住核心，后者长但也许多写了内容。EM 像严格判卷老师，必须完全一致；F1 像看关键词重合的老师，允许部分正确。

精确定义 / 机制： Exact Match (EM) 通常是 0 或 1：预测答案经过 normalization 后是否与某个 gold answer 完全一致。F1 基于 prediction 和 gold answer 的 token overlap，计算 precision 与 recall 的调和平均，因此能给部分匹配 partial credit。SQuAD 评价允许多个 valid answers，并对所有参考答案取最高分；常见 normalization 包括去掉 articles、punctuation 和大小写差异。EM 的问题是太严格，语义正确但措辞不同会被判错；F1 的问题是仍依赖词面重合，不能真正判断语义等价，也可能奖励含有多余词的答案。

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

考试问法：如果问 EM vs F1，答法要有三层：EM 完全匹配、F1 token overlap、多个 gold answers 取 max。评价局限题要指出二者都不是完美语义评价，尤其生成式 QA、长答案、解释型答案和同义改写会让词面指标失真。

5. Neural RC: 把答案变成两个指针

Neural Reading Comprehension

Problem:

Input:

context/paragraph $C = \langle c_1, \dots, c_n \rangle$, question $Q = \langle q_1, \dots, q_m \rangle$, $c_i, q_j \in V$

Output:

$1 \leq \text{answer start index} \leq \text{answer end index} \leq n$
(start and end indices in the provided context/passage)

原 PPT 第 20 页

人话直觉


神经阅读理解里，模型常常不是从零开始写一句答案，而是在 passage 上放两枚图钉：第一枚钉 answer start，第二枚钉 answer end。比如 Beyoncé 段落里，问题问“什么时候开始流行”，模型要把 start 指到 in，把 end 指到 1990s。

精确定义 / 机制： slide 20 把 extractive neural RC 形式化为：context C 是 token 序列，question Q 也是 token 序列；输出不是任意字符串，而是 context 中满足 $1 \leq \text{start index} \leq \text{end index} \leq n$ 的答案区间。这种 start/end span prediction 与 SQuAD 非常匹配，因为 SQuAD 答案通常是 passage 中连续 span。它让 QA 变成监督学习中的位置预测问题：模型为每个 context token 打 start probability 和 end probability，再组合出最可能答案 span。

$$C = \langle c_1, \dots, c_n \rangle, \quad Q = \langle q_1, \dots, q_m \rangle, \quad 1 \leq s \leq e \leq n$$

考试问法：如果考 neural RC 的输入输出，要写 $C = \langle c_1, \dots, c_n \rangle$ 、 $Q = \langle q_1, \dots, q_m \rangle$ ，输出 start/end indices。局限要写清楚：只适合 extractive continuous span，不擅长多跳推理、多个不连续证据、摘要式答案、答案不在 context 中或需要自由生成的 non-factoid 问题。

6. BiDAF: pre-BERT 时代的专用阅读机器



Seo et al. (2016) Bi-Directional Attention Flow

Alexandra Birch

ATNLP Week 2 / Lecture 4

School of
informatics

21

原 PPT 第 21 页

人话直觉


BiDAF 像一台为阅读理解专门组装的机器：先把词和字符编码好，再让上下文和问题互相“看”对方，最后经过 LSTM 建模输出答案边界。它很聪明，但也很工程化——为了做好一个任务，需要设计许多专门模块。

精确定义 / 机制： BiDAF 即 Bi-Directional Attention Flow，是早期 neural reading comprehension 的代表。结构包括 character/word embedding layer、contextual embedding layer、attention flow layer、modeling layer 和 output layer。attention flow 的关键是双向：context-to-query attention 让每个 context token 找到 question 中相关信息；query-to-context attention 帮助模型识别 context 中哪些位置对整个任务最重要。它约 2.5M 参数，使用多个 BiLSTM，除 GloVe 等词向量外基本从任务数据训练，体现了 pre-BERT 时代依赖任务专用架构工程的风格。

考试问法： 如果考 BiDAF，不需要逐层画得很复杂，但要抓住关键词：Bi-Directional Attention Flow、context-to-query、query-to-context、BiLSTM、start/end span。若和 BERT 对比，BiDAF 是 task-specific architecture；BERT 是大规模预训练表示加少量 QA fine-tuning。

7. BERT-based QA: 从架构工程转向预训练加微调

BERT-based Models



Devlin et al. (2019) BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, ACL

Alexandra Birch

ATNLP Week 2 / Lecture 4

School of Informatics

22

原 PPT 第 22 页

人话直觉


BERT 出现后，阅读理解的路线变了：以前像给每门考试都造一台专用答题机器；BERT 像先培养一个语言基础很强的学生，再给他几张 QA 题型训练。slide 22 的关键不是图有多复杂，而是 pre-training 的语言知识被带到 fine-tuning 的 QA 任务里。

精确定义 / 机制： BERT 是 Transformer encoder，没有 recurrence，BERT-large 约 340M 参数。预训练阶段包括 Masked LM 和 NSP；QA fine-tuning 阶段把 question 和 paragraph 拼接，用 [SEP] 分隔，并在输出层预测 answer start/end span。与 BiDAF 相比，BERT 不需要大量任务专用结构：同一个预训练模型参数可初始化不同下游任务，fine-tuning 时所有参数都可调整。slide 23 的对比显示，BERT-large 在 SQuAD 上达到约 85.1 EM 和 91.8 F1，接近或超过 human performance，而 BiDAF F1 约 85.8。

考试问法： 如果考 BiDAF vs BERT，要答训练范式和架构差异：BiDAF 依赖 GloVe、BiLSTM、attention flow 和任务数据；BERT 依赖大规模预训练 Transformer，再用 question-paragraph pair fine-tune start/end output。还要补一句：SQuAD 上高分不等于真实 QA 已解决。

8. Open-Domain QA: 从开卷阅读题到自己找书

Open Domain QA



- **Open-Domain Question Answering (ODQA):** Not given one small passage
- We can access a large collection of documents (e.g., Wikipedia) — we don't know which document contains the answer, and the goal is to answer any open-domain questions.
- Both more challenging and more practical/useful!

原 PPT 第 28 页

人话直觉

Reading Comprehension 是老师把文章递给你；Open-Domain QA 是老师只问问题，然后让你自己去整座图书馆找资料。难点立刻翻倍：第一步要找对证据，第二步才是读懂证据。retriever 如果没找回含答案的 passage，reader 再聪明也只能空转。


精确定义 / 机制： Open-Domain Question Answering 不给系统一个小 passage，而是允许访问大型 document collection，如 Wikipedia。系统不知道哪个 document 包含答案，目标是回答广泛主题的开放域问题。典型 pipeline 是 retriever-reader: retriever 从非结构化文档集合中找 top-k relevant passages, reader 或 generator 再基于这些 passages 输出答案。Dense Passage Retrieval 则把 question 和 passage/document 编码成 dense vectors, 用 dot product 计算相似度, 并通过 approximate nearest neighbours 找 top-k。相比 closed-book LLM, retrieval from trusted knowledge source 能提高可更新性、可追溯性, 并降低纯参数记忆过时或 hallucination 的风险。

$$\text{sim}(Q, P) = \mathbf{q}^T \mathbf{p}, \quad \text{Retriever}(\mathcal{D}, Q) \rightarrow \{P_1, \dots, P_k\}$$

考试问法： 如果问 Reading Comprehension 和 ODQA 区别, 核心句是: RC 给定 passage, ODQA 要先从大库检索 passage。若问 ODQA 为什么更难, 写 retriever failure 和 reader failure 两类错误; 若问 dense retrieval, 写 neural vectors、dot product、top-k、ANN, 以及相对 sparse retrieval 的语义匹配优势。

9. FiD: 把多段证据交给 decoder 融合

Fusion in Decoder



- Combined advantages of extractive reading comprehension models, with advantages of generative QA systems like T5 which relied only on parameters: retrieve and generate!
- Question+Passage are processed independently in the encoder (T5 model) with added tokens "question:", "title:", "context:"
- Decoder attends over the concatenation of all retrieved passages: fusion in the decoder.
- Can better aggregate evidence from multiple passages

Izcard and Grave (2021). Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering, EACL

Alexandra Birch

ATNLP Week 2 / Lecture 4

School of Informatics

33

原 PPT 第 33 页

人话直觉

FiD 的名字很形象：fusion 不发生在一开始，而发生在 decoder。你可以把它想成多个助教各自读一篇相关 passage，把笔记交给同一个答题人；答题人写答案时同时看所有笔记，决定哪些证据该合并、哪些该忽略。

精确定义 / 机制：Fusion-in-Decoder 是一种 open-domain generative QA 方法。它先把 question 分别与每个 retrieved passage 拼接，形成多个 question-passage inputs；encoder 独立处理每个 pair，避免过早把很多 passage 混成一团；decoder 对所有 retrieved passages 的 concatenated representations 做 attention，并生成最终 answer。它结合了 extractive reading comprehension 的证据 grounding 思想和 T5 等 generative models 的生成能力，能从多个 passage 聚合信息，是现代 RAG 和多证据生成式 QA 的重要基础。Natural Questions 等真实搜索数据集进一步推动了这种方向，因为真实问题来自 Google queries，面对完整 Wikipedia 页面、歧义、无答案、long answer 与 short answer，而不是 SQuAD 那种干净短 passage。

考试问法：如果考 FiD，标准答法是：retrieve multiple passages；encode each question-passage pair independently；decoder attends over concatenated encoded representations；generate answer。若问它为什么是 RAG 前身，答它明确结合 retrieval 和 generation，并展示了 decoder 端多证据融合对 ODQA 的价值。

考试速记版

- QA 是让系统回答自然语言问题的任务，类型包括 factoid/non-factoid、open/closed、simple/compositional、natural/cloze-style。
- QA 是语言理解 test bed，因为它同时要求理解问题、理解文本或知识源，并把二者对齐产生答案。
- Reading Comprehension 给定 passage P 和 question Q，输出 answer A；extractive QA 的答案必须是原文 span。
- SQuAD 提供大规模 Wikipedia passage-question-answer triples，推动 neural RC，但设置干净、短 passage、span-based、缺少真实检索和无答案。

- EM 要完全匹配; F1 看 token overlap; 多个 valid answers 时通常取最高分; 二者都不能完美判断语义正确性。
- Neural extractive RC 常输出 start/end indices, 满足 $1 \leq \text{start} \leq \text{end} \leq n$ 。
- BiDAF 是 task-specific RC 架构, 核心是 context-to-query 与 query-to-context attention flow。
- BERT-based QA 用预训练 Transformer, 把 question 和 paragraph 拼接后 fine-tune 预测 start/end span。
- BERT 在 SQuAD 上接近或超过人类表现, 但这不等于真实 QA 被解决。
- Open-Domain QA 不给定 passage, 需先从大型文档集合检索证据, 再由 reader/generator 回答。
- Dense retrieval 把 question 和 passage 编码为向量, 用 dot product/cosine 找 top-k, 并常用 ANN 加速。
- Natural Questions 更真实: 真实 Google queries、完整 Wikipedia 页面、歧义、无答案、long/short answers。
- Fusion-in-Decoder 将多个 question-passage pairs 独立编码, 在 decoder 中融合证据生成答案。
- 现代 RAG 的核心思想已经在 ODQA 中出现: 先检索可信证据, 再基于证据回答。

一段稳妥考场回答

Question Answering 是构建能够回答人类自然语言问题的系统。它之所以是 NLP 的重要 test bed, 是因为系统必须理解问题、理解文本或知识源, 并把问题与证据对齐后产生答案。早期核心设置是 Reading Comprehension: 给定 paragraph P 和 question Q, 输出 answer A; 在 extractive QA 中, 答案必须是 passage 中的连续 span, 因此神经模型常把任务建模为预测 answer start 和 end indices。SQuAD 用大量 Wikipedia passage-question-answer triples 推动了 neural RC, 并用 Exact Match 和 token-level F1 评价答案, 但它的局限是 passage 已给定、答案通常是短 span, 缺少真实检索、歧义和无答案问题。BiDAF 代表 pre-BERT 时代的任务专用架构, 通过 context-to-query 和 query-to-context attention 预测 span; BERT-based QA 则用大规模预训练 Transformer, 再把 question 和 paragraph 拼接 fine-tune start/end 输出, 在 SQuAD 上接近或超过人类表现。Open-Domain QA 进一步放宽设置: 系统不再得到正确 passage, 而要先从 Wikipedia 等大型文档集合中检索 top-k evidence, 再由 reader 或 generator 回答, 因此错误可能来自 retriever 没找到证据或 reader/generator 理解错误。Natural Questions 用真实 Google queries 和完整 Wikipedia 页面展示了真实 QA 的噪声、歧义、长答案和不可回答问题。Fusion-in-Decoder 则把多个 retrieved passages 分别编码, 并让 decoder 融合所有证据生成答案, 是现代 retrieval-augmented QA/RAG 的重要前身。