


Alexandra Birch

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Data

预训练数据来源 → 数据选择目标 → Language Filtering → Heuristic Filtering → Data Quality → Deduplication 与 MinHash

这节课一句话

这节课围绕“为什么说 data is the key？”：因为模型只能从训练数据中学习知识、语言模式、推理模式和偏差；数据的质量、覆盖面和筛选方式直接决定模型能力。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Outline

- Overview
- Pre-training Data Sources
- Pre-training Data Selection
- Post-training Data
- Data Ethics and Law
- Summary

Readings: Albalak et al. (2024) [A Survey on Data Selection for Language Models](#), TML. (Section 2 and 3)
Penedo et al. (2024) [The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale](#), NeurIPS

Alexandra Birch ATNLP Week 2/ Lecture 5  2

原 PPT : Outline

Data is the key

Data determines capabilities

- Model learns only what's in the training data (knowledge, reasoning patterns, biases)

Data quality requires human effort

- Most resource intensive and valuable component of modern AI
- Requires sustained investment into human expertise and careful curation
- Long tail of problems: domains, edge cases, quality issues

Competitive Differentiator

- Proprietary datasets (GPT-4, Claude) provide performance edge
- Architectural innovations shared in papers, system engineering can be reverse-engineered – datasets give sustained advantage
- Reasons for secrecy: (i) competitive dynamics and (ii) copyright liability

Alexandra Birch ATNLP Week 2/ Lecture 5  3

原 PPT : Data is the key

Types of Data

Pre-training data – on raw text

Annealing or mid-training – more focus on particular capabilities, higher quality data

Post-training – focus on evaluation tasks, desired behaviour
consist of: instruction training, RL, alignment, task fine-tuning

Terminology:

Base model: after pre-training + annealing

Instruct model: after post-training

Each task has own data: translation, long context, reasoning etc. which we will look at in future lectures

原 PPT : Types of Data

2. 先抓住核心

这节课怎么入脑

这节课围绕“为什么说 data is the key？”：因为模型只能从训练数据中学习知识、语言模式、推理模式和偏差；数据的质量、覆盖面和筛选方式直接决定模型能力。

考点问法：为什么说 data is the key？

人话版：因为模型只能从训练数据中学习知识、语言模式、推理模式和偏差；数据的质量、覆盖面和筛选方式直接决定模型能力。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：数据为什么是现代 AI 的竞争优势？

人话版：模型架构和工程细节容易被论文和系统复现，但高质量、专有、持续维护的数据集更难获得，因此能带来长期性能优势。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么大型模型的数据集常常不公开？

人话版：主要原因是竞争优势和版权责任：公开数据来源可能削弱商业壁垒，也可能暴露版权风险。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：训练 LLM 的数据大致分为哪几类？

人话版：主要包括 pre-training data、annealing 或 mid-training data，以及 post-training data。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：什么是 pre-training data？

人话版：Pre-training data 是用于训练 base model 的大规模原始文本或代码数据，目标是让模型学习通用语言、知识和模式。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. 预训练数据来源



原 PPT : Pre-training Data Sources

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“Wikipedia 为什么常被用于 LLM 训练？”。考试版答案可以先说：因为它质量较高、结构清晰、多语言覆盖广、许可证较开放，并且有丰富元数据。进一步看，优点包括社区维护、质量控制机制、300 多种语言覆盖、Creative Commons license 和较高知识密度。

- 考点问法：Wikipedia 为什么常被用于 LLM 训练？。答题抓手：因为它质量较高、结构清晰、多语言覆盖广、许可证较开放，并且有丰富元数据。
- 考点问法：Wikipedia 有哪些优点？。答题抓手：优点包括社区维护、质量控制机制、300 多种语言覆盖、Creative Commons license 和较高知识密度。
- 考点问法：Wikipedia 有哪些局限？。答题抓手：它存在地理和人口统计偏差，例如女性编辑比例较低，某些地区和群体代表性不足。

4. 数据选择目标

Wikipedia

- High quality, structured data
- Large community of **15 million writers**
 - 13 editors: more than 1 million edits!
- Sophisticated mechanism for quality standards even across very controversial pages
- Multilingual coverage – over 300 languages
- Free and accessible – creative commons license
- Rich Metadata
- Limitations: geographic and demographic biases – only 8-15% are women

Used in training **almost all LLMs** alongside other larger, more diverse corpora

#WikipediaYearInReview



Wikipedia logo

Most read articles on English Wikipedia

1. Charlie Kirk
2. Deaths in 2025
3. Ed Gein
4. Donald Trump
5. Pope Leo XIV

Hours spent reading 2,376,813,343

Changes editors made **79 million**

Alexandra Birch

ATNLP Week 2/ Lecture 5

School of informatics

6

原 PPT : Wikipedia

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“data selection 的总体目标是什么？”。考试版答案可以先说：选择最适合训练目标的数据，同时提高性能、减少成本、保证评价完整性，并减少有害行为。进一步看，Optimal dataset 是尽可能接近模型测试或部署时分布的数据集。

- 考点问法：data selection 的总体目标是什么？。答题抓手：选择最适合训练目标的数据，同时提高性能、减少成本、保证评价完整性，并减少有害行为。
- 考点问法：什么是 optimal dataset？。答题抓手：Optimal dataset 是尽可能接近模型测试或部署时分布的数据集。
- 考点问法：为什么 data selection 能降低成本？。答题抓手：通过去掉低质量、重复、无关或有害数据，可以减少训练 tokens、计算资源和存储成本。

5. Language Filtering

Web Data

- The biggest and most freely available data source is the web
- How big is it? **HUGE**
 - Google search indexes about **400 billion web pages**
- Actual web far larger in the deep web – can be just institutional data that is behind a login eg. Amazon, but also dark web with deliberately encrypted data
- Spans a broad range of **domains, genres, languages** – world knowledge and linguistic knowledge that LLMs need
- Broad but not universal – overrepresents younger users and developed countries especially USA

<https://zyppy.com/seo/google-index-size/>

Alexandra Birch

ATNLP Week 2/ Lecture 5

School of
informatics

8

原 PPT : Web Data

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“为什么需要 language filtering？”。

考试版答案可以先说：因为训练者可能希望控制语言比例、聚焦某些语言，或过滤掉不符合目标语言的数据。

进一步看，多语言数据质量更难保证、筛选成本更高，而且不同语言在数据量和质量上差异很大。

- 考点问法：为什么需要 language filtering？。答题抓手：因为训练者可能希望控制语言比例、聚焦某些语言，或过滤掉不符合目标语言的数据。
- 考点问法：为什么不总是直接做 multilingual training？。答题抓手：多语言数据质量更难保证、筛选成本更高，而且不同语言在数据量和质量上差异很大。
- 考点问法：URL-based language filtering 是什么？。答题抓手：通过域名或 URL 线索判断语言，例如 .fr 可能对应法语、.es 可能对应西班牙语。

6. Heuristic Filtering

Common Crawl

- Non-profit organization started in 2007
- **Mission:** To provide open and free access to web data, a resource that was once primarily available only to large corporations like Google.
- **Data Size:** The corpus contains petabytes of data, with **monthly** crawls adding billions of new pages.
- **Accessibility:** The data is hosted on Amazon Web Services and is freely available for anyone to use and analyze.
- **Coverage strategy:** Crawls contain some overlap but deliberately diversify content capture
- **Scale of crawls:** in 2016 crawling took 12 days on a cluster of 100 machines

From groups.google.com

Alexandra Birch

ATNLP Week 2/ Lecture 5

School of
informatics

9

原 PPT : Common Crawl

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“heuristic filtering 的目标是什么？”。考试版答案可以先说：快速去除 boilerplate、错误信息、重复片段、乱码、低质量格式和明显不适合训练的文本。进一步看，预训练语料规模极大，过滤函数需要能在海量文档上低成本运行。

- 考点问法：heuristic filtering 的目标是什么？。答题抓手：快速去除 boilerplate、错误信息、重复片段、乱码、低质量格式和明显不适合训练的文本。
- 考点问法：heuristic filtering 为什么必须快？。答题抓手：预训练语料规模极大，过滤函数需要能在海量文档上低成本运行。
- 考点问法：heuristic filtering 的局限是什么？。答题抓手：它只能看表面统计，不能真正判断文档内容是否有深度或教育价值。

7. Data Quality

GitHub

- Code is essential for programming tasks, but also helps develop reasoning behaviour
- GitHub started in 2008, acquired by Microsoft in 2018
- It contains a massive number of repositories: [630M](#) projects
- It has valuable metadata: stars, project maturity and activity, issues and pull requests
- License information - enables filtering for permissively-licensed code only

The Stack dataset **31TB of data** across **30 programming languages** of permissively licensed code

- A tool called "Am I in The Stack" for developers to search for copies of their code
- MIT, Apache, BSD

Kocetkov et al. (2023) [The stack: 3 TB of permissively licensed source code](#)

Alexandra Birch

ATNLP Week 2/ Lecture 5

School of Informatics

11


原 PPT : GitHub

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“数据质量为什么难以定义？”。考试版答案可以先说：因为“高质量”最终取决于训练后模型在什么测试集或应用场景上表现更好。进一步看，Wikipedia、books、patents 和 peer-reviewed journal articles。

- 考点问法：数据质量为什么难以定义？。答题抓手：因为“高质量”最终取决于训练后模型在什么测试集或应用场景上表现更好。
- 考点问法：讲义中给出的高质量数据例子有哪些？。答题抓手：Wikipedia、books、patents 和 peer-reviewed journal articles。
- 考点问法：classifier-based quality filtering 是什么？。答题抓手：训练一个分类器判断数据点是否接近某个已知高质量参考语料的分布。

8. Deduplication 与 MinHash



原 PPT : Data Selection Criteria

人话直觉

把数据想成模型的食材：高资源语言像供应充足的大厨房，低资源语言常常只有少量、噪声更大的食材，所以数据比例和清洗会直接改变模型口味。这部分的核心问题是“deduplication 是什么？”。考试版答案可以先说：Deduplication 是去除训练语料中的重复或近重复文档。进一步看，它能减少数据规模和训练成本，提高泛化，并降低模型记忆低质量重复内容的风险。

- 考点问法：deduplication 是什么？。答题抓手：Deduplication 是去除训练语料中的重复或近重复文档。
- 考点问法：为什么预训练数据需要 deduplication？。答题抓手：它能减少数据规模和训练成本，提高泛化，并降低模型记忆低质量重复内容的风险。
- 考点问法：exact matching deduplication 是什么？。答题抓手：它通过完全相同的内容或 URL 来删除重复文档。

考试速记版

- 为什么说 data is the key? : 因为模型只能从训练数据中学习知识、语言模式、推理模式和偏差; 数据的质量、覆盖面和筛选方式直接决定模型能力。
- 数据为什么是现代 AI 的竞争优势? : 模型架构和工程细节容易被论文和系统复现, 但高质量、专有、持续维护的数据集更难获得, 因此能带来长期性能优势。
- 为什么大型模型的数据集常常不公开? : 主要原因是竞争优势和版权责任: 公开数据来源可能削弱商业壁垒, 也可能暴露版权风险。
- 训练 LLM 的数据大致分为哪几类? : 主要包括 pre-training data、annealing 或 mid-training data, 以及 post-training data。
- 什么是 pre-training data? : Pre-training data 是用于训练 base model 的大规模原始文本或代码数据, 目标是让模型学习通用语言、知识和模式。
- 什么是 annealing 或 mid-training? : 它是在预训练后期使用更高质量或更面向特定能力的数据继续训练, 以强化某些能力。
- 什么是 post-training data? : Post-training data 用于让模型学习期望行为, 包括 instruction training、RL、alignment 和 task fine-tuning。
- base model 和 instruct model 的区别是什么? : Base model 是预训练和 mid-training 后的模型; instruct model 是进一步经过 post-training 后, 更会遵循人类指令的模型。
- 数据质量为什么需要大量人工努力? : 因为高质量数据需要专家判断、持续清洗、领域覆盖、边界案例处理和人工制定筛选标准。
- 数据问题中的 long tail 指什么? : 指大量低频但重要的问题, 例如少数领域、边缘案例、低资源语言、罕见格式和质量异常。

一段稳妥考场回答

为什么说 data is the key? : 因为模型只能从训练数据中学习知识、语言模式、推理模式和偏差; 数据的质量、覆盖面和筛选方式直接决定模型能力。数据为什么是现代 AI 的竞争优势? : 模型架构和工程细节容易被论文和系统复现, 但高质量、专有、持续维护的数据集更难获得, 因此能带来长期性能优势。为什么大型模型的数据集常常不公开? : 主要原因是竞争优势和版权责任: 公开数据来源可能削弱商业壁垒, 也可能暴露版权风险。训练 LLM 的数据大致分为哪几类? : 主要包括 pre-training data、annealing 或 mid-training data, 以及 post-training data。