

Evaluation

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

开场困境：传统程序有清晰 oracle，LLM 开放回答常常 plausible 但难以证伪 → 评价目标：比较系统、检验改动、判断是否适合具体 use case → 评价框架：answer type、ground truth、metric、prompt formulation、deployment criteria 一起决定评价设计 → Intrinsic evaluation：perplexity 衡量语言建模困惑度，但不是事实性、推理或 alignment 的通行证 → Task-based benchmarks：MMLU、MMLU-Pro、GPQA 等用标准化任务切开不同能力维度 → Saturation：旧 benchmark 被模型追平后失去区分力，需要更难、动态或私有的评测 → Open-ended generation：没有唯一答案时，评价转向 rubrics、偏好比较和真实使用数据 → LM Arena 与 Elo：用人类 pairwise preference 聚合开放式回答的相对好坏 → LLM-as-a-Judge：用模型降低评价成本，但必须警惕位置偏差、流畅性偏好和 self-referential bias → Contamination：测试题进入训练数据后，evaluation 会从泛化测试变成记忆表演 → 最终原则：没有 one true evaluation，必须看 individual instances，并用 helpfulness、safety、reasoning、factuality、style、cost 多维评分

Testing is crucial

Suppose I give you a **prompt**: “What caused the decline of civic trust in modern democracies?”

Response: “The decline of civic trust stems from a combination of economic inequality, media fragmentation, political polarization, and perceived institutional failure.”

How would you decide if the implementation is correct?

- Claims are plausible but not falsifiable in isolation.
- Missing citations, but still sounds authoritative.
- The list could be endless - why these factors?
- Is this insightful synthesis or generic hand-waving?

这节课一句话

Evaluation 不是给模型贴一个漂亮分数，而是先问“我要证明它在什么使用场景里真的更好、更可靠、更值得部署”，再选择能对齐目标、风险、答案形式和失败模式的多维证据。

1. 为什么 LLM 评价比测 Fibonacci 难：答案会“像真的”

Testing is crucial

Suppose I give you a **prompt**: “What caused the decline of civic trust in modern democracies?”

Response: “The decline of civic trust stems from a combination of economic inequality, media fragmentation, political polarization, and perceived institutional failure.”

How would you decide if the implementation is correct?

- Claims are plausible but not falsifiable in isolation.
- Missing citations, but still sounds authoritative.
- The list could be endless - why these factors?
- Is this insightful synthesis or generic hand-waving?

Alexandra Birch

ATNLP Week 2 / Lecture 7

School of
informatics

6

原 PPT 第 6 页

人话直觉

测 Fibonacci 程序像查计算器：第 10 项是多少，错了就是错了。测 LLM 更像听一个很会说话的人做时评：语气自信、结构完整、关键词都在，但你仍然要追问——这些因果真的成立吗？为什么只列这几个因素？有没有证据？是不是一段漂亮的空话？

精确定义 / 机制：讲义前几页故意从 Fibonacci、Python interpreter、speech recognizer、self-driving car 一路升级到 LLM prompt，是为了说明 evaluation 的 oracle 越来越不清楚。传统程序往往有明确 input-output specification；LLM 的开放式回答则常常没有唯一 ground truth，而且质量维度混在一起：事实性、完整性、推理深度、风格、引用、原创性、风险。slide 6 的 civic trust 例子尤其关键：回答“经济不平等、媒体碎片化、政治极化、制度失败”听起来合理，但 plausible 不等于 correct，也不等于 insightful。Evaluation 因此不是问“模型有没有输出一句顺耳的话”，而是设计证据来判断它是否满足任务目标。

考试问法：如果考“为什么评价 LLM 很难”，不要只写“因为没有答案”。高分答案要说：开放式输出常无唯一 ground truth；评价标准主观且多维；prompt 和上下文会改变表现；流畅性会掩盖事实错误；部署风险不同导致同一回答在不同场景下可接受性不同。

2. Evaluation Frameworks: 先选尺子，再量模型

Evaluation Frameworks

- 1) Answer type: Multiple choice, short answer, long answer
- 2) Ground truth or no ground truth
- 3) Metric: accuracy, precision @5, BLEU, LLM as judge
- 4) Formulation: prompt, in-context examples, chain-of-thought
- 5) Deployment criteria: how critical is the task?

人话直觉

评价就像体检，不是拿一根体温计测所有病。你要先知道病人是跑马拉松、做手术还是只是感冒复查；模型也是一样，聊天娱乐、医学建议、代码代理和自动驾驶不可能用同一把尺子。

精确定义 / 机制： slide 7 给出 evaluation 的三个目标：比较两个或多个系统；判断新方法、数据或训练是否带来预期改进；判断系统是否适合某个 use case。slide 8 把这些目标落成五个设计维度。Answer type 决定评分难度：multiple choice 容易自动判分，short answer 可用 exact match/F1，long answer 往往要 human 或 LLM judge。Ground truth 决定能否用 accuracy、precision@5、BLEU 等自动指标；没有 ground truth 时就需要 rubric、pairwise preference 或 judge。Metric 决定模型被奖励什么行为，错 metric 会把系统推向错目标。Prompt formulation 包括 zero-shot、few-shot、chain-of-thought 等，会显著改变分数。Deployment criteria 则把风险带进评价：安全关键任务不能只看排行榜平均分。

考试问法：如果考“如何设计 evaluation”，按五步答最稳：确定 answer type；判断是否有 ground truth；选择 metric；固定或比较 prompt formulation；根据 deployment criticality 设置通过标准。最后补一句：不同目标会转化成不同评价，没有 one true evaluation。

3. Perplexity: 语言模型的困惑度，不是万能能力证书

Perplexity

Perplexity is a **standard metric** used to evaluate language models

Perplexity is the average number of choices the model thinks it has at each word:

Perplexity = 1 → the model is perfectly certain

Perplexity = 10 → the model feels like there are ~10 equally likely next words

Higher perplexity → more confusion

Good for:

- Standard metric for measuring language modelling quality
- Comparing models on the same dataset
- Tracking training progress
- Detecting overfitting (train vs validation perplexity)

Alexandra Birch

ATNLP Week 2 / Lecture 7

School of
informatics

10

原 PPT 第 10 页

人话直觉

Perplexity 像让模型每走一步猜下一个词时的“犹豫指数”。Perplexity=1 就像模型说“我百分百知道下一个词”；perplexity=10 就像它觉得桌上平均有 10 个差不多可能的候选词。犹豫少通常说明语言建模更顺，但不说明它真的懂世界。

精确定义 / 机制：Perplexity 是 intrinsic evaluation：它直接评价语言模型对文本分布的预测能力，而不是某个下游应用。它适合在同一数据集、同一 tokenization 条件下比较语言建模质量，也适合跟踪训练进度和检测 train/validation overfitting。直觉上，perplexity 是模型在每个词位置平均认为有多少个选择；越低表示模型对真实下一个 token 分配的概率越高。关键 caveat 来自 slide 11: lower perplexity does not necessarily mean a better model。模型可能通过记忆常见模式降低困惑度，却仍然事实错误、缺乏长程连贯、不会推理，或不符合用户意图。


$$\text{PPL}(x_{1:T}) = \exp\left(-\frac{1}{T} \sum_{t=1}^T \log p(x_t | x_{<t})\right)$$

考试问法：考“perplexity 的优缺点”时，优点写 standard、cheap、适合同数据集比较、追踪训练和 overfitting；缺点写不能可靠衡量 factuality、reasoning、alignment、long-range coherence，也不能跨数据集或 tokenization 随便横比。

4. Cloze 与 Benchmarks: 从补词能力走向多维能力表格

MMLU-Pro

- MMLU-Pro has 10 options vs. 4 for MMLU
- More challenging college-level exam problems requiring reasoning
- Two rounds of expert reviews to reduce the noise Round 1: expert verification Round 2: SoTA LLMs to identify potential errors and annotators to perform more targeted verification.



Wang et al. (2024) [MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark](#)

原 PPT 第 17 页

人话直觉

Cloze task 像在小说里挖掉最后一个关键词，让模型凭前文补回来；MMLU、GPQA 这类 benchmark 则像综合考试，把医学、物理、经济、数学、代码、事实性和推理分开出题。前者看语言分布的敏感度，后者看能力地图。

精确定义 / 机制： LAMBADA 这类 cloze task 要求模型利用较宽的 discourse context 预测目标词，因此和 perplexity 测量相近的语言建模能力：perplexity 是连续概率，cloze 是离散对错。但 foundation models 需要 task-based benchmarks，因为真实能力不是一条线。Gemma 3 报告页展示 MMLU-Pro、LiveCodeBench、Bird-SQL、GPQA、SimpleQA、MATH、MMMUS 等多任务表格，说明现代评价必须 multidimensional。MMLU 测世界知识、问题解决和 57 subjects；MMLU-Pro 在 slide 17 中把选项从 4 个增到 10 个、加入更难 college-level reasoning、通过两轮专家/模型辅助复核减少噪声，并降低 prompt sensitivity；GPQA 则用专家级、Google-proof 的题目测试深专业知识和推理。

考试问法：如果考“为什么 foundation model 需要 multidimensional benchmark”，答：单一分数会掩盖能力差异；模型可能数学强但事实弱，代码强但安全差。若比较 MMLU 与 MMLU-Pro，要点是 MMLU-Pro 更难、选项更多、专家降噪、prompt sensitivity 更低、更强调 reasoning。


5. Saturation 与 HLE: 旧卷子考不出差距, 就会变成排行榜噪音

Humanity's Last Exam

Solutions to saturation:

- Subject-matter experts at frontier of human knowledge
- Multiple choice/short answer – automatic grading
- More challenging multimodal Qs
- Filter questions over multiple stages of review

HLE combines these approaches



Phan et al. (2025) [Humanity's Last Exam](#)

Alexandra Birch

ATNLP Week 2 / Lecture 7

School of
informatics

20

原 PPT 第 20 页

人话直觉

Benchmark saturation 就像全班都把同一套模拟卷刷到 98 分: 成绩单看起来辉煌, 但老师已经分不出谁真的会迁移、谁只是熟悉题型。继续盯着这张卷子, 只会把进步幻觉包装成科学数字。

精确定义 / 机制: Saturation 指模型在某个 benchmark 上接近满分或人类 baseline, 导致该 benchmark 失去区分力和诊断价值。AI Index 页用趋势图提醒我们, 许多经典任务已经被快速追平。Humanity's Last Exam 是一个反 saturation 的设计例子: 邀请 subject-matter experts 在人类知识前沿出题, 采用 multiple choice/short answer 方便自动评分, 加入更难的 multimodal questions, 并通过多阶段 review 过滤问题。slide 22 又给出 caveat: HLE 可能是“最后一次学术考试”的说法要谨慎, 因为它主要测 structured academic problems, 不测开放式、创造性或交互式问题解决, 而且任何固定公开 benchmark 最终都可能再次 saturate。

考试问法: 考“benchmark saturation 是什么、怎么解决”时, 先定义: 分数接近上限导致区分力下降。解决方案写更难专家题、动态/私有 held-out tests、多维评价、真实使用评价。一定要补 caveat: 更难的封闭题不能替代 open-ended generation 和 deployment-specific evaluation。

6. Open-ended Generation: 没有唯一答案时，评价变成判断品味与目标

Open-ended questions

Prompt: "Write a short poem about grief that avoids clichés."

Response:

"The house forgets your weight—
doors close too quickly now.
Dust settles where your voice
used to interrupt the light."

- Very often no ground truth or no single ground truth (Might be one for tasks translation/summarization)
- No clear rubric for success
- Instructions are subjective eg. "Avoids clichés"
- Even human evaluators may disagree on Originality, Emotional depth

Alexandra Birch

ATNLP Week 2 / Lecture 7

School of
informatics

24

原 PPT 第 24 页

人话直觉

让模型写一首避免陈词滥调的悲伤短诗，不像问 2+2。有人喜欢克制，有人喜欢强烈；有人看重意象，有人看重情感真实。这里的难点不是“没有答案”，而是“好答案可以有很多种”。

精确定义 / 机制：开放式生成评价的核心问题是 no ground truth or no single ground truth。翻译和摘要有时有 reference，但也存在多个合理表达；诗歌、创意写作、建议、分析、长上下文助手回答更是没有唯一标准。slide 24 中 originality、emotional depth、cliché avoidance 都是主观维度，人类评价者也可能分歧。slide 25 的真实使用分析进一步说明，用户和助手的实际交互大量是写作、代码、分析、创意和个人化任务，并不等同于 MCQ 或 accuracy-style benchmark。因此开放式评价更常依赖 rubrics、human preference、pairwise comparison、LLM judge，以及从真实使用中反推评价任务。

考试问法：如果考“为什么 open-ended generation 难评价”，写四点：无唯一 ground truth；rubric 主观；人类评价者分歧；真实任务多目标且上下文相关。可补充：因此需要 preference evaluation 或 rubric-based judgement，而不是只用 accuracy。

7. LM Arena 与 Elo: 把人类偏好变成动态排行榜

ELO

All models start at the same rating (e.g. 1000)
For Model A vs Model B

- R^A and R^B are current ELO rankings
- O_A is outcome for A (1 win, 0.5 tie, 0 loss)
- K is update rate

A's expected win probability:

$$E_A = \frac{1}{1 + 10^{(R^B - R^A)/400}}$$

Update:

$$R^{A'} = R^A + K(O_A - E_A)$$

Intuition

Beating a strong opponent $\rightarrow$ big gain
Losing to a weak opponent $\rightarrow$ big loss
Expected outcomes $\rightarrow$ small change

原 PPT 第 27 页

人话直觉

LM Arena 像让两个匿名模型同台答题，观众只投“左边好、右边好、平局”。Elo 的聪明之处是：赢弱者不值得大吹，赢强者才说明你可能真的被低估；输给弱者则说明你的旧分数可能虚高。

精确定义 / 机制：LM Arena 是开放、众包的大模型评价平台：用户向两个匿名模型发同一 prompt，并排看回答后选择哪个更好或 tie。它比固定 test set 更贴近真实开放式使用，因为 prompts 来自真实用户，评价对象也是完整回答体验。结果通常用 Elo-style rating 聚合。所有模型从相同 rating 开始，例如 1000；模型 A 对模型 B 的 expected win probability 由当前 rating 差决定；实际 outcome O_A 可以是 1、0.5、0。更新时，如果实际结果比预期好，A 上升；比预期差，A 下降。Arena 适合 general-purpose alignment、instruction-following、user-facing preferences，也方便持续加入新模型；但它昂贵，受用户群体偏好影响，不适合单独承担 safety-critical decision making。

$$E_A = \frac{1}{1 + 10^{(R_B - R_A)/400}}, \quad R'_A = R_A + K(O_A - E_A)$$

考试问法：考“LM Arena 如何工作”时按流程答：两个匿名模型 side-by-side 回答同一 prompt；用户选择更好或 tie；用 Elo-style rating 聚合。若考 Elo，解释 O_A 、 E_A 、 K ，并写出“beating a strong opponent gives bigger gain; losing to a weak opponent gives bigger loss”。

8. LLM-as-a-Judge: 自动裁判能省力，也会带着自己的偏见

LLM as a Judge

- Two key advantages:
 - Scalability
 - Explainability

Zheng et al. (2023) [Judging LLM-as-a-Judge](#)

- Showed that LLM judgments correlate strongly with human judgments across multiple tasks.
- Established best practices for pairwise comparison, prompt design, and calibration eg. Need to randomize order as bias toward first answer

原 PPT 第 29 页

人话直觉

让强模型当裁判，就像请一个很快的助教批作业：它能批很多、还能写评语，特别适合先筛一大堆开放式答案。但如果助教偏爱长答案、流畅语气，或者偏爱和自己写作风格相似的学生，分数就会系统性歪掉。

精确定义 / 机制：LLM-as-a-Judge 的两大吸引力是 scalability 和 explainability：它可以低成本评价大量开放式回答，并给出选择理由，帮助分析模型优缺点。Zheng et al. (2023) 显示 LLM judgments 与 human judgments 在多个任务上有较强相关性，并建立了 pairwise comparison、prompt design、calibration 等实践。关键 best practice 是 randomize answer order，因为 judge 可能偏向第一个答案。slide 30 展示的问题也很典型：LLM judge 可能偏向更流畅、更长、更自信的回答，即使事实不完全正确；还可能有 self-referential bias，即偏好和自己风格或模型家族相似的输出；模型不像人类那样稳定表达不确定，也会 confident but wrong。

考试问法：考“LLM-as-a-Judge 的利弊”时，优点写 scalable、cheaper、explainable、适合大规模初筛和开放式比较；缺点写 prompt sensitivity、position bias、fluency/verbosity bias、self-referential bias、事实误判。结论：可辅助评价，但高风险场景必须用人类校准和验证。

9. Contamination: 当测试集混进训练，评价就不再评价泛化

Contamination

- Machine learning 101: do not train on your test set
- Pre-foundation models: well-defined train-test splits
- Nowadays: train on the internet – many benchmarks are on the internet
- Evaluation becomes memorization not reasoning – undermines real progress
- **Solution 1:** Model providers should report train-test overlap – need to trust self reporting and difficult to know fuzzy overlap
- **Solution 2:** Dynamic and private held out test sets

Zhang et al. (2025) [Language model developers should report train-test overlap](#)

Alexandra Birch

ATNLP Week 2 / Lecture 7

School of Informatics

31

原 PPT 第 31 页

人话直觉

机器学习第一课是不要把考卷给学生背。Foundation model 时代的问题是：学生不是偷看了一张卷子，而是读完整个互联网；而很多 benchmark 题目也正好挂在互联网上。

精确定义 / 机制： Benchmark contamination 指测试集或近似内容进入训练数据，使模型在评价中可能靠记忆而非泛化、推理或真实理解得分。Pre-foundation model 时代 train/test split 往往清晰；现在模型在互联网规模数据上训练，公开 benchmark、题解、讨论帖、排行榜分析都可能被吸入。这样 evaluation becomes memorization not reasoning，直接 undermines real progress。slide 31 给出两类方案：模型提供者报告 train-test overlap，但这依赖自报且 fuzzy overlap 难检测；使用 dynamic and private held-out test sets，降低测试题提前进入训练的概率。slide 32 还补充可从模型行为推断污染：比较 public/private benchmark 表现，做 prefix completion 测 memorization，或利用数据点 exchangeability。
考试问法：如果考“contamination 为什么危险、如何处理”，答：它夸大能力、破坏公平比较、加速 saturation，让测试变成记忆。解决写 train-test overlap reporting、dynamic/private held-out tests、public vs private performance comparison、prefix completion memorization tests。

考试速记版

- Evaluation 的三个目标：比较系统、检验改动、判断是否适合 use case。
- 评价框架五维：answer type、ground truth、metric、prompt formulation、deployment criteria。
- LLM 难评是因为开放式输出常无唯一答案，质量维度主观且多目标。
- Perplexity 是模型平均每步的困惑度；低 perplexity 不等于事实正确、推理强或 aligned。
- Cloze task 是离散补词；perplexity 是连续概率，二者都偏语言建模能力。
- Task-based benchmark 要多维看能力，不能只看平均分或单一 leaderboard。
- MMLU-Pro 比 MMLU 更难：10 个选项、专家复核、更复杂推理、更低 prompt sensitivity。
- GPQA 是专家级、Google-proof Q&A，用来测试深专业知识和推理。
- Saturation 是 benchmark 接近满分后失去区分力；HLE 用专家难题、多模态和多阶段过滤缓解。

- Open-ended generation 常没有单一 ground truth，因此依赖 rubrics、human preference 或 judge。
- LM Arena 用匿名 pairwise comparison 收集人类偏好，并用 Elo-style rating 聚合。
- Elo 更新看实际结果和预期胜率差：赢强者涨多，输弱者掉多。
- LLM-as-a-Judge 的优点是 scalable 和 explainable；缺点是位置偏差、流畅性偏好、自我偏好和事实误判。
- Contamination 让 evaluation 变成 memorization；可用 private/dynamic tests 和 overlap/memorization 检测缓解。
- 最终原则：没有 one true evaluation；要看 individual instances，并用 helpfulness、safety、reasoning、factuality、style、cost 多维评分。

一段稳妥考场回答

Evaluation 的核心不是给 LLM 找一个唯一总分，而是根据 use case 选择能测到目标能力和风险的证据。首先要明确评价目的：比较多个系统、判断某个改动是否有效，或决定系统是否适合部署；然后根据 answer type、是否有 ground truth、metric、prompt formulation 和 deployment criticality 设计评价。Intrinsic metrics 如 perplexity 可衡量语言建模困惑度，适合在同一数据集上比较训练进展，但不能可靠评价事实性、推理、alignment 或开放式质量。Task-based benchmarks 如 MMLU、MMLU-Pro、GPQA 能提供多维能力地图，但会受到题目噪声、prompt sensitivity、saturation 和 contamination 影响，因此不能只看排行榜平均分。开放式生成没有唯一答案，常需要 human preference、LM Arena 的 pairwise comparison 与 Elo 聚合，或 LLM-as-a-Judge 来降低成本；但 judge 也可能有位置偏差、流畅性偏好、自我偏好和事实误判。Foundation model 时代还必须警惕 test contamination，因为公开测试题进入训练数据会把评价变成记忆测试。高质量 evaluation 应该多维、场景对齐、包含逐例错误分析，并同时考虑 helpfulness、safety、reasoning、factuality、style 和 cost。