


Evaluation

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Evaluation

Evaluation Frameworks → Intrinsic Evaluation 与 Perplexity → Cloze Tasks → Task-based Benchmarks → Saturation 与 Humanity's Last Exam → Open-ended Generation Evaluation

这节课一句话

这节课围绕“为什么 evaluation 对 NLP 和 LLM 很关键？”：Evaluation 决定我们如何判断系统是否变好、是否适合部署，以及研究是否真的取得进展。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Testing is crucial

Suppose I give you a **prompt**: "What caused the decline of civic trust in modern democracies?"

Response: "The decline of civic trust stems from a combination of economic inequality, media fragmentation, political polarization, and perceived institutional failure."

How would you decide if the implementation is correct?

- Claims are plausible but not falsifiable in isolation.
- Missing citations, but still sounds authoritative.
- The list could be endless - why these factors?
- Is this insightful synthesis or generic hand-waving?

Alexandra Birch

ATNLP Week 2/ Lecture 7

School of
informatics

6

原 PPT : Testing is crucial

Purpose of Evaluation

Evaluation is profoundly difficult and critical for progress in the field!

Possible Goals:

- 1) Decide which of two (or more) systems is better to use
- 2) Evaluate incremental changes to systems
 - Does a new method/data/training make it better or worse?
 - Does it change things in the intended way?
- 3) Decide whether a system is appropriate for a given use case.

Each case might translate into different evaluations

Alexandra Birch

ATNLP Week 2/ Lecture 7

School of
informatics

7

原 PPT : Purpose of Evaluation

Evaluation Frameworks

- 1) Answer type: Multiple choice, short answer, long answer
- 2) Ground truth or no ground truth
- 3) Metric: accuracy, precision @5, BLEU, LLM as judge
- 4) Formulation: prompt, in-context examples, chain-of-thought
- 5) Deployment criteria: how critical is the task?

原 PPT : Evaluation Frameworks

2. 先抓住核心

这节课怎么入脑

这节课围绕“为什么 evaluation 对 NLP 和 LLM 很关键？”：Evaluation 决定我们如何判断系统是否变好、是否适合部署，以及研究是否真的取得进展。

考点问法：为什么 evaluation 对 NLP 和 LLM 很关键？

人话版：Evaluation 决定我们如何判断系统是否变好、是否适合部署，以及研究是否真的取得进展。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么评价 LLM 比评价传统程序更难？

人话版：传统程序常有明确正确答案；LLM 输出开放、主观、上下文相关，常常没有唯一 ground truth。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：evaluation 的三个常见目标是什么？

人话版：比较两个或多个系统、评估系统改动是否有效、判断系统是否适合某个 use case。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。


考点问法：为什么不同目标需要不同 evaluation？

人话版：因为“哪个系统整体更强”“某个改动是否有效”和“是否适合安全关键应用”衡量的风险和质量维度不同。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：评价框架需要考虑哪些维度？

人话版：答案类型、是否有 ground truth、使用什么 metric、prompt formulation，以及 deployment criteria。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Evaluation Frameworks



原 PPT : Intrinsic Evaluation

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“answer type 对评价有什么影响？”。考试版答案可以先说：Multiple choice 容易自动评分；short answer 可用 exact match 或 F1；long/open answer 通常需要人工或 LLM 判断。进一步看，有 ground truth 时可用 accuracy、F1 等自动指标；无 ground truth 时通常需要 rubrics、pairwise preference 或 judge。

- 考点问法：answer type 对评价有什么影响？。答题抓手：Multiple choice 容易自动评分；short answer 可用 exact match 或 F1；long/open answer 通常需要人工或 LLM 判断。
- 考点问法：有 ground truth 和无 ground truth 的评价有什么区别？。答题抓手：有 ground truth 时可用 accuracy、F1 等自动指标；无 ground truth 时通常需要 rubrics、pairwise preference 或 judge。
- 考点问法：metric 的选择为什么重要？。答题抓手：metric 决定模型被奖励什么行为，错误 metric 会推动模型优化错误目标。

4. Intrinsic Evaluation 与 Perpl

Perplexity

Perplexity is a **standard metric** used to evaluate language models

Perplexity is the average number of choices the model thinks it has at each word:

Perplexity = 1 → the model is perfectly certain

Perplexity = 10 → the model feels like there are ~10 equally likely next words

Higher perplexity → more confusion

Good for:

- Standard metric for measuring language modelling quality
- Comparing models on the same dataset
- Tracking training progress
- Detecting overfitting (train vs validation perplexity)

Alexandra Birch ATNLP Week 2/ Lecture 7 School of informatics 10

原 PPT : Perplexity

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“什么是 intrinsic evaluation？”。

考试版答案可以先说：Intrinsic evaluation 直接评价模型本身的内部任务或语言建模能力，而不是某个下游应用效果。进一步看，Perplexity 是评价语言模型的标准指标，可直观理解为模型在每个词位置平均认为有多少个可能选择。

- 考点问法：什么是 intrinsic evaluation？。答题抓手：Intrinsic evaluation 直接评价模型本身的内部任务或语言建模能力，而不是某个下游应用效果。
- 考点问法：perplexity 是什么？。答题抓手：Perplexity 是评价语言模型的标准指标，可直观理解为模型在每个词位置平均认为有多少个可能选择。
- 考点问法：perplexity 越低表示什么？。答题抓手：表示模型对下一个词越确定，语言建模损失越低。

5. Cloze Tasks

Perplexity				
Setting	LAMBADA (acc)	LAMBADA (ppl)	StoryCloze (acc)	HellaSwag (acc)
SOTA	68.0 ^a	8.63 ^b	91.8^c	85.6^d
GPT-3 Zero-Shot	76.2	3.00	83.2	78.9
GPT-3 One-Shot	72.5	3.35	84.7	78.1
GPT-3 Few-Shot	86.4	1.92	87.7	79.3

Brown et al. (2020) [Language Models are Few-Shot Learners](#), NeurIPS

Lower Perplexity ≠ Better Model

- Can improve by memorizing frequent patterns
- Doesn't capture long-range coherence
- Not good at measuring factual correctness, reasoning or alignment

language modeling papers have shifted more towards downstream task accuracy

Alexandra Birch ATNLP Week 2/ Lecture 7 School of Informatics 11

原 PPT : Perplexity

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“cloze task 是什么？”

。考试版答案可以先说：Cloze task 是给定上下文，要求模型填入缺失词或短语的任务。进一步看，LAMBADA 测试需要较宽 discourse context 才能预测目标词的语言理解能力。

- 考点问法：cloze task 是什么？。答题抓手：Cloze task 是给定上下文，要求模型填入缺失词或短语的任务。
- 考点问法：LAMBADA 测试什么能力？。答题抓手：LAMBADA 测试需要较宽 discourse context 才能预测目标词的语言理解能力。
- 考点问法：perplexity 和 cloze task 的关系是什么？。答题抓手：二者测量相近的语言建模能力；perplexity 是连续概率评价，cloze 是离散对错评价。

6. Task-based Benchmarks

Cloze Tasks

(1) Context: "Yes, I thought I was going to lose the baby." "I was scared too," he stated, sincerity flooding his eyes. "You were?" "Yes, of course. Why do you even ask?" "This baby wasn't exactly planned for."
Target sentence: "Do you honestly think that I would want you to have a _____?"
Target word: miscarriage

(2) Context: "Why?" "I would have thought you'd find him rather dry," she said. "I don't know about that," said Gabriel.
"He was a great craftsman," said Heather. "That he was," said Flannery.
Target sentence: "And Polish, to boot," said _____.
Target word: Gabriel

Paperno et al. (2016) [The LAMBADA dataset: Word prediction requiring a broad discourse context](#)

Perplexity and Cloze measure the same underlying capability:

- Perplexity is measured continuously – how confident was the model
- Cloze is measured discretely – right or wrong answer

Alexandra BirchATNLP Week 2/ Lecture 7School of Informatics 12

原 PPT : Cloze Tasks

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“什么是 task-based benchmark？”。考试版答案可以先说：它用一组标准化任务评价模型在不同能力维度上的表现，例如知识、代码、数学、推理和多模态。进一步看，因为一个模型可能数学强但事实性弱，或代码强但安全性差，单一任务不能代表整体能力。

- 考点问法：什么是 task-based benchmark？。答题抓手：它用一组标准化任务评价模型在不同能力维度上的表现，例如知识、代码、数学、推理和多模态。
- 考点问法：为什么 foundation models 需要 multidimensional evaluation？。答题抓手：因为一个模型可能数学强但事实性弱，或代码强但安全性差，单一任务不能代表整体能力。
- 考点问法：Gemma 3 技术报告中的 benchmark 表格说明什么？。答题抓手：现代模型评估通常跨多个任务报告结果，如 MMLU-Pro、LiveCodeBench、Bird-SQL、GPQA、SimpleQA、MATH、MMMU 等。

7. Saturation 与 Humanity's Last

Standardized Tasks												
	Gemini 1.5		Gemini 2.0		Gemma 2			Gemma 3				
	Flash	Pro	Flash	Pro	2B	9B	27B	1B	4B	12B	27B	
MMLU-Pro	67.3	75.8	77.6	79.1	15.6	46.8	56.9	14.7	43.6	60.6	67.5	
LiveCodeBench	30.7	34.2	34.5	36.0	1.2	10.8	20.4	1.9	12.6	24.6	29.7	
Bird-SQL (dev)	45.6	54.4	58.7	59.3	12.2	33.8	46.7	6.4	36.3	47.9	54.4	
GPQA Diamond	51.0	59.1	60.1	64.7	24.7	28.8	34.3	19.2	30.8	40.9	42.4	
SimpleQA	8.6	24.9	29.9	44.3	2.8	5.3	9.2	2.2	4.0	6.3	10.0	
FACTS Grounding	82.9	80.0	84.6	82.8	43.8	62.0	62.4	36.4	70.1	75.8	74.9	
Global MMLU-Lite	73.7	80.8	83.4	86.5	41.9	64.8	68.6	34.2	54.5	69.5	75.1	
MATH	77.9	86.5	90.9	91.8	27.2	49.4	55.6	48.0	75.6	83.8	89.0	
HiddenMath	47.2	52.0	63.5	65.2	1.8	10.4	14.8	15.8	43.0	54.5	60.3	
MMMU (val)	62.3	65.9	71.7	72.7	-	-	-	-	48.8	59.6	64.9	

Gemma Team et al. (2025) [Gema 3 Technical Report](#)

Evaluate across a range of standardized tasks – multidimensional performance for foundation models

Alexandra Birch ATNLP Week 2/ Lecture 7 School of Informatics 14

原 PPT : Standardized Tasks

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“benchmark saturation 是什么？”。考试版答案可以先说：当模型在 benchmark 上接近满分或人类水平，benchmark 不再能有效区分模型能力时，就发生 saturation。进一步看，它会让排行榜失去诊断价值，模型之间看似都很好，但真实能力差异可能被掩盖。

- 考点问法：benchmark saturation 是什么？。答题抓手：当模型在 benchmark 上接近满分或人类水平，benchmark 不再能有效区分模型能力时，就发生 saturation。
- 考点问法：saturation 有什么问题？。答题抓手：它会让排行榜失去诊断价值，模型之间看似都很好，但真实能力差异可能被掩盖。
- 考点问法：AI Index 图中的 saturation 说明什么？。答题抓手：许多经典 benchmark 上模型已经接近或超过人类 baseline，说明需要更难、更真实的评价。

8. Open-ended Generation Evalua

Testing is crucial

Suppose I give you a self-driving car.

How would you decide if the implementation is correct?



Alexandra Birch

ATNLP Week 2/ Lecture 7

School of
informatics

5

原 PPT : Testing is crucial

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“为什么开放式生成问题难评价？”。考试版答案可以先说：因为没有唯一正确答案，评价标准主观，甚至人类也会对质量有分歧。进一步看，因为 originality、emotional depth 和 cliché avoidance 都是主观维度，没有简单 ground truth。

- 考点问法：为什么开放式生成问题难评价？。答题抓手：因为没有唯一正确答案，评价标准主观，甚至人类也会对质量有分歧。
- 考点问法：“写一首避免陈词滥调的悲伤短诗”为什么难评分？。答题抓手：因为 originality、emotional depth 和 cliché avoidance 都是主观维度，没有简单 ground truth。
- 考点问法：哪些任务可能有参考答案但仍难评价？。答题抓手：翻译和摘要可能有参考答案，但仍有多个合理输出，自动指标不一定认可所有好答案。

- 为什么 evaluation 对 NLP 和 LLM 很关键？：Evaluation 决定我们如何判断系统是否变好、是否适合部署，以及研究是否真的取得进展。
- 为什么评价 LLM 比评价传统程序更难？：传统程序常有明确正确答案；LLM 输出开放、主观、上下文相关，常常没有唯一 ground truth。
- evaluation 的三个常见目标是什么？：比较两个或多个系统、评估系统改动是否有效、判断系统是否适合某个 use case。
- 为什么不同目标需要不同 evaluation？：因为“哪个系统整体更强”“某个改动是否有效”和“是否适合安全关键应用”衡量的风险和质量维度不同。
- 评价框架需要考虑哪些维度？：答案类型、是否有 ground truth、使用什么 metric、prompt formulation，以及 deployment criteria。
- 为什么没有 one true evaluation？：不同任务和部署场景重视不同能力，例如事实性、推理、安全、用户偏好或成本，单一指标无法覆盖。
- 为什么要看 individual instances 和 predictions？：总体分数可能隐藏错误模式，逐例分析能发现模型具体失败在哪里。
- 为什么 LLM 的开放式回答难以评价？：因为常无单一 ground truth，成功标准主观，人类评价者也可能对 originality、style 或 depth 有分歧。
- answer type 对评价有什么影响？：Multiple choice 容易自动评分；short answer 可用 exact match 或 F1；long/open answer 通常需要人工或 LLM 判断。
- 有 ground truth 和无 ground truth 的评价有什么区别？：有 ground truth 时可用 accuracy、F1 等自动指标；无 ground truth 时通常需要 rubrics、pairwise preference 或 judge。

一段稳妥考场回答

为什么 evaluation 对 NLP 和 LLM 很关键？：Evaluation 决定我们如何判断系统是否变好、是否适合部署，以及研究是否真的取得进展。为什么评价 LLM 比评价传统程序更难？：传统程序常有明确正确答案；LLM 输出开放、主观、上下文相关，常常没有唯一 ground truth。evaluation 的三个常见目标是什么？：比较两个或多个系统、评估系统改动是否有效、判断系统是否适合某个 use case。为什么不同目标需要不同 evaluation？：因为“哪个系统整体更强”“某个改动是否有效”和“是否适合安全关键应用”衡量的风险和质量维度不同。