


Parameter-efficient Finetuning

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Parameter-efficient Finetuning


In-context Learning 与 PEFT 动机 → PEFT 形式化框架 → Parameter Composition → LoRA → Input Composition 与 Prompt Tuning → Function Composition 与 Adapters

这节课一句话


这节课围绕“什么是 fine-tuning？”：Fine-tuning 是在预训练模型基础上继续训练，使模型适应某个任务、领域或行为目标。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。



原 PPT : Finetuning



原 PPT : In-context learning

Disadvantages of ICL

- **Inefficiency**: the prompt needs to be processed every time the model makes a prediction
- **Performance**: prompting generally performs worse than fine-tuning (Brown et al., 2020)
- **Sensitivity** to the wording of the prompt (Webson and Pavlick, 2022), order of examples (Zhao et al., 2021; Lu et al., 2022)
- **Lack of clarity** regarding what the model learns from the prompt — even random label can provide non-trivial results (Min et al., 2022)!

原 PPT : Disadvantages of ICL

2. 先抓住核心

这节课怎么入脑

这节课围绕“什么是 fine-tuning？”：Fine-tuning 是在预训练模型基础上继续训练，使模型适应某个任务、领域或行为目标。

考点问法：什么是 fine-tuning？

人话版：Fine-tuning 是在预训练模型基础上继续训练，使模型适应某个任务、领域或行为目标。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么模型越大，full fine-tuning 越困难？

人话版：因为需要更新和存储所有参数、梯度和优化器状态，显存、计算和存储成本都很高。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么讲义说 standard transfer learning formula breaks down？

人话版：在超大模型时代，像过去那样为每个任务完整 fine-tune 一个模型变得成本过高，不再实用。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。


考点问法：什么是 Parameter-Efficient Fine-Tuning？

人话版：PEFT 是只训练少量新增或选定参数，同时冻结大部分预训练模型参数的 fine-tuning 方法。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：PEFT 的核心目标是什么？

人话版：用更少可训练参数和更低训练成本，尽量接近 full fine-tuning 的下游性能。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. In-context Learning 与 PEFT 动



原 PPT : Parameter-efficient Finetuning

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“in-context learning 是什么？”。考试版答案可以先说：ICL 是在 prompt 中提供任务说明或示例，让模型在不更新参数的情况下完成任务。进一步看，不需要训练或更新模型参数，使用方便，适合快速测试和少样本任务。

- 考点问法：in-context learning 是什么？。答题抓手：ICL 是在 prompt 中提供任务说明或示例，让模型在不更新参数的情况下完成任务。
- 考点问法：ICL 的主要优点是什么？。答题抓手：不需要训练或更新模型参数，使用方便，适合快速测试和少样本任务。
- 考点问法：ICL 的第一个缺点是什么？。答题抓手：效率低，因为每次预测都要重新处理完整 prompt 和 examples。

4. PEFT 形式化框架

PEFT

Parameter-Efficient Fine-Tuning (PEFT) is not really a new idea!

- Updating the last layer of the model was common in computer vision (Donahue et al., 2014).
- In NLP, people experimented with static (frozen) and non-static (trainable) (Kim, 2014)
- ELMo did not fine-tune word embeddings (Peters et al., 2018)

Shay Cohen ATNLP Lecture 8 7/29

原 PPT : PEFT

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“讲义中如何把神经网络分解？”。考试版答案可以先说：把网络 $f: X \rightarrow Y$ 分解成多个函数组合 $f_{\theta_1} \odot \dots \odot f_{\theta_n}$ 。进一步看， θ 是原预训练模型参数，通常冻结； ϕ 是新增或可训练的模块参数。

- 考点问法：讲义中如何把神经网络分解？。答题抓手：把网络 $f: X \rightarrow Y$ 分解成多个函数组合 $f_{\theta_1} \odot \dots \odot f_{\theta_n}$ 。
- 考点问法：PEFT 中 θ 和 ϕ 分别表示什么？。答题抓手： θ 是原预训练模型参数，通常冻结； ϕ 是新增或可训练的模块参数。
- 考点问法：PEFT 的通常训练方式是什么？。答题抓手：固定原模型参数 θ ，只更新少量模块参数 ϕ 。

5. Parameter Composition

PEFT

Parameter-Efficient Fine-Tuning (PEFT) is not really a new idea!

- Updating the last layer of the model was common in computer vision (Donahue et al., 2014).
- In NLP, people experimented with static (frozen) and non-static (trainable) (Kim, 2014)
- ELMo did not fine-tune word embeddings (Peters et al., 2018)
- In practice, fine-tuning everything seems to work better - why go back to fine-tuning only some parameters?
- Fine-tuning everything is impractical with large models
- LLMs nowadays are massively over-parameterised — PEFT matches full fine-tuning in downstream accuracy

Food for thought: How would you reduce the number of parameters?

Shay Cohen

ATNLP Lecture 8

7/29

原 PPT : PEFT

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“parameter composition 是什么？”。考试版答案可以先说：它通过修改、选择或低秩更新原模型参数来适配新任务。进一步看，包括 sparse subnetworks、structured composition 和 low-rank composition。

- 考点问法：parameter composition 是什么？。答题抓手：它通过修改、选择或低秩更新原模型参数来适配新任务。
- 考点问法：parameter composition 包括哪些子类？。答题抓手：包括 sparse subnetworks、structured composition 和 low-rank composition。
- 考点问法：sparse subnetworks 的核心思想是什么？。答题抓手：只激活或训练模型中的一部分参数，用稀疏性降低可训练参数量。

6. LoRA

Three Kinds of PEFT

Let $f: X \rightarrow Y$ be a neural network, which can be decomposed into a composition of functions $f_{\theta_1} \odot \dots \odot f_{\theta_n}$, where each function has parameters θ_i with $i \in \{1, \dots, n\}$.
A module with parameters ϕ can modify a function f_{θ_i} as follows:

- Parameter composition: $g_i(x) = f_{\theta_i \oplus \phi}(x)$ (interpolation)
- Input composition: $g_i(x) = f_{\theta_i}([x, \phi])$ (concatenation)
- Function composition: $g_i(x) = f_{\theta_i} \odot f_{\phi}(x)$

Typically, only module parameters ϕ are updated while θ is fixed

Shay Cohen

ATNLP Lecture 8

8/29


原 PPT : Three Kinds of PEFT

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“LoRA 是什么？”。考试版答案可以先说：LoRA 是 Low-Rank Adaptation，通过学习低秩矩阵来表示权重更新。进一步看， $h = [W_0 + \Delta W]x = [W_0 + BA]x$ 。

- 考点问法：LoRA 是什么？。答题抓手：LoRA 是 Low-Rank Adaptation，通过学习低秩矩阵来表示权重更新。
- 考点问法：LoRA 的核心公式是什么？。答题抓手： $h = [W_0 + \Delta W]x = [W_0 + BA]x$ 。
- 考点问法：LoRA 中 W_0 表示什么？。答题抓手： W_0 是冻结的预训练权重。

7. Input Composition 与 Prompt T



原 PPT : Three Kinds of PEFT

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“input composition 是什么？”。考试版答案可以先说：它通过给模型输入拼接可学习向量或 prompt 来适配任务。进一步看， $g_i(x)=f_{\{\theta_i\}}([\phi_i, x])$ 。


- 考点问法：input composition 是什么？。答题抓手：它通过给模型输入拼接可学习向量或 prompt 来适配任务。
- 考点问法：input composition 的公式是什么？。答题抓手： $g_i(x)=f_{\{\theta_i\}}([\phi_i, x])$ 。
- 考点问法：standard prompting 如何看作 input composition？。答题抓手：离散文本 prompt 被 embedding layer 映射后，相当于在输入中加入提示向量。

8. Function Composition 与 Adapt

Parameter composition: low-rank composition

Another useful inductive bias: module parameters ϕ should lie in a low-dimensional space. Li et al., 2018 show that models can be optimised in a low-dimensional, randomly oriented subspace rather than the full parameter space.

Low-rank finetuning takes the form $g = f_{\theta + P\phi}$ where $P \in \mathbb{R}^{D \times d}$ - with a dense matrix of shape $D \times d$, this scales as $O(D \times d)$ in time and storage. D is the dimension of the model parameter, and d is a reduced size.



Shay Cohen

ATNLP Lecture 8

13/29

原 PPT : Parameter composition: low-rank composition

人话直觉

PEFT 像只调机器上的少数旋钮：不重造整个模型，而是在很小的参数预算里适配新任务。这部分的核心问题是“function composition 是什么？”。考试版答案可以先说：它在预训练模型函数中加入新的任务特定函数模块。进一步看， $g_i(x) = f_{\theta_i} \odot f_{\phi}(x)$ 。

- 考点问法：function composition 是什么？。答题抓手：它在预训练模型函数中加入新的任务特定函数模块。
- 考点问法：function composition 的公式是什么？。答题抓手： $g_i(x) = f_{\theta_i} \odot f_{\phi}(x)$ 。
- 考点问法：adapters 是什么？。答题抓手：Adapters 是插入预训练模型中的小型可训练模块，用来适配新任务。

- 什么是 fine-tuning ? : Fine-tuning 是在预训练模型基础上继续训练, 使模型适应某个任务、领域或行为目标。
- 为什么模型越大, full fine-tuning 越困难 ? : 因为需要更新和存储所有参数、梯度和优化器状态, 显存、计算和存储成本都很高。
- 为什么讲义说 standard transfer learning formula breaks down ? : 在超大模型时代, 像过去那样为每个任务完整 fine-tune 一个模型变得成本过高, 不再实用。
- 什么是 Parameter-Efficient Fine-Tuning ? : PEFT 是只训练少量新增或选定参数, 同时冻结大部分预训练模型参数的 fine-tuning 方法。
- PEFT 的核心目标是什么 ? : 用更少可训练参数和更低训练成本, 尽量接近 full fine-tuning 的下游性能。
- 为什么 training 的 memory constraint 比 inference 更严重 ? : 训练不仅要存模型参数, 还要存 gradients、activations 和 optimizer states; 推理通常不需要这些。
- PEFT 为什么在 LLM 时代重要 ? : LLM 参数量巨大, full fine-tuning 昂贵且难部署; PEFT 让大模型适配多个任务更现实。
- PEFT 是不是全新思想 ? : 不是。早期计算机视觉中更新最后一层、NLP 中冻结 embeddings 或部分参数都体现了类似思想。
- 为什么过去 full fine-tuning 常常效果更好, 现在又回到 PEFT ? : 因为大模型过度参数化, 少量参数调整也能达到强效果, 而 full fine-tuning 的成本在 LLM 上太高。
- PEFT 常见的三大类是什么 ? : Parameter composition、input composition 和 function composition。

一段稳妥考场回答

什么是 fine-tuning ? : Fine-tuning 是在预训练模型基础上继续训练, 使模型适应某个任务、领域或行为目标。为什么模型越大, full fine-tuning 越困难 ? : 因为需要更新和存储所有参数、梯度和优化器状态, 显存、计算和存储成本都很高。为什么讲义说 standard transfer learning formula breaks down ? : 在超大模型时代, 像过去那样为每个任务完整 fine-tune 一个模型变得成本过高, 不再实用。什么是 Parameter-Efficient Fine-Tuning ? : PEFT 是只训练少量新增或选定参数, 同时冻结大部分预训练模型参数的 fine-tuning 方法。