


Knowledge Distillation

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Knowledge Distillation

Proprietary 与 Open-source LLM → KD Recipe → 获取知识的方法 → 将知识转移给 Student → 综合比较题 → 公式与术语速记

这节课一句话

这节课围绕“什么是 Knowledge Distillation？”：Knowledge Distillation 是用强大的 teacher model 产生知识或监督信号，再训练较小或开源的 student model 学习这些能力。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Proprietary large language models

Advantages:

- Robust and can answer many types of queries
- Continuously updated and developed - no need to update software locally
- Performance is relatively high

Shay Cohen ATNLP Lecture 10 2/31

原 PPT : Proprietary large language models

Proprietary large language models

Disadvantages:

- Provided as a blackbox API - no way of checking the activations directly
- Issues with privacy (sending data to external services)
- High cost incurred (charged "per token")

Shay Cohen ATNLP Lecture 10 3/31

原 PPT : Proprietary large language models

Open-source large language models

Advantages:

- Full control over the model, including the representations
- Lower cost, some of them can run on a single GPU, depending on needs
- Often, the sources of the data trained on are well-known and training could be replicable
- Run locally, no issues with privacy

原 PPT : Open-source large language models

2. 先抓住核心

这节课怎么入脑

这节课围绕“什么是 Knowledge Distillation？”：Knowledge Distillation 是用强大的 teacher model 产生知识或监督信号，再训练较小或开源的 student model 学习这些能力。

考点问法：什么是 Knowledge Distillation？

人话版：Knowledge Distillation 是用强大的 teacher model 产生知识或监督信号，再训练较小或开源的 student model 学习这些能力。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：在 LLM 语境中，teacher 和 student 分别是什么？

人话版：Teacher 通常是性能更强的大模型或专有模型；student 通常是较小、成本更低或开源的模型。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：LLM distillation 的主要目标是什么？

人话版：把强模型的能力转移到更便宜、更可控、更易部署的模型上。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么要从 proprietary LLM 蒸馏到 open-source LLM？

人话版：为了缩小开源模型和昂贵专有模型的性能差距，同时降低成本、提高可控性和隐私性。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Knowledge Distillation 的核心 trick 是什么？

人话版：从更大的 teacher LLM 中抽取数据或反馈，再用标准训练方法进一步训练 student LLM。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Proprietary 与 Open-source LL

Open-source large language models

Disadvantages:

- Performance is lower, less engineering involved in perfecting them
- Fine-tuned on fewer tasks and fewer instructions
- The flip-side of lack of API: could be more difficult to run a service locally

Shay Cohen ATNLP Lecture 10 5/31

原 PPT : Open-source large language models

人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“proprietary LLM 的优点是什么？”。考试版答案可以先说：通常鲁棒、能回答多种 query、持续更新维护、性能较高。进一步看，常作为黑盒 API 提供，无法直接检查 activations；有隐私风险；按 token 收费成本高。

- 考点问法：proprietary LLM 的优点是什么？。答题抓手：通常鲁棒、能回答多种 query、持续更新维护、性能较高。
- 考点问法：proprietary LLM 的缺点是什么？。答题抓手：常作为黑盒 API 提供，无法直接检查 activations；有隐私风险；按 token 收费成本高。
- 考点问法：为什么 black-box API 对研究和调试不方便？。答题抓手：因为无法访问内部表示、梯度或中间状态，难以深入分析模型行为。

4. KD Recipe

Knowledge distillation

Main idea: Use the highly performing LLMs (OpenAI's models, for example) to further train open source models (such as Llama) to improve the latter's performance

Analogy: the big LLMs are the "teachers" and the open source models are the "students"

Shay Cohen ATNLP Lecture 10 6/31

原 PPT : Knowledge distillation

人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“LLM KD 的四个基本阶段是什么？”。考试版答案可以先说：选择 teacher 的目标 skill/domain 和 template，准备 seed knowledge，生成 distillation knowledge，再用生成知识训练 student。进一步看，I 是给 teacher LLM 的特定 instruction 或 prompt template，用来引导生成目标知识。

- 考点问法：LLM KD 的四个基本阶段是什么？。答题抓手：选择 teacher 的目标 skill/domain 和 template，准备 seed knowledge，生成 distillation knowledge，再用生成知识训练 student。
- 考点问法：template I 在 KD 中表示什么？。答题抓手：I 是给 teacher LLM 的特定 instruction 或 prompt template，用来引导生成目标知识。
- 考点问法：seed knowledge S 是什么？。答题抓手：S 是给 teacher 的初始输入，可以是 demonstrations、已有数据或 meta-knowledge。

5. 获取知识的方法

Benefits of KD

Take the best of both worlds (?)

- Narrow the gap between highly costly proprietary models and cost-effective open source models
- Reduce computation overall (by using an open source model instead of the big LLM). For example, can deploy on mobile phones or other resource-constrained environments
- Make LLMs more accessible to a wide audience and smaller stakeholders

Shay Cohen ATNLP Lecture 10 7/31

原 PPT : Benefits of KD


人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“讲义把获取知识的方法分成哪六类？”。

考试版答案可以先说：Labelling、Expansion、Data curation、Feature、Feedback 和 Self-knowledge。进一步看，给定输入 x ，让 teacher LLM 生成对应输出 y ，形成标注数据。

- 考点问法：讲义把获取知识的方法分成哪六类？。答题抓手：Labelling、Expansion、Data curation、Feature、Feedback 和 Self-knowledge。
- 考点问法：Approach 1: Labelling 是什么？。答题抓手：给定输入 x ，让 teacher LLM 生成对应输出 y ，形成标注数据。
- 考点问法：Labelling 的形式化定义是什么？。答题抓手： $D^{(lab)} = \{(x,y) \mid x \sim X, y \sim p_T(y \mid l \oplus c \oplus x)\}$ 。

6. 将知识转移给 Student



原 PPT : Knowledge Distillation

人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“拿到 distillation knowledge 后，还需要做什么？”。考试版答案可以先说：需要选择训练目标和算法，把 teacher 产生的知识转移到 student LLM。进一步看，Supervised finetuning、divergence/similarity methods、reinforcement learning 和 rank optimisation。

- 考点问法：拿到 distillation knowledge 后，还需要做什么？。答题抓手：需要选择训练目标和算法，把 teacher 产生的知识转移到 student LLM。
- 考点问法：讲义列出的知识转移方法有哪些？。答题抓手：Supervised finetuning、divergence/similarity methods、reinforcement learning 和 rank optimisation。
- 考点问法：Approach 1: Supervised finetuning 是什么？。答题抓手：用 curated/distilled dataset 继续训练 student model，使其学习 teacher 生成的输入输出映射。

7. 综合比较题

Recipe for KD

- Target skill or domain in the teacher LLM with template T
- Seed knowledge as input: feed the teacher LLM with seed knowledge (S) - can be embodied in various ways (demonstrations, existing data, meta-knowledge)
- Generation of distillation knowledge: use teacher LLM to generate knowledge examples
- Training the student model with the generated knowledge

Shay Cohen

ATNLP Lecture 10

10/31


原 PPT : Recipe for KD

人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“Labelling 和 Expansion 的区别是什么？”。考试版答案可以先说：Labelling 给定输入 x 让 teacher 生成标签 y ；Expansion 连输入 x 也由 teacher 根据 demonstrations 生成。进一步看，Expansion 依赖 demonstrations；Data curation 依赖 meta-information，例如主题或领域说明。

- 考点问法：Labelling 和 Expansion 的区别是什么？。答题抓手：Labelling 给定输入 x 让 teacher 生成标签 y ；Expansion 连输入 x 也由 teacher 根据 demonstrations 生成。
- 考点问法：Expansion 和 Data curation 的区别是什么？。答题抓手：Expansion 依赖 demonstrations；Data curation 依赖 meta-information，例如主题或领域说明。
- 考点问法：Feature 和 Feedback 的区别是什么？。答题抓手：Feature 使用 teacher 内部表示或分布；Feedback 使用 teacher 对 student 输出的评价或纠正。

8. 公式与术语速记



原 PPT : Roles of KD

人话直觉

Distillation 像大老师带小学生：小模型不必复制大模型全部体积，但要学会它最有用的行为模式。这部分的核心问题是“ $D_{I \rightarrow kd}$ 表示什么？”。考试版答案可以先说：表示由 template I 引导 teacher 生成并解析出的 distillation dataset。进一步看，表示 teacher 在给定 template 和 seed knowledge 后生成输出 o 的概率分布。

- 考点问法： $D_{I \rightarrow kd}$ 表示什么？。答题抓手：表示由 template I 引导 teacher 生成并解析出的 distillation dataset。
- 考点问法： $p_T(o | I \oplus s)$ 表示什么？。答题抓手：表示 teacher 在给定 template 和 seed knowledge 后生成输出 o 的概率分布。
- 考点问法： $p_S(y | x)$ 表示什么？。答题抓手：表示 student model 在输入 x 下生成输出 y 的概率。

- 什么是 Knowledge Distillation ? : Knowledge Distillation 是用强大的 teacher model 产生知识或监督信号，再训练较小或开源的 student model 学习这些能力。
- 在 LLM 语境中，teacher 和 student 分别是什么 ? : Teacher 通常是性能更强的大模型或专有模型；student 通常是较小、成本更低或开源的模型。
- LLM distillation 的主要目标是什么 ? : 把强模型的能力转移到更便宜、更可控、更易部署的模型上。
- 为什么要从 proprietary LLM 蒸馏到 open-source LLM ? : 为了缩小开源模型和昂贵专有模型的性能差距，同时降低成本、提高可控性和隐私性。
- Knowledge Distillation 的核心 trick 是什么 ? : 从更大的 teacher LLM 中抽取数据或反馈，再用标准训练方法进一步训练 student LLM。
- KD 在 LLM 中有哪三个角色 ? : 增强模型能力、传统压缩以提升效率、通过自生成知识实现自我改进。
- KD 为什么能提升 accessibility ? : 它让较小机构或本地设备也能使用接近强模型能力的 student model，而不总是调用昂贵 API。
- KD 和普通 supervised fine-tuning 有什么关系 ? : KD 常常先由 teacher 生成数据或标签，再用这些数据对 student 做 supervised fine-tuning 或其他训练。
- KD 是否一定需要访问 teacher 内部参数 ? : 不一定。很多方法只需要 black-box API 输出；但 feature-based 或 divergence-based 方法通常需要 white-box access。
- 为什么 KD 在 LLM 时代特别重要 ? : 强模型昂贵且常是黑盒，开源或小模型可控但能力弱；KD 提供了连接二者的实用方法。

一段稳妥考场回答

什么是 Knowledge Distillation ? : Knowledge Distillation 是用强大的 teacher model 产生知识或监督信号，再训练较小或开源的 student model 学习这些能力。在 LLM 语境中，teacher 和 student 分别是什么 ? : Teacher 通常是性能更强的大模型或专有模型；student 通常是较小、成本更低或开源的模型。LLM distillation 的主要目标是什么 ? : 把强模型的能力转移到更便宜、更可控、更易部署的模型上。为什么要从 proprietary LLM 蒸馏到 open-source LLM ? : 为了缩小开源模型和昂贵专有模型的性能差距，同时降低成本、提高可控性和隐私性。