

Long-Context

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Long-Context

Positional Encodings → RoPE 与 Context Extension → Efficient Attention → Long-Context Evaluation → Lost in the Middle → 综合比较题

这节课一句话

这节课围绕“什么是 long-context modelling？”：Long-context modelling 是让模型处理、检索并推理非常长的输入或输出序列，长度可从数万到百万 tokens。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Motivation

Long Documents (Code, legal, agent interaction histories)

Review this paper [paper] with these guidelines [reviewer guidelines]

Summary
This paper presents a method for extending the context window of LLaMA 2 models from 4K to 32K tokens through continual pretraining....

Strengths
Comprehensive Evaluation: The paper provides extensive empirical evaluation across multiple dimensions...
Practical Impact: The models maintain or improve performance on short-context tasks while gaining long-context capabilities, addressing a key limitation of prior work (e.g., Chen et al., 2023) ...

Inference-time Reasoning

If the entire world were made of glass marbles, could a human walk on the surface

This is a fascinating physics question! Let me think through what would happen.
Short answer: No, a human could not walk on the surface - they would sink.
Here's why:
The Marble Packing Problem
Glass marbles can't pack perfectly. Even in the most efficient arrangement (face-centered cubic), spheres only fill about 74% of space....


Alexandra Birch

ATNLP Week 2/ Lecture 11

School of Informatics

2

原 PPT : Motivation



原 PPT : Context Length

Current Frontier Models

Model family	Typical max input context window (tokens)	Notes
Anthropic Claude 4	200k standard; 500k enterprise; 1M beta tiers	May 2025
Google Gemini 3 Pro	1M tokens standard; up to 2M in some enterprise configs	Nov 2025: Longest context window of any large-scale foundation model
DeepSeek-R1	128k input tokens, 32k output	Jan 2025: Separate input and output context limits to support reasoning
OpenAI GPT-5	400k tokens input, 128k output	August 2025

原 PPT : Current Frontier Models

2. 先抓住核心

这节课怎么入脑

这节课围绕“什么是 long-context modelling？”：Long-context modelling 是让模型处理、检索并推理非常长的输入或输出序列，长度可从数万到百万 tokens。

考点问法：什么是 long-context modelling？

人话版：Long-context modelling 是让模型处理、检索并推理非常长的输入或输出序列，长度可从数万到百万 tokens。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么需要 long-context modelling？

人话版：现实任务常包含长文档、代码库、法律材料、agent 历史和长推理过程；如果只能截断或摘要，可能丢失关键信息。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：没有长上下文能力时，系统通常怎么处理长输入？

人话版：通常使用 retrieval、truncation 或 summarisation，但这些方法都可能遗漏关键内容。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：长上下文建模的三个核心挑战是什么？

人话版：训练数据 mismatch、计算成本高、任务本身更难。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：training data mismatch 指什么？

人话版：大多数预训练数据是短文档，模型在训练中很少见到真实长文档，因此长上下文推理会遇到分布偏移。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Positional Encodings

Long-Context Modelling

Process, retrieve, and reason over **very long input and/or output sequences**, ranging to **millions of tokens**

Without long-context modeling, systems need **retrieval, truncation, or summarization**, which can lose critical information.

Alexandra Birch ATNLP Week 2/ Lecture 11 School of Informatics 5

原 PPT : Long-Context Modelling

人话直觉

Long context 像把书桌变大：能摊开更多资料，但真正难的是在一大桌内容里找到、记住、整合正确的信息。这部分的核心问题是“Transformer 为什么需要 positional encodings？”。考试版答案可以先说：Transformer 并行处理 tokens，token embeddings 本身不包含顺序信息，所以需要位置编码表示 token 顺序。进一步看，通常相加： $z_{pos} = x_{pos} + PE_{pos}$ 。

- 考点问法：Transformer 为什么需要 positional encodings？。答题抓手：Transformer 并行处理 tokens，token embeddings 本身不包含顺序信息，所以需要位置编码表示 token 顺序。
- 考点问法：token embedding 和 positional encoding 如何结合？。答题抓手：通常相加： $z_{pos} = x_{pos} + PE_{pos}$ 。
- 考点问法：为什么不能直接用整数位置编码？。答题抓手：整数位置值无界、数值大小会支配 embedding、训练外位置无法泛化，且相邻位置差异不具备良好缩放性质。

4. RoPE 与 Context Extension

Core Challenges

- Training Data Mismatch**
 - Most pretraining data consists of **short documents**.
 - Training on long documents **extremely expensive** and **lack of realistic data**
 - Models extrapolating to long contexts face:
 - Distribution shift
 - Positional generalization failures
- Computational Cost**
 - Self-attention scales quadratically with sequence length
 - This makes naive scaling prohibitively expensive in compute and memory.
- Task Difficulty**
 - Even when long contexts are supported, models may:
 - Fail to retrieve relevant information
 - Overweight irrelevant or recent content
 - Long context $\neq$ effective long-range reasoning.

Alexandra Birch ATNLP Week 2/ Lecture 11 School of Informatics 6

原 PPT : Core Challenges

人话直觉

Long context 像把书桌变大：能摊开更多资料，但真正难的是在一大桌内容里找到、记住、整合正确的信息。这部分的核心问题是“RoPE 是什么？”。考试版答案可以先说：RoPE 是 Rotary Position Embedding，通过旋转 query/key 向量来编码位置。进一步看，sinusoidal PE 把位置加到向量上；RoPE 用位置旋转向量，使相对位置以角度差形式进入 attention。

- 考点问法：RoPE 是什么？。答题抓手：RoPE 是 Rotary Position Embedding，通过旋转 query/key 向量来编码位置。
- 考点问法：RoPE 和 sinusoidal addition 的区别是什么？。答题抓手：sinusoidal PE 把位置加到向量上；RoPE 用位置旋转向量，使相对位置以角度差形式进入 attention。
- 考点问法：RoPE 为什么适合表示相对距离？。答题抓手：两个位置的旋转角度差会自然反映相对距离，attention 能直接感知相对位置。

5. Efficient Attention

Outline

- Positional Encodings
- Efficient Attention
- Evaluation
- Analysis
- Summary

Alexandra Birch

ATNLP Week 2/ Lecture 11

School of
informatics

7

原 PPT : Outline

人话直觉

Long context 像把书桌变大：能摊开更多资料，但真正难的是在一大桌内容里找到、记住、整合正确的信息。这部分的核心问题是“Transformer attention 的基本公式是什么？”。考试版答案可以先说： $\text{Attention}(Q,K,V)=\text{softmax}(QK^T/\sqrt{d})V$ 。进一步看，因为 QK^T 产生 $n \times n$ attention matrix，需要计算每个 token 对每个 token 的关系。

- 考点问法：Transformer attention 的基本公式是什么？。答题抓手： $\text{Attention}(Q,K,V)=\text{softmax}(QK^T/\sqrt{d})V$ 。
- 考点问法：为什么 full attention 是 $O(n^2)$ ？。答题抓手：因为 QK^T 产生 $n \times n$ attention matrix，需要计算每个 token 对每个 token 的关系。
- 考点问法：sparse attention 是什么？。答题抓手：Sparse attention 只计算部分 token pair 的注意力，而不是所有 pair。

6. Long-Context Evaluation

Positional Encodings: Recap

Attention Is All You Need/Transformer

- Order of elements is crucial – word embeddings do not contain position
- Transformer processes all tokens in parallel – unlike recurrent models – no concept of sequential structure of data
- Token embeddings x_{pos} + Positional encodings PE_{pos} get concatenated before being passed to Transformer attention layers

$$z_{pos} = x_{pos} + PE_{pos}$$

Alexandra Birch

ATNLP Week 2/ Lecture 11

School of
informatics

9

原 PPT : Positional Encodings: Recap

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“为什么长上下文需要专门评价？”。考试版答案可以先说：因为支持长输入和真正使用长输入是两回事，需要测试模型是否能在长文档中定位和推理关键信息。进一步看，把一个关键事实放进很长的无关文本中，要求模型找出该事实，用来测试长上下文检索能力。

- 考点问法：为什么长上下文需要专门评价？。答题抓手：因为支持长输入和真正使用长输入是两回事，需要测试模型是否能在长文档中定位和推理关键信息。
- 考点问法：Needle in the Haystack 是什么？。答题抓手：把一个关键事实放进很长的无关文本中，要求模型找出该事实，用来测试长上下文检索能力。
- 考点问法：Needle in the Haystack 中 haystack 和 needle 分别是什么？。答题抓手：Haystack 是大量无关填充文本；needle 是隐藏在其中的关键事实。

7. Lost in the Middle

Positional Encodings

Q: Why not use integer positional encodings?

- Unbounded values:
 - Position 1000 is 1000× larger than position 1
 - Dominates the embedding magnitudes
 - Breaks numerical stability
- No generalization:
 - If trained on sequences up to length 512 Never seen positions 513, 514, ...
 - Can't handle longer sequences
- Poor scaling:
 - Position differences aren't meaningful Is position 100→101 similar to 500→501?
 - Hard for model to learn

Alexandra Birch ATNLP Week 2/ Lecture 11 School of Informatics 10

原 PPT : Positional Encodings

人话直觉

Long context 像把书桌变大：能摊开更多资料，但真正难的是在一大桌内容里找到、记住、整合正确的信息。这部分的核心问题是“lost-in-the-middle 是什么？”。考试版答案可以先说：模型在长输入中更容易利用开头和结尾信息，而对中间信息利用较差。进一步看，当相关信息位于上下文中间时，模型表现显著下降，形成 U-shaped performance curve。

- 考点问法：lost-in-the-middle 是什么？。答题抓手：模型在长输入中更容易利用开头和结尾信息，而对中间信息利用较差。
- 考点问法：lost-in-the-middle 的表现是什么？。答题抓手：当相关信息位于上下文中间时，模型表现显著下降，形成 U-shaped performance curve。
- 考点问法：为什么 lost-in-the-middle 重要？。答题抓手：它说明长上下文窗口不等于均匀有效的信息访问。


8. 综合比较题

Positional Encodings: Sinosoidal

$$\text{PE}_{\text{pos}} = [\sin(\omega_0 \text{pos}), \cos(\omega_0 \text{pos}), \sin(\omega_1 \text{pos}), \cos(\omega_1 \text{pos}), \dots, \sin(\omega_{d/2-1} \text{pos}), \cos(\omega_{d/2-1} \text{pos})]$$

Where $\omega_i = 1/10000^{2i/d}$ frequency determines the speed of oscillation
 d = transformer embedding dim

- **Properties**
 - sin cos pair defines a **single angle** on a unit circle
 - PE sin cos vector forms a **unique fingerprint** for each position
 - Can infer how far apart two tokens or pos are: dot product of two PE contain **relative distance**
 - Deterministic (no learning)
 - **Extrapolate** to longer sequences than seen in training



Alexandra Birch ATNLP Week 2/ Lecture 11 School of Informatics 12

原 PPT : Positional Encodings: Sinosoidal

人话直觉

Long context 像把书桌变大：能摊开更多资料，但真正难的是在一大桌内容里找到、记住、整合正确的信息。这部分的核心问题是“Long context 和 RAG 的区别是什么？”。考试版答案可以先说：Long context 试图把更多信息直接放进模型窗口；RAG 先检索相关信息再生成，减少无关内容但依赖检索质量。进一步看，都试图让基于 RoPE 的模型在超过预训练长度的上下文中更稳定工作。

- 考点问法：Long context 和 RAG 的区别是什么？。答题抓手：Long context 试图把更多信息直接放进模型窗口；RAG 先检索相关信息再生成，减少无关内容但依赖检索质量。
- 考点问法：Position Interpolation、NTK Scaling 和 YaRN 的共同目标是什么？。答题抓手：都试图让基于 RoPE 的模型在超过预训练长度的上下文中更稳定工作。
- 考点问法：Efficient attention 和 RoPE scaling 解决的问题有何不同？。答题抓手：RoPE scaling 解决位置泛化；efficient attention 解决长序列计算成本。

- 什么是 long-context modelling ? : Long-context modelling 是让模型处理、检索并推理非常长的输入或输出序列，长度可从数万到百万 tokens。
- 为什么需要 long-context modelling ? : 现实任务常包含长文档、代码库、法律材料、agent 历史和长推理过程；如果只能截断或摘要，可能丢失关键信息。
- 没有长上下文能力时，系统通常怎么处理长输入 ? : 通常使用 retrieval、truncation 或 summarisation，但这些方法都可能遗漏关键内容。
- 长上下文建模的三个核心挑战是什么 ? : 训练数据 mismatch、计算成本高、任务本身更难。
- training data mismatch 指什么 ? : 大多数预训练数据是短文档，模型在训练中很少见到真实长文档，因此长上下文推理会遇到分布偏移。
- positional generalization failure 是什么 ? : 模型在训练中只见过较短位置，推理时遇到更远位置可能无法正确泛化位置关系。
- 为什么 self-attention 是长上下文的计算瓶颈 ? : 因为 full attention 需要计算所有 token pair 的注意力，复杂度随序列长度平方增长。
- “long context $\neq$ effective long-range reasoning” 是什么意思 ? : 即使模型支持很长输入，也不代表它能有效找到、使用和推理中间的关键信息。
- Transformer 为什么需要 positional encodings ? : Transformer 并行处理 tokens，token embeddings 本身不包含顺序信息，所以需要位置编码表示 token 顺序。
- token embedding 和 positional encoding 如何结合 ? : 通常相加： $z_{pos} = x_{pos} + PE_{pos}$ 。

一段稳妥考场回答

什么是 long-context modelling ? : Long-context modelling 是让模型处理、检索并推理非常长的输入或输出序列，长度可从数万到百万 tokens。为什么需要 long-context modelling ? : 现实任务常包含长文档、代码库、法律材料、agent 历史和长推理过程；如果只能截断或摘要，可能丢失关键信息。没有长上下文能力时，系统通常怎么处理长输入 ? : 通常使用 retrieval、truncation 或 summarisation，但这些方法都可能遗漏关键内容。长上下文建模的三个核心挑战是什么 ? : 训练数据 mismatch、计算成本高、任务本身更难。