

Long-Context Modelling

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

Long documents and reasoning need more context → Long context is processing, retrieving, and reasoning over very long sequences → Three bottlenecks: data mismatch, quadratic attention, task difficulty → Positional encodings give Transformer order information → RoPE turns position into Q/K rotation and makes relative distance visible to attention → Context extension rescales positions or frequencies: Position Interpolation, NTK Scaling, YaRN → Efficient attention trades full global visibility for cheaper sparse patterns → Long-context evaluation asks whether models can actually access and use evidence → Lost in the Middle shows long window does not imply uniform long-range reasoning

Long-Context Modelling

Process, retrieve, and reason over **very long input and/or output sequences**, ranging to **millions of tokens**

Without long-context modeling, systems need **retrieval, truncation, or summarization**, which can lose critical information.

这节课一句话

这节课的核心不是“把窗口做大就万事大吉”，而是理解长上下文能力由三件事共同决定：位置能不能外推、attention 算不算得起、模型是否真的会在长文本里找到并使用关键信息。

1. 先别迷信百万窗口：long context 是一种使用能力，不只是容量指标

Long-Context Modelling

Process, retrieve, and reason over **very long input and/or output sequences**, ranging to millions of tokens

Without long-context modeling, systems need **retrieval, truncation, or summarization**, which can lose critical information.

原 PPT 第 5 页

人话直觉

把上下文窗口想成书桌。桌子大当然能摊开更多论文、代码、法律条文和 agent 历史，但考试真正问的是：模型能不能在这张大桌子上找到该看的那一页，并把它用进答案里。桌子大不等于会读书，这就是 long-context modelling 的第一层直觉。

精确定义 / 机制：Long-context modelling 指模型能够 process、retrieve、reason over very long input and/or output sequences，长度可以从几万到百万 tokens。它的重要性来自真实任务：长文档审稿、代码库理解、法律材料、agent interaction histories，以及 inference-time reasoning 产生的长推理轨迹。没有长上下文能力时，系统通常只能 retrieval、truncation 或 summarisation；这些方法能省输入长度，但会把关键信息挡在门外、截掉，或压缩成不够精确的摘要。所以本讲不是简单反 RAG，而是在问：当我们真的把长材料放进模型时，模型是否能稳定处理和使用它。

考试问法：如果问“什么是 long-context modelling，为什么需要它”，先给定义：处理、检索、推理 very long sequences；再给动机：长文档、代码、法律、agent 历史、长推理；最后补 caveat：retrieval/truncation/summarisation 可用但可能丢失 critical information。

2. 三座大山：数据没见过、attention 太贵、任务本身更难

Core Challenges

Training Data Mismatch

- Most pretraining data consists of **short documents**.
- Training on long documents **extremely expensive** and **lack of realistic data**
- Models extrapolating to long contexts face:
 - Distribution shift
 - Positional generalization failures

Computational Cost

- Self-attention scales quadratically with sequence length
- This makes naive scaling prohibitively expensive in compute and memory.

Task Difficulty

- Even when long contexts are supported, models may:
 - Fail to retrieve relevant information
 - Overweight irrelevant or recent content
- Long context $\neq$ effective long-range reasoning.

原 PPT 第 6 页

人话直觉

长上下文失败通常不是一个按钮没开，而是三件事同时拖后腿。第一，模型像只读过短篇小说的学生，突然被扔进长篇巨著，会遇到训练分布外的位置和结构。第二，full attention 像让全班每个人和每个人握手，人数翻倍，握手次数近似翻四倍。第三，就算握手完成，模型也未必知道哪句话是证据、哪句话是噪音。

精确定义 / 机制：讲义把核心挑战分成 training data mismatch、computational cost 和 task difficulty。Training data mismatch 指大多数预训练数据是短文档，真实长文档昂贵且稀缺；模型外推到更长上下文时会遇到 distribution shift 和 positional generalization failures。Computational cost 来自 self-attention 的二次复杂度：序列越长，token pair 越多，显存和计算迅速爆炸。Task difficulty 则提醒我们，支持长 context window 不等于能有效 long-range reasoning：模型可能找不到相关信息，也可能过度关注无关内容或最近内容。因此考试里最重要的一句话是：long context $\neq$ effective long-range reasoning。

考试问法：高频问法是“长上下文建模的核心挑战”。按三点答：训练数据 mismatch/position 外推失败，self-attention quadratic cost，任务难度与检索使用失败；最后用一句 long context 不等于有效推理收尾。


3. 位置编码: Transformer 需要一只“顺序罗盘”

Positional Encodings: Sinosoidal

$$PE_{pos} = [\sin(\omega_0 pos), \cos(\omega_0 pos), \sin(\omega_1 pos), \cos(\omega_1 pos)$$

$$\dots \sin(\omega_{d/2-1} pos), \cos(\omega_{d/2-1} pos)]$$

Where $\omega_i = 1/10000^{2i/d}$ frequency determines the speed of oscillation
 d = transformer embedding dim



- **Properties**

- sin cos pair defines a **single angle** on a unit circle
- PE sin cos vector forms a **unique fingerprint** for each position
- Can infer how far apart two tokens or pos are: dot product of two PE contain **relative distance**
- Deterministic (no learning)
- **Extrapolate** to longer sequences than seen in training

原 PPT 第 12 页

人话直觉

Transformer 本身并不像 RNN 那样一个词一个词往前走，它更像把所有 token 同时倒在桌上。如果不加位置编码，‘dog bites man’ 和 ‘man bites dog’ 的词袋看起来太像。Positional encoding 就是给每个 token 别上坐标牌，告诉模型谁在前、谁在后、相隔多远。

精确定义 / 机制：Token embedding 只表示词义，不天然包含顺序；Transformer 并行处理所有 token，所以必须把 positional encoding 加入输入表示，常见形式是 $z_{pos} = x_{pos} + PE_{pos}$ 。不能直接用整数位置，因为整数无界、数值尺度会支配 embedding、训练外位置无法泛化，而且 $100 \rightarrow 101$ 与 $500 \rightarrow 501$ 的相邻关系不容易以良好尺度表达。Sinusoidal positional encoding 用多组 sine/cosine 频率给每个位置生成固定向量：高频维度变化快，适合局部位置；低频维度变化慢，适合全局位置。每个位置得到一个 deterministic fingerprint，点积中也携带相对距离信息。

$$z_{pos} = x_{pos} + PE_{pos}, \quad PE_{pos} = [\sin(\omega_0 pos), \cos(\omega_0 pos), \dots, \sin(\omega_i pos), \cos(\omega_i pos)]$$

考试问法：如果问 positional encoding，答题顺序是：Transformer 缺少顺序感 $\rightarrow z_{pos} = x_{pos} + PE_{pos}$ $\rightarrow$ 整数位置编码的问题 $\rightarrow$ sinusoidal 用多频 sine/cosine，快频看局部、慢频看全局、无需学习且能表达相对距离。

4. RoPE: 不要把位置贴上去, 而是把 Q/K 转一个角度

RoPE

2D Example:

Query $q = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, Key $k = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

Attention without position: $q \cdot k = 1$

Rotation matrix R for position pos : $\begin{bmatrix} \cos(pos) & -\sin(pos) \\ \sin(pos) & \cos(pos) \end{bmatrix}$

Query at position 1: $q_1 = R(1)q = \begin{bmatrix} \cos 1 \\ \sin 1 \end{bmatrix} \approx \begin{bmatrix} 0.54 \\ 0.84 \end{bmatrix}$ Rotary position embedding

Key at position 3: $k_3 = R(3)k = \begin{bmatrix} \cos 3 \\ \sin 3 \end{bmatrix} \approx \begin{bmatrix} -0.99 \\ 0.14 \end{bmatrix}$

Attention with position: $q_1 \cdot k_3 = (0.54)(-0.99) + (0.84)(0.14) = -0.41$

Now, relative position difference is 2. What is $\cos 2$? -0.41 !

ie. Attention sees $\cos(\text{relative distance})$.

Alexandra Birch

ATNLP Week 2/ Lecture 11

School of Informatics

16

原 PPT 第 16 页

人话直觉

Sinusoidal addition 像给向量贴一张位置标签; RoPE 更像拿着指南针把 query 和 key 真的旋转到对应方向。两个 token 的位置差, 不再需要模型费劲学出来, 而是自然变成两个旋转角之间的差。Attention 一做点积, 就能感到“你离我多远”。

精确定义 / 机制: RoPE 即 Rotary Position Embedding。它不把位置作为额外向量简单相加, 而是在 attention 的 Q 和 K 上应用由位置决定的旋转矩阵。以 2D 为例, 位置 pos 对应旋转 $R(pos)$; query at position 1 与 key at position 3 旋转后做点积, 结果等价于看到相对角度差 2。RoPE 通常只作用于 Q/K, 因为 Q/K 决定 attention score, 也就是 token 之间该互相关注多少; V 是被聚合的内容, 不需要同样旋转。旋转是 orthogonal transform, 能保持向量长度, 因此稳定、方向敏感、不扭曲 content magnitude, 并把 relative position 内建进 attention math。


$$R(pos) = \begin{bmatrix} \cos(pos) & -\sin(pos) \\ \sin(pos) & \cos(pos) \end{bmatrix}, \quad \langle R(m)q, R(n)k \rangle \text{ depends on } n - m$$

考试问法: 如果考 RoPE, 必须说清它与 sinusoidal addition 的区别: addition 是把位置贴到表示上, RoPE 是旋转 Q/K; 优点是相对距离由角度差自然进入 attention, 且旋转保持长度。别忘了说明为什么不转 V: 位置主要影响 attention score。

5. Context extension: 把模型带到更远位置，不能直接硬拉

Extending Context Beyond Training

- Training with long context is expensive!
- And RoPE struggles to generalize past the context window seen during pre-training. Why?
High-frequency rotations wrap around too fast and relative distances become noisy



Performance degrades on unseen range

Position Interpolation:
Downscale position indices to reside in pretrained range
Extended from 2048 to 32k
Fine tuning on only 1000 steps
Negligible compared to pre-train

Chen et al. (2023) [Extending Context Window of Large Language Models via Positional Interpolation](#)

Alexandra Birch

ATNLP Week 2/ Lecture 11

School of Informatics

18

原 PPT 第 18 页

人话直觉

RoPE 在训练长度内像一块调好的钟表；一旦走到太远位置，高频指针会转得太快、绕圈太多，模型看到的距离开始像噪音。Position Interpolation 的思路很朴素：既然模型只熟悉 2048 以内的位置，那就把 4096 的坐标压缩回熟悉范围，让它在老地图上走新路。

精确定义 / 机制：长上下文训练非常昂贵，而 RoPE 直接外推到预训练窗口之外会退化，原因是 high-frequency rotations wrap around too fast, relative distances become noisy。Position Interpolation 把更长上下文的位置索引 downscale 到 pretrained range，例如原来只训练到 2048，要扩到 4096，可以把位置 m 映射成 $m/2$ 。这样模型不必面对完全没见过的巨大位置，并且 Chen et al. 展示了用很少 long-context fine-tuning steps 就能扩展窗口。但代价是线性压缩会让相邻 token 更难区分：100,101,102,103 压缩 4 倍后变成 25.0,25.25,25.5,25.75，局部分辨率变低。

$$f'(x, m) = f\left(x, \frac{m}{s}\right), \quad s = \frac{L_{new}}{L_{train}}$$

考试问法：如果问 Position Interpolation，答：目的：扩展 RoPE 模型上下文；方法：缩放 position indices 回预训练范围；优点：便宜、少量微调可行；问题：压缩位置会降低相邻 token 区分度。

6. NTK Scaling 与 YaRN: 位置压缩太粗，就改频率、分波长处理


YaRN

YaRN: Yet another RoPE extension method: Position Interpolation in parts

Pretrained Context length = L

Wavelength λ = number of tokens for a RoPE dimension to complete rotation

$\ll L$ no positional interpolation
in between some positional interpolation
 $\geq L$ positional interpolation



Peng et al. (2023) [YaRN: Efficient Context Window Extension of Large Language Models](#)

Alexandra Birch

ATNLP Week 2 / Lecture 11

School of Informatics

20

原 PPT 第 20 页

人话直觉

如果 Position Interpolation 是把整张地图统一缩小，NTK Scaling 更像调钟表齿轮：位置号还照常走，但让某些旋转频率慢一点。YaRN 再细一点：短波长负责局部细节，别乱压；长波长负责全局跨度，可以拉伸；中间区域做平滑过渡。

精确定义 / 机制：NTK Scaling 的核心区别是 keep position indices, adjust rotation frequencies。RoPE 旋转角可写作 $\theta = \omega_i \text{ pos}$ ；为了更长 context，可以把频率变小， $\theta = (\alpha \omega_i) \text{ pos}$ ，其中 $\alpha < 1$ ，使远距离下旋转不至于过快 wrap around。YaRN，即 Yet another RoPE extension method，是分段 position interpolation：对于 wavelength 远小于预训练长度 L 的维度，不做插值以保护局部 token 区分；中间波长做部分插值；长波长维度做位置插值以覆盖全局距离。它体现了长上下文扩展的核心 tradeoff：既要保住短距离精度，又要拉开长距离视野。

$$\theta_i = \omega_i \text{ pos}, \quad \theta_i^{\text{NTK}} = (\alpha \omega_i) \text{ pos}, \quad 0 < \alpha < 1$$


考试问法：比较题常问 Position Interpolation、NTK Scaling、YaRN。推荐答：PI 压 position indices；NTK 不压位置而调 RoPE frequency；YaRN 按 wavelength 分段，短波长保局部、长波长扩全局。

7. Efficient attention: 不是每个 token pair 都值得付全价

Sparse Attention

Sparse attention reduces complexity to $O(n)$: only compute attention weights for a subset of possible pairs

Beltagy et al. (2020) [Longformer: The Long-Document Transformer](#)



Showed could process sequences beyond 512 tokens – to 4096

Alexandra Birch

ATNLP Week 2 / Lecture 11

School of
informatics

23

原 PPT 第 23 页

人话直觉

Full attention 像让会议室里每个人都和其他所有人逐一聊天，信息最全，但人一多就崩。Sparse attention 的想法是：大多数时候只和附近的人说话；偶尔隔几个座位看远处；再安排几个主持人能看全场。这样牺牲一点全局细节，换来能处理更长文档。

精确定义 / 机制：标准 attention 为 $Attention(Q, K, V) = softmax(QK^T / \sqrt{d})V$ 。若序列长度为 n ， QK^T 形成 $n \times n$ attention matrix，因此 full attention 是 $O(n^2)$ 。Sparse attention 只计算部分 token pairs，把复杂度向 $O(n)$ 靠近。Longformer 图中有三类核心模式：sliding window attention 让每个 token 只看局部窗口；dilated sliding window 通过间隔采样覆盖更远位置；global+sliding window 让少数全局 token attend to entire sequence，用于全局理解，其余 token 保持局部计算。关键 tradeoff 是效率 vs attention quality：你省掉的 pair 里可能正好有需要的长距离依赖。

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d}}\right)V, \quad QK^T \in \mathbb{R}^{n \times n}$$

考试问法：如果问 efficient attention，先写 full attention 公式和 $O(n^2)$ 来源，再解释 sparse/sliding/dilated/global tokens 如何省计算；最后必须说 tradeoff：更便宜但可能损失全局信息整合。

8. Evaluation: 能塞进去，不等于能找出来；能找出来，不等于真理解

Needle in the Haystack

Can the model access long context? Simple, controllable sanity check

- The model is given a **very long context** (e.g. 50k–200k tokens).
Most of the text is **irrelevant filler** (the “haystack”): Eg. Wikipedia articles, News text
- Somewhere in the middle (often randomly placed) is a **single critical fact** (the “needle”).
- Ask the model to retrieve this statement
- Iterate over various document depths (where the needle is placed) and context lengths to measure performance

原 PPT 第 27 页


人话直觉

长上下文评测先问一个很朴素的问题：我把一条关键事实藏进十万 token 的无关文本里，你能不能拿回来？这就是 Needle in the Haystack。但这只是开门测视力，不是完整考阅读理解；真正任务还要跨文档、多轮对话、代码库、表格和长推理。

精确定义 / 机制：Needle in the Haystack 是一个 simple, controllable sanity check: 给模型很长 context, 其中大部分是 irrelevant filler, 即 haystack; 在某个位置藏一个 critical fact, 即 needle; 然后要求模型 retrieve this statement。评测通常系统调节 context length 和 needle depth, 观察模型是否在不同长度、不同位置都能稳定取回信息。它的优点是可控、直观、能快速测试 access long context; 局限是偏单事实检索, 不代表真实 long-document understanding 或 reasoning。LongBench v2 则更接近真实任务, 覆盖 single/multi-document QA、long in-context learning、long dialogue history、code repository understanding 和 structured data understanding, 强调长上下文的 deeper understanding and reasoning。

考试问法：评价题要分层答：Needle test 测访问和检索能力, 变量是 context length 与 needle depth, 优点是可控 sanity check, 缺点是太简单; LongBench 更真实、多任务、多领域, 但标注和评估成本更高。

9. Lost in the Middle: 窗口很长，但模型的注意力并不公平



Liu et al. (2024) [Lost in the Middle: How Language Models Use Long Contexts](#), ACL

Alexandra Birch

ATNLP Week 2 / Lecture 11

School of Informatics

34

原 PPT 第 34 页

人话直觉

想象你把证据放在一本厚书中间，模型却像只认真看封面和封底。Lost in the Middle 的 U 形曲线说明：相关信息在开头或结尾时表现较好，放到中间就明显变差。最扎心的一点是：模型也许能 attend 到中间 token，但不代表它会把中间证据用对。

精确定义 / 机制： Lost in the Middle 指长输入中 relevant information 的位置会显著影响模型表现。Liu et al. 展示，当答案 passage 位于输入中间时，multi-document QA performance 下降，形成 U-shaped performance curve。这与 recency bias 和开头位置偏好有关，也支持讲义中的警句：Attention $\neq$ reasoning。即便模型架构允许访问远处 token，或者 attention map 显示某些中间 token 被看见，模型仍可能无法有效 integrate evidence。对 RAG 和 context engineering 的启发是：把证据塞进上下文还不够，证据排序、突出、去噪和结构化同样重要。

考试问法：如果问 lost-in-the-middle，答：模型更善用开头/结尾信息，中间相关信息导致表现下降，曲线常呈 U-shape；意义是 long context window 不等于均匀有效访问，attention 不等于 reasoning；对 RAG 要合理排序和突出关键证据。

考试速记版

- Long-context modelling = process, retrieve, and reason over very long input/output sequences, not just having a large token limit.
- 没有长上下文时常用 retrieval、truncation、summarisation，但都可能丢 critical information。
- 三大挑战：training data mismatch/positional generalization failure，self-attention quadratic cost，task difficulty。
- Transformer 需要 positional encodings，因为 token embeddings 本身没有顺序，Transformer 又并行处理 tokens。
- 整数位置编码不好：数值无界、尺度支配 embedding、训练外位置不能泛化、相邻差异缩放差。
- Sinusoidal PE 用多频 sine/cosine：高频看局部，低频看全局；固定、无需学习、能携带相对距离信息。

- RoPE 用位置旋转 Q/K，而不是把位置加到向量上；relative position 以 angle difference 进入 attention。
- RoPE 不转 V，因为位置主要影响 attention score；V 是被聚合的内容。
- Position Interpolation 压缩 position indices 回预训练范围；优点便宜，缺点相邻 token 更难区分。
- NTK Scaling 保留位置索引但调低 RoPE frequencies；YaRN 按 wavelength 分段处理，兼顾局部和全局。
- Full attention 的 QK^T 是 $n \times n$ ，所以复杂度 $O(n^2)$ ；sparse attention 只算部分 pair 来省成本。
- Sliding window 看局部，dilated window 间隔看远处，global tokens 负责全局视野。
- Needle in the Haystack 测模型能否从长 haystack 取回 hidden needle；变量是 context length 和 needle depth。
- LongBench v2 比 Needle 更真实，覆盖长 QA、长 ICL、对话历史、代码库、结构化数据等任务。
- Lost in the Middle：相关信息在中间时表现下降；long window $\neq$ effective long-range reasoning, attention $\neq$ reasoning。

一段稳妥考场回答

Long-context modelling 是让模型能够处理、检索并推理非常长的输入或输出序列，现实动机包括长文档、代码库、法律材料、agent 历史和长推理过程；如果只能 retrieval、truncation 或 summarisation，就可能丢失关键信息。它的核心挑战有三类：第一，training data mismatch，大多数预训练数据较短，模型在更长位置上会遇到 distribution shift 和 positional generalization failure；第二，计算成本，标准 attention 为 $\text{softmax}(QK^T/\sqrt{d})V$ ，其中 QK^T 是 $n \times n$ matrix，所以 full attention 随序列长度呈 $O(n^2)$ 增长；第三，任务本身更难，模型即使支持长窗口，也可能找不到或用不好关键证据。位置编码是扩展长序列的关键：sinusoidal PE 用多频 sine/cosine 给位置 fixed fingerprint，但超出训练长度时不一定稳定；RoPE 则通过旋转 Q/K 把 position 编进 attention，使 relative distance 以 angle difference 形式出现，并保持向量长度。为了扩展 RoPE context，Position Interpolation 会把长位置缩放回预训练范围，NTK Scaling 调整旋转频率，YaRN 按 wavelength 分段插值以兼顾局部精度和全局跨度。计算上，Longformer 式 sparse attention 用 sliding window、dilated window 和 global tokens 避免所有 token pair 都计算，但存在效率与 attention quality 的 tradeoff。评价上，Needle in the Haystack 通过调节 context length 和 needle depth 测试模型能否访问长上下文中的关键事实，LongBench v2 用多任务长文本评测更接近真实理解。最后，Lost in the Middle 表明模型常更善用开头和结尾信息，中间证据表现下降，因此 long context window 不等于 effective long-range reasoning，attention 也不等于 reasoning。