


Retrieval Augmented Generation

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Retrieval Augmented Generation

Open-Domain QA 与 Retriever-Reader → Sparse Retrieval → Dense Retrieval → RAG 生成机制 → Hallucination 与 Attribution → RAG Taxonomy 与新方向

这节课一句话

这节课围绕“RAG 是什么？”：Retrieval-Augmented Generation 是让生成模型在回答前或回答中检索外部知识，并把检索到的证据作为条件生成答案。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Outline

Aim: Understand how machines learn to read texts and answer questions

- Recap
- Retriever-Reader Architecture
- Retrievers
- RAG
- Advanced RAG
- Summary

Reading:
- Jurafsky and Martin 3rd Edition pdf August 2025 [Chapter 11](#)


Alexandra Birch

ATNLP Week 5/ Lecture 14

2

原 PPT : Outline

Open Domain QA



Open-Domain Question Answering (ODQA):
We do not assume we are given a passage together with the question

We can only access a large collection of documents (e.g., Wikipedia) — we don't know which document contains the answer, and the goal is to answer any open-domain questions.

Both more challenging and more practical/useful!

Alexandra Birch


ATNLP Week 5/ Lecture 14

4

原 PPT : Open Domain QA

LLMs Can Do Open-Domain QA

LLMs — without an (explicit) retrieval component — can be used to solve Open-Domain Question Answering tasks; knowledge about the world is encoded in their parameters and activations, rather than in a corpus:



原 PPT : LLMs Can Do Open-Domain QA

2. 先抓住核心

这节课怎么入脑

这节课围绕“RAG 是什么？”：Retrieval-Augmented Generation 是让生成模型在回答前或回答中检索外部知识，并把检索到的证据作为条件生成答案。

考点问法：RAG 是什么？

人话版：Retrieval-Augmented Generation 是让生成模型在回答前或回答中检索外部知识，并把检索到的证据作为条件生成答案。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：RAG 为什么重要？

人话版：它把 LLM 的 parametric memory 和外部 non-parametric memory 结合起来，可提升事实性、更新性、可追溯性和长尾知识覆盖。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：RAG 与普通 closed-book LLM 的区别是什么？

人话版：closed-book LLM 只依赖参数中的知识；RAG 会显式访问文档库、网页、数据库或图结构等外部来源。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。


考点问法：RAG 与只把所有文档塞进 long context 的区别是什么？

人话版：RAG 先选择相关证据再生成，成本更低、更聚焦；long context 依赖模型在大量输入中自行定位信息。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：RAG 的基本模块有哪些？

人话版：通常包括 corpus/index、retriever、可选 reranker、generator/reader，以及 attribution 或 verification 模块。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Open-Domain QA 与 Retriever-R




原 PPT : Fusion in Decoder

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“Open-domain QA 是什么？”。考试版答案可以先说：给定自然语言问题，系统需要从大规模开放文档集合中找到答案，而不是只在给定 passage 内回答。进一步看，reading comprehension 通常给定 passage；open-domain QA 需要先检索相关 passage，再阅读并回答。

- 考点问法：Open-domain QA 是什么？。答题抓手：给定自然语言问题，系统需要从大规模开放文档集合中找到答案，而不是只在给定 passage 内回答。
- 考点问法：Open-domain QA 与 reading comprehension 的区别是什么？。答题抓手：reading comprehension 通常给定 passage；open-domain QA 需要先检索相关 passage，再阅读并回答。
- 考点问法：Retriever-reader pipeline 是什么？。答题抓手：retriever 从大语料库中选出 top-k 相关文档，reader/generator 基于这些文档生成或抽取答案。

4. Sparse Retrieval



原 PPT : Model NQ TriviaQA SQ

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“Sparse retrieval 是什么？”。考试版答案可以先说：用稀疏词项向量表示 query 和 document，并根据词项重叠计算相关性。进一步看，一个词在 query/document 中越频繁越重要，但如果它在所有文档中都常见，则区分度较低。

- 考点问法：Sparse retrieval 是什么？。答题抓手：用稀疏词项向量表示 query 和 document，并根据词项重叠计算相关性。
- 考点问法：TF-IDF 的核心直觉是什么？。答题抓手：一个词在 query/document 中越频繁越重要，但如果它在所有文档中都常见，则区分度较低。
- 考点问法：TF 表示什么？。答题抓手：Term frequency，表示某个词在文本中出现的频率或次数。

5. Dense Retrieval

LLMs and their Limitations

LLMs are Extremely Impressive —

- ✓ They can store vast amounts of knowledge in their parameters/activations
- ✓ Very strong results on many tasks, even in few-shot learning settings
- ✓ Very flexible — applicable on a variety of tasks


Input: List the top five US states with the highest per-capita GDP, in order.

Parametric LMs: Pre-trained on large-scale pre-training data

Input →

LM

Training corpus



Top five states are:

1. District of Columbia (DC)
2. New York
3. Massachusetts
4. ~~California~~
5. ~~Connecticut~~

- 1 Factual inaccuracies
- 2 Difficulty of verification
- 3 Difficulty of data opt-out
- 4 Expensive costs to adapt
- 5 Large model size

Figure from Asai et al. (2024). Reliable, Adaptable, and Attributable Language Models with Retrieval

Alexandra BirchATNLP Week 5/ Lecture 14School of Informatics


原 PPT : LLMs and their Limitations

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“Dense retrieval 是什么？”。考试版答案可以先说：用神经编码器把 query 和 passage 映射到 dense vectors，再用向量相似度检索。进一步看，因为相似语义可被映射到邻近向量，即使词面不完全重合也能检索到相关文档。

- 考点问法：Dense retrieval 是什么？。答题抓手：用神经编码器把 query 和 passage 映射到 dense vectors，再用向量相似度检索。
- 考点问法：Dense retrieval 为什么能处理语义匹配？。答题抓手：因为相似语义可被映射到邻近向量，即使词面不完全重合也能检索到相关文档。
- 考点问法：Bi-encoder 是什么？。答题抓手：query 和 passage 分别独立编码成向量，然后用 dot product 或 cosine similarity 打分。

6. RAG 生成机制




原 PPT : Retrieval Augmented Generation

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“RAG 中 non-parametric memory 指什么？”。考试版答案可以先说：外部文档库、数据库或知识源，不存储在模型参数中，可更新、可检索。进一步看，模型参数中学到的语言和世界知识。

- 考点问法：RAG 中 non-parametric memory 指什么？。答题抓手：外部文档库、数据库或知识源，不存储在模型参数中，可更新、可检索。
- 考点问法：RAG 中 parametric memory 指什么？。答题抓手：模型参数中学到的语言和世界知识。
- 考点问法：RAG 的经典概率思想是什么？。答题抓手：对多个检索文档作为 latent evidence 进行边缘化，让生成答案依赖可能相关的文档集合。

7. Hallucination 与 Attribution



原 PPT : Retriever-Reader Architecture

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“Hallucination 在 RAG 里指什么？”。考试版答案可以先说：生成内容与事实或检索证据不一致，或者凭空编造未被证据支持的信息。进一步看，它提供可检查的外部证据，让生成更受检索文档约束。

- 考点问法：Hallucination 在 RAG 里指什么？。答题抓手：生成内容与事实或检索证据不一致，或者凭空编造未被证据支持的信息。
- 考点问法：RAG 如何降低 hallucination？。答题抓手：它提供可检查的外部证据，让生成更受检索文档约束。
- 考点问法：Attribution 是什么？。答题抓手：为生成答案提供来源、引用或证据连接，说明答案中哪些内容由哪些文档支持。

8. RAG Taxonomy 与新方向

The Retriever-Reader Framework

Input: a large collection of documents $\mathcal{D} = \{D_1, \dots, D_n\}$ and a question Q

Output: an answer A retrieved from $P_1, \dots, P_k$

Retriever: $\text{retriever}(\mathcal{D}, Q) \rightarrow P_1, \dots, P_k$, where $k \in \mathbb{N}$ is pre-defined (e.g., 100)

Reader: $\text{reader}(Q, \{P_1, \dots, P_k\}) \rightarrow A$, similar to reading comprehension

An early retriever-reader system is **DrQA** [Chen et al., 2017]:

Retriever: a standard, “classic” TF-IDF information retrieval module (fixed)

Reader: a neural reading comprehension model, trained on SQuAD via distant supervision (i.e., by using retrieved paragraphs rather than gold ones)

Alexandra Birch ATNLP Week 5/ Lecture 14 School of Informatics 12

原 PPT : The Retriever-Reader Framework

人话直觉

RAG 像让模型开卷考试：模型不是只靠记忆硬答，而是先找资料，再把检索到的证据组织成答案。这部分的核心问题是“RAG taxonomy 可以从哪些维度看？”。考试版答案可以先说：检索粒度、证据如何融入模型、检索频率，以及是否使用多步/agent 流程。进一步看，检索单位的大小，例如 token、句子、段落、文档、表格行或图节点。

- 考点问法：RAG taxonomy 可以从哪些维度看？。答题抓手：检索粒度、证据如何融入模型、检索频率，以及是否使用多步/agent 流程。
- 考点问法：Retrieval granularity 是什么？。答题抓手：检索单位的大小，例如 token、句子、段落、文档、表格行或图节点。
- 考点问法：Evidence incorporation 是什么？。答题抓手：检索结果如何进入模型，例如拼接进 prompt、作为 encoder 输入、或通过 memory/cross-attention 使用。

- RAG 是什么？：Retrieval-Augmented Generation 是让生成模型在回答前或回答中检索外部知识，并把检索到的证据作为条件生成答案。
- RAG 为什么重要？：它把 LLM 的 parametric memory 和外部 non-parametric memory 结合起来，可提升事实性、更新性、可追溯性和长尾知识覆盖。
- RAG 与普通 closed-book LLM 的区别是什么？：closed-book LLM 只依赖参数中的知识；RAG 会显式访问文档库、网页、数据库或图结构等外部来源。
- RAG 与只把所有文档塞进 long context 的区别是什么？：RAG 先选择相关证据再生成，成本更低、更聚焦；long context 依赖模型在大量输入中自行定位信息。
- RAG 的基本模块有哪些？：通常包括 corpus/index、retriever、可选 reranker、generator/reader，以及 attribution 或 verification 模块。
- RAG 最适合解决哪类问题？：需要外部事实、领域知识、最新信息、长尾实体或可引用证据的问题。
- RAG 的基本风险是什么？：检索可能漏掉关键证据、取回错误证据，生成器也可能忽略证据或编造答案。
- RAG 的核心评价不只看什么？：不只看最终答案是否正确，还要看检索证据是否相关、是否支持答案、引用是否可靠。
- Open-domain QA 是什么？：给定自然语言问题，系统需要从大规模开放文档集合中找到答案，而不是只在给定 passage 内回答。
- Open-domain QA 与 reading comprehension 的区别是什么？：reading comprehension 通常给定 passage；open-domain QA 需要先检索相关 passage，再阅读并回答。

一段稳妥考场回答

RAG 是什么？：Retrieval-Augmented Generation 是让生成模型在回答前或回答中检索外部知识，并把检索到的证据作为条件生成答案。RAG 为什么重要？：它把 LLM 的 parametric memory 和外部 non-parametric memory 结合起来，可提升事实性、更新性、可追溯性和长尾知识覆盖。RAG 与普通 closed-book LLM 的区别是什么？：closed-book LLM 只依赖参数中的知识；RAG 会显式访问文档库、网页、数据库或图结构等外部来源。RAG 与只把所有文档塞进 long context 的区别是什么？：RAG 先选择相关证据再生成，成本更低、更聚焦；long context 依赖模型在大量输入中自行定位信息。