


Multilingual LLMs

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Multilingual LLMs

语言资源与数据不均衡 → 建模选择 → Tokenization → 数据质量与数据混合 → Scaling Laws
与 Transfer → 评测

这节课一句话

这节课围绕“为什么 multilingual LLM 重要？”：世界上大量用户不以英语为主要语言，多语言模型关系到公平、可及性、知识覆盖和跨语言迁移。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Promise of MLLMs

- Create AI systems that can operate across languages
 - providing AI for education/healthcare/etc. across the world: **fairness and inclusivity**
 - **commercial potential** - 6.5B people do not speak English
- **More efficient** - training and deploying one model instead of 100s, or even 1000s for cross lingual problems like machine translation
- **Transfer knowledge** between languages – improved performance for low resource languages
- **Deeper understanding** of generative AI models themselves
 - how do they access knowledge and reason across languages?

Alexandra Birch

ATNLP Week 5/ Lecture 15

School of
informatics

2

原 PPT : Promise of MLLMs

Language Resources

Class	5 Example Languages	#Langs	#Speakers	% of Total Langs
0	Dahalo, Warlpiri, Popoloca, Wallisian, Bora	2191	1.2B	88.38%
1	Cherokee, Fijian, Greenlandic, Bhojpuri, Navajo	222	30M	5.49%
2	Zulu, Konkani, Lao, Maltese, Irish	19	5.7M	0.36%
3	Indonesian, Ukrainian, Cebuano, Afrikaans, Hebrew	28	1.8B	4.42%
4	Russian, Hungarian, Vietnamese, Dutch, Korean	18	2.2B	1.07%
5	English, Spanish, German, Japanese, French	7	2.5B	0.28%

88.38% of languages have no labelled or unlabelled data resources!

Joshi et al. (2020) The State and Fate of Linguistic Diversity and Inclusion in the NLP World

Alexandra Birch

ATNLP Week 5/ Lecture 15

School of
informatics

4

原 PPT : Language Resources

How Multilingual Are Current Models?

Gemma 3

An open model featuring text and image input, support for over 140 languages, and a 128K context window.

Qwen3 models are supporting **119 languages and dialects**. This extensive multilingual capability opens up new possibilities for international applications, enabling users worldwide to benefit from the power of these models.

Claude excels at tasks across multiple languages, maintaining strong cross-lingual performance relative to English.

?

原 PPT : How Multilingual Are Current Models?

2. 先抓住核心

这节课怎么入脑

这节课围绕“为什么 multilingual LLM 重要？”：世界上大量用户不以英语为主要语言，多语言模型关系到公平、可及性、知识覆盖和跨语言迁移。

考点问法：为什么 multilingual LLM 重要？

人话版：世界上大量用户不以英语为主要语言，多语言模型关系到公平、可及性、知识覆盖和跨语言迁移。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Multilingual LLM 的核心目标是什么？

人话版：让一个模型能理解、生成并推理多种语言，同时尽量在高资源和低资源语言上都保持质量。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么“只做英语模型”是不够的？

人话版：它会排除大量非英语用户，并把模型能力、知识和安全保障集中在少数高资源语言上。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：多语言模型相比每种语言单独训练模型有什么优势？

人话版：共享参数可降低成本，并让高资源语言的知识 and 能力迁移到低资源语言。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：多语言模型的主要挑战有哪些？

人话版：数据不均衡、tokenization 不公平、跨语言 transfer/interference、评测困难，以及文化和安全差异。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. 语言资源与数据不均衡

How Multilingual Are Current Models?

Natalia sold clips to 48 of her friends in April, and then she sold half as many clips in May. How many clips did Natalia sell altogether in April and May?

Let me work through this step by step.

April: Natalia sold clips to 48 friends

May: She sold half as many clips as in April

- Half of 48 = $48 \div 2 = 24$ clips

Total for April and May: $48 + 24 = 72$ clips

Natalia sold 72 clips altogether in April and May.

GSM8k math problems – most frontier models do really well – Claude 4.5

Alexandra BirchATNLP Week 5/ Lecture 15School of Informatics

原 PPT : How Multilingual Are Current Models?


人话直觉

把这一部分当成从“为什么要做”到“怎么做、哪里会失败、考试怎么问”的一段链条；先抓住动机，再抓住机制。这部分的核心问题是“为什么语言资源分布是多语言 NLP 的根本问题？”。考试版答案可以先说：大多数语言缺少足够的标注数据、未标注文本、工具链和评测集。进一步看，大量语言没有足够 labelled 或 unlabelled resources，因此难以直接训练和评测。

- 考点问法：为什么语言资源分布是多语言 NLP 的根本问题？。答题抓手：大多数语言缺少足够的标注数据、未标注文本、工具链和评测集。
- 考点问法：讲义中提到大量语言缺少什么？。答题抓手：大量语言没有足够 labelled 或 unlabelled resources，因此难以直接训练和评测。
- 考点问法：High-resource language 是什么？。答题抓手：拥有大量文本、标注数据、工具和 benchmark 的语言，如英语、西班牙语、中文等。

4. 建模选择

How Multilingual Are Current Models?



Natalia vendió clips a 48 de sus amigos en abril y luego vendió la mitad en mayo. ¿Cuántos clips vendió Natalia en total entre abril y mayo?

Voy a resolver este problema paso a paso.

Datos:

- Abril: Natalia vendió 48 clips
- Mayo: vendió la mitad de lo que vendió en abril

Cálculo:

- Clips vendidos en mayo = $48 \div 2 = 24$ clips
- Total de clips vendidos = $48 + 24 = 72$ clips

Respuesta: Natalia vendió 72 clips en total entre abril y mayo.

Spanish – many models work well for high resource languages

Alexandra Birch ATNLP Week 5/ Lecture 15 School of Informatics 7

原 PPT : How Multilingual Are Current Models?

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“多语言模型设计要决定哪些组件是否共享？”。考试版答案可以先说：词表、embedding、encoder/decoder、attention layers、任务头和语言特定参数都可能共享或拆分。进一步看，可能使用语言特定 embedding、encoder/decoder 或输出头，以减轻语言差异带来的冲突。

- 考点问法：多语言模型设计要决定哪些组件是否共享？。答题抓手：词表、embedding、encoder/decoder、attention layers、任务头和语言特定参数都可能共享或拆分。
- 考点问法：早期多语言模型常使用什么语言特定设计？。答题抓手：可能使用语言特定 embedding、encoder/decoder 或输出头，以减轻语言差异带来的冲突。
- 考点问法：当前大模型通常采用什么共享策略？。答题抓手：多数现代 LLM 共享几乎全部参数，只通过数据、tokenizer 和 prompt 控制语言行为。

5. Tokenization

How Multilingual Are Current Models?

UNatalia wathengisa ama-clip kubangani bakhe abangu-48 ngo-Ephreli, wabe esethengisa ama-clip ayingxenywe yalawo ngoMeyi. Zingaki iziqephu uNatalia azithengisa sezizonke ngo-Ephreli nangoMeyi?

Nginyaxolisa, kodwa ngidinga ulwazi olwengeziwe ukuze ngisizo kulomsebenzi wezibalo.

Ngiyazi ukuthi uNatalia wathengisa ama-clip angu-48 ngo-Ephreli, kodwa akukho lwazi olunikeziwe mayelana nokuthi mangaki ama-clip awathengisa ngoMeyi. Umbuzo uthi "wathengisa ama-clip ayingxenywe yalawo ngoMeyi" kepha akucaci ukuthi yingxenywe kangakanani leyo.

Ukuze ngikwazi ukubala inani eliphelele lama-clip awathengisa ngo-Ephreli nangoMeyi, ngidinga ukwazi:

- Mangaki ama-clip awathengisa ngoMeyi? (isib. ingxenywe, noma inombolo ethile)

Ungakwazi yini ukunginika leli lwazi elengeziwe?

Zulu – Claude struggles

Alexandra BirchATNLP Week 5/ Lecture 15School of informatics 8

原 PPT : How Multilingual Are Current Models?

人话直觉

把 tokenizer 想成模型量文本的尺子：尺子偏向哪种语言，哪种语言就更便宜、更顺手；被切得很碎的语言会付出更多 context 和训练预算。这部分的核心问题是“Tokenization 为什么会影响多语言公平性？”。考试版答案可以先说：同样一句话在不同语言中可能被切成不同数量 tokens，影响训练成本、上下文长度和生成质量。进一步看，把词拆成常见子词单位，在词级和字符级之间折中，既能处理常见词也能处理新词。

- 考点问法：Tokenization 为什么会影响多语言公平性？。答题抓手：同样一句话在不同语言中可能被切成不同数量 tokens，影响训练成本、上下文长度和生成质量。
- 考点问法：Subword tokenizer 的基本思想是什么？。答题抓手：把词拆成常见子词单位，在词级和字符级之间折中，既能处理常见词也能处理新词。
- 考点问法：多语言 tokenizer 的困难是什么？。答题抓手：优化一种语言的切分可能损害另一种语言；不同脚本、形态和空格习惯差异很大。

6. 数据质量与数据混合

How Multilingual Are Current Models?

1. Thola inani langoMeyi
Umbuzo uthi ngoMeyi uthengise **yingxenye** (half) yalawo awathengise ngo-Ephreli (48).

$$48 \div 2 = 24$$

Ngakho-ke, uthengise ama-clip angu-**24** ngoMeyi.

2. Thola inani selilonke
Manje, hlanganisa amanani ezinyanga zombili:

- Ephreli: 48
- Meyi: 24

$$48 + 24 = 72$$

Zulu – Gemini 3 does much better

Alexandra Birch ATNLP Week 5/ Lecture 15 School of Informatics 9

原 PPT : How Multilingual Are Current Models?

人话直觉

把这一部分当成从“为什么要做”到“怎么做、哪里会失败、考试怎么问”的一段链条；先抓住动机，再抓住机制。这部分的核心问题是“多语言语料常见噪声有哪些？”。考试版答案可以先说：错误语言、机器翻译噪声、乱码、模板文本、重复内容、错配句对和非自然语言内容。进一步看，文本语言和内容符合预期，可作为有效训练样本。

- 考点问法：多语言语料常见噪声有哪些？。答题抓手：错误语言、机器翻译噪声、乱码、模板文本、重复内容、错配句对和非自然语言内容。
- 考点问法：数据质量标签中 correct 表示什么？。答题抓手：文本语言和内容符合预期，可作为有效训练样本。
- 考点问法：Wrong language 表示什么？。答题抓手：样本被归到某语言，但实际是另一种语言。

7. Scaling Laws 与 Transfer

Challenges

- **Imbalance of data** there will always be a vast difference in quality and quantity of different language data
- Positive transfer vs **negative interference**
- **Effort and cost**: collecting data, tokenisation, pre and post- training, evaluation
- **Evaluation** creating meaningful and high quality evaluations that address cultural differences

Alexandra Birch

ATNLP Week 5/ Lecture 15

School of
informatics

10

原 PPT : Challenges

人话直觉

把这一部分当成从“为什么要做”到“怎么做、哪里会失败、考试怎么问”的一段链条；先抓住动机，再抓住机制。这部分的核心问题是“ATLAS 研究关注什么？”。考试版答案可以先说：关注 multilingual scaling laws，研究模型规模、数据、语言数量和跨语言迁移如何共同影响表现。进一步看，目标语言表现不仅取决于本语言数据，还取决于相似语言和其他语言带来的正负迁移。

- 考点问法：ATLAS 研究关注什么？。答题抓手：关注 multilingual scaling laws，研究模型规模、数据、语言数量和跨语言迁移如何共同影响表现。
- 考点问法：Adaptive transfer law 的核心思想是什么？。答题抓手：目标语言表现不仅取决于本语言数据，还取决于相似语言和其他语言带来的正负迁移。
- 考点问法：Transfer matrix 表示什么？。答题抓手：表示一种语言的训练数据对另一种语言表现的影响，可包含 positive transfer 和 negative interference。

8. 评测

Number and diversity of languages

How many languages are you going to cover, and which ones?

English First with emergent multilingual abilities:

- GPT2, 3 – Contamination of English with other languages (see Blevins and Zettlemoyer 2022 **Language Contamination Helps Explain the Cross-lingual Capabilities of English Pretrained Models**)
- Llama 1,2,3 mainly English training data (90+) but with increasing multilingual performance

Bilingual models eg. Chinese and English:

- Qwen, Deepseek

Multilingual Focus:

- BLOOM 2022 – open science landmark 46 natural languages, 13 programming languages
- Glot 500 2023 – 500 languages many low resource
- EuroLLM 2024 – All European languages + 11 others

Multilingual extensions:

- Aya 23 -> Aya Expans 101
- Qwen 2 29 languages -> Qwen3 119 languages and dialects,

How much engineering and compute do you have?

Alexandra Birch ATNLP Week 5/ Lecture 15 School of Informatics 15

原 PPT : Number and diversity of languages

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“多语言评测为什么困难？”。考试版答案可以先说：不同语言数据质量、文化背景、任务难度和翻译等价性都可能不同。进一步看，翻译可能不自然、不等价或泄露英语中心内容，不能代表真实语言使用。

- 考点问法：多语言评测为什么困难？。答题抓手：不同语言数据质量、文化背景、任务难度和翻译等价性都可能不同。
- 考点问法：机器翻译 benchmark 的问题是什么？。答题抓手：翻译可能不自然、不等价或泄露英语中心内容，不能代表真实语言使用。
- 考点问法：为什么需要专家验证多语言 benchmark？。答题抓手：只有熟悉语言和文化的人才能判断题目是否自然、正确、公平。

- 为什么 multilingual LLM 重要？：世界上大量用户不以英语为主要语言，多语言模型关系到公平、可及性、知识覆盖和跨语言迁移。
- Multilingual LLM 的核心目标是什么？：让一个模型能理解、生成并推理多种语言，同时尽量在高资源和低资源语言上都保持质量。
- 为什么“只做英语模型”是不够的？：它会排除大量非英语用户，并把模型能力、知识和安全保障集中在少数高资源语言上。
- 多语言模型相比每种语言单独训练模型有什么优势？：共享参数可降低成本，并让高资源语言的知识 and 能力迁移到低资源语言。
- 多语言模型的主要挑战有哪些？：数据不均衡、tokenization 不公平、跨语言 transfer/interference、评测困难，以及文化和安全差异。
- Positive transfer 是什么？：一种语言的训练帮助另一种语言提升表现，常发生在相近语言、共享脚本或共享任务结构之间。
- Negative interference 是什么？：多语言共享模型时，一种语言或任务的学习损害另一种语言表现。
- Curse of multilinguality 是什么？：语言数量增加后，固定模型容量和训练预算被更多语言共享，单个语言可能得到更少资源，表现下降。
- 为什么语言资源分布是多语言 NLP 的根本问题？：大多数语言缺少足够的标注数据、未标注文本、工具链和评测集。
- 讲义中提到大量语言缺少什么？：大量语言没有足够 labelled 或 unlabelled resources，因此难以直接训练和评测。

一段稳妥考场回答

为什么 multilingual LLM 重要？：世界上大量用户不以英语为主要语言，多语言模型关系到公平、可及性、知识覆盖和跨语言迁移。Multilingual LLM 的核心目标是什么？：让一个模型能理解、生成并推理多种语言，同时尽量在高资源和低资源语言上都保持质量。为什么“只做英语模型”是不够的？：它会排除大量非英语用户，并把模型能力、知识和安全保障集中在少数高资源语言上。多语言模型相比每种语言单独训练模型有什么优势？：共享参数可降低成本，并让高资源语言的知识 and 能力迁移到低资源语言。