


Safety and Security with LLMs

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Safety and Security with LLMs


Watermarking 算法 → Watermark 识别与局限 → Threat Types 与 Illicit Content → Adversarial Suffix Attacks → Safety/Security Tradeoffs → 考前作答模板

这节课一句话

这节课围绕“Safety 和 security 的区别是什么？”：Safety 关注系统不会造成伤害；security 关注系统不被恶意利用、攻击或绕过。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。



原 PPT : What is the difference between safety and security?



原 PPT : What is the difference between safety and security?

Different types of security

- Trying to extract information from the neural representations
- Trying to detect parts of the training set (membership attacks)
- Trying to distill a new model from bigger models, making big companies vulnerable to “model theft”
- Trying to make an LLM output something that is not allowed
- Trying to use LLMs for unpermitted purposes (disinformation, essay writing...)
- Trying to poison training data

Each one of these questions is a rich domain for research!

Food for thought: Think of this as a relation. Who is the attacker and who is the entity being attacked? They are not all the same here.

原 PPT : Different types of security

2. 先抓住核心

这节课怎么入脑

这节课围绕“Safety 和 security 的区别是什么？”：Safety 关注系统不会造成伤害；security 关注系统不被恶意利用、攻击或绕过。

考点问法：Safety 和 security 的区别是什么？

人话版：Safety 关注系统不会造成伤害；security 关注系统不被恶意利用、攻击或绕过。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：LLM safety 关注哪些问题？

人话版：有害内容、偏见、错误信息、隐私泄露、危险建议和不符合人类意图的行为。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：LLM security 关注哪些问题？

人话版：prompt injection、jailbreak、data exfiltration、模型滥用、水印规避和系统被攻击者操纵等。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：为什么 safety 与 security 会重叠？

人话版：攻击者常通过 security 漏洞绕过 safety guardrails，从而诱导模型产生有害输出。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：本讲可考部分主要关注哪些方向？

人话版：watermarking、illicit content prevention、adversarial suffix attacks 和 jailbreak transfer。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Watermarking 算法

Different types of safety

- Hallucination causing a severe unintended consequence
- Decision making that unintentionally goes wrong
- Doomsday predictions (security or safety?) or generally, misalignment with human values, or goals

Partially addressed through verification, understanding the models, policies, regulations and laws...

Shay Cohen

ATNLP Lecture 20

4/27

原 PPT : Different types of safety

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“Watermarking 在 decoding 时如何工作？”。考试版答案可以先说：根据前文和密钥把词表划分为 green list 与 red list，并提高 green tokens 的采样概率。进一步看，在某一步生成中被 watermark 算法偏好的 tokens 集合。

- 考点问法：Watermarking 在 decoding 时如何工作？。答题抓手：根据前文和密钥把词表划分为 green list 与 red list，并提高 green tokens 的采样概率。
- 考点问法：Green list 是什么？。答题抓手：在某一步生成中被 watermark 算法偏好的 tokens 集合。
- 考点问法：Red list 是什么？。答题抓手：相对不被 watermark 偏好的 tokens 集合。

4. Watermark 识别与局限

Our Focus Today

- We will focus mostly on intentional misuse of LLMs today
- We will actually study two very specific test cases: identifying LLM text and using LLMs to provide harmful information
- We partially tackled notion of safety in Lecture 16 (mechanistic interpretability)

Word of Caution: Safety and security is a *huge* area – this is the tip (of the tip) of the iceberg.

Shay Cohen

ATNLP Lecture 20

5/27

原 PPT : Our Focus Today

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“Watermark detection 的 false positive 是什么？”。考试版答案可以先说：人类或无水印文本被误判为 watermarked。进一步看，有水印文本没有被检测出来。

- 考点问法：Watermark detection 的 false positive 是什么？。答题抓手：人类或无水印文本被误判为 watermarked。
- 考点问法：Watermark detection 的 false negative 是什么？。答题抓手：有水印文本没有被检测出来。
- 考点问法：为什么 paraphrasing 会削弱 watermark？。答题抓手：改写会替换 tokens，破坏原生成过程嵌入的 green token 统计模式。

5. Threat Types 与 Illicit Conte

Watermarking (Kirchenbauer et al., 2023)

From Kirchenbauer et al.:

In this work, we study watermarking of language model output. A watermark is a hidden pattern in text that is imperceptible to humans, while making the text algorithmically identifiable as synthetic.

Shay Cohen

ATNLP Lecture 20

6/27

原 PPT : Watermarking (Kirchenbauer et al., 2023)

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“LLM security concerns 可以包括哪些？”。考试版答案可以先说：恶意提示、越狱、隐私泄露、自动化滥用、模型复制、输出伪造和检测规避。进一步看，攻击者诱导模型生成违法、危险或平台禁止的内容。

- 考点问法：LLM security concerns 可以包括哪些？。答题抓手：恶意提示、越狱、隐私泄露、自动化滥用、模型复制、输出伪造和检测规避。
- 考点问法：Illicit content attack 是什么？。答题抓手：攻击者诱导模型生成违法、危险或平台禁止的内容。
- 考点问法：为什么 illicit content prevention 很难？。答题抓手：同一知识可有良性和恶意用途，攻击者还能用改写、角色扮演或编码绕过规则。

6. Adversarial Suffix Attacks

Watermarking (Kirchenbauer et al., 2023)

Basic algorithm:

- Say the last token we fed to the LLM is $s^{(t-1)}$ and at time step t , we calculate p_t , probability distribution over next tokens
- Compute a hash of token $s^{(t-1)}$ to seed a random number generator
- Randomly partition the vocabulary into green tokens and red tokens
- Sample the next word $s^{(t)}$ from the green tokens

Shay Cohen

ATNLP Lecture 20

7/27

原 PPT : Watermarking (Kirchenbauer et al., 2023)

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“Zou et al. adversarial suffix attack 的目标是什么？”。考试版答案可以先说：寻找一段可附加到恶意请求后的 suffix，使模型更可能服从并生成有害内容。进一步看，suffix 可能通用、自动化搜索得到，并能迁移到多个模型。

- 考点问法：Zou et al. adversarial suffix attack 的目标是什么？。答题抓手：寻找一段可附加到恶意请求后的 suffix，使模型更可能服从并生成有害内容。
- 考点问法：为什么 adversarial suffix attack 很危险？。答题抓手：suffix 可能通用、自动化搜索得到，并能迁移到多个模型。
- 考点问法：Positive affirmation objective 是什么？。答题抓手：优化 suffix 使模型输出以肯定服从的开头开始，例如倾向于回答“Sure, here is...”而不是拒绝。

7. Safety/Security Tradeoffs

Watermarking - example			
Prompt	Num tokens	Z-score	p-value
...The watermark detection algorithm can be made public, enabling third parties (e.g., social media platforms) to run it themselves, or it can be kept private and run behind an API. We seek a watermark with the following properties:			
No watermark Extremely efficient on average term lengths and word frequencies on synthetic, microamount text (as little as 25 words) Very small and low-resource key/hash (e.g., 140 bits per key is sufficient for 99.99999999% of the Synthetic Internet)	56	.31	.38
With watermark - minimal marginal probability for a detection attempt. - Good speech frequency and energy rate reduction. - messages indiscernible to humans. - easy for humans to verify.	36	7.4	6e-14

Shay Cohen ATNLP Lecture 20 8/27


原 PPT : Watermarking - example

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“为什么 safety 不能只靠训练数据过滤？”。考试版答案可以先说：模型可组合知识，攻击者可绕过过滤，且许多风险出现在部署交互中。进一步看，filter 可能漏检、误检，且模型内部仍可能具备危险能力。

- 考点问法：为什么 safety 不能只靠训练数据过滤？。答题抓手：模型可组合知识，攻击者可绕过过滤，且许多风险出现在部署交互中。
- 考点问法：为什么 safety 不能只靠 inference-time filter？。答题抓手：filter 可能漏检、误检，且模型内部仍可能具备危险能力。
- 考点问法：多层防御是什么意思？。答题抓手：结合数据治理、训练对齐、系统提示、分类器、工具权限、监控、水印和红队测试。

8. 考前作答模板



原 PPT : How do we recognise a watermark?

人话直觉

安全不是给英语模型贴一张多语言标签；不同语言和文化里的风险表达不同，防护也必须跟着跨语言迁移。这部分的核心问题是“如果考“safety vs security”，应该怎么答？”。考试版答案可以先说：safety 是避免伤害，security 是防止被攻击或滥用；二者相互影响，jailbreak 就是 security failure 导致 safety failure。进一步看，生成时用密钥把词表分成 green/red list，提高 green tokens 概率；检测时统计 green token 比例是否显著偏高。

- 考点问法：如果考“safety vs security”，应该怎么答？。答题抓手：safety 是避免伤害，security 是防止被攻击或滥用；二者相互影响，jailbreak 就是 security failure 导致 safety failure。
- 考点问法：如果考“LLM watermarking”，应该怎么答？。答题抓手：生成时用密钥把词表分成 green/red list，提高 green tokens 概率；检测时统计 green token 比例是否显著偏高。
- 考点问法：如果考“watermark 的局限”，应该怎么答？。答题抓手：短文本统计弱，改写/翻译/编辑会破坏信号，key 泄露会被伪造或规避，且 watermark 不能阻止有害内容。

考试速记版

- Safety 和 security 的区别是什么？：Safety 关注系统不会造成伤害；security 关注系统不被恶意利用、攻击或绕过。
- LLM safety 关注哪些问题？：有害内容、偏见、错误信息、隐私泄露、危险建议和不符合人类意图的行为。
- LLM security 关注哪些问题？：prompt injection、jailbreak、data exfiltration、模型滥用、水印规避和系统被攻击者操纵等。
- 为什么 safety 与 security 会重叠？：攻击者常通过 security 漏洞绕过 safety guardrails，从而诱导模型产生有害输出。
- 本讲可考部分主要关注哪些方向？：watermarking、illicit content prevention、adversarial suffix attacks 和 jailbreak transfer。
- 为什么 LLM 输出来源识别重要？：识别 AI-generated text 有助于检测滥用、学术诚信问题、垃圾内容和虚假信息传播。
- Watermarking 的核心思想是什么？：在生成文本时嵌入统计上可检测的模式，使检测器能判断文本是否可能由某模型生成。
- LLM watermark 为什么不能像图片水印一样直接嵌入不可见标记？：文本是离散符号，微小改动会改变含义或流畅度，因此通常只能嵌入统计偏好。
- Watermarking 在 decoding 时如何工作？：根据前文和密钥把词表划分为 green list 与 red list，并提高 green tokens 的采样概率。
- Green list 是什么？：在某一步生成中被 watermark 算法偏好的 tokens 集合。

一段稳妥考场回答

Safety 和 security 的区别是什么？：Safety 关注系统不会造成伤害；security 关注系统不被恶意利用、攻击或绕过。LLM safety 关注哪些问题？：有害内容、偏见、错误信息、隐私泄露、危险建议和不符合人类意图的行为。LLM security 关注哪些问题？：prompt injection、jailbreak、data exfiltration、模型滥用、水印规避和系统被攻击者操纵等。为什么 safety 与 security 会重叠？：攻击者常通过 security 漏洞绕过 safety guardrails，从而诱导模型产生有害输出。