


Slides created from material by Desmond Elliott and Raquel Fernandez

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Slides created from material by Desmond Elliott and Raquel Fernandez

Grounding 与 Symbol Grounding → Experience Grounds Language 与 World Scopes → VLM Tasks 与数据集 → 视觉表示与模型设计 → Training Objectives → Evaluation

这节课一句话

这节课围绕“Multimodal AI 是什么？”：Multimodal AI 通过机器学习整合多种数据类型，例如文本、图像、音频或视频，以提升理解、预测和决策。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Outline

Aim: Understand why we need Multimodal Models and what are the main design choices that we need to make to design them

Outline:

- Historical background on Perceptually Grounded NLP
- Vision and Language Models as an implementation of Multimodal Models
 - Input data
 - Model design
 - Training regimes
- Evaluating Vision and Language Models

Alessandro Suglia

ATNLP Week 9/ Lecture 25

School of
informatics

2

原 PPT : Outline

Symbol Grounding Problem

How can the meanings of the **meaningless symbol tokens**, manipulated solely on the basis of their (arbitrary) **shapes**, be grounded in anything but other **meaningless symbols**?

Harad, Stevan. "The symbol grounding problem." *Physica D: Nonlinear Phenomena* 42.1-3 (1990): 335-346.

Alessandro Suglia

ATNLP Week 9/ Lecture 25


School of
informatics

6

原 PPT : Symbol Grounding Problem

Perceptually Grounded Natural Language Processing

- To be **grounded** the symbol system would have to be able to **pick out** the **referents of its symbols** and its **sensorimotor interactions** with the world would have to fit coherently with the **symbols' interpretations**.
- Meaning is multimodal!



Ogden, C. K., & Richards, I. A. (1930). The Meaning of Meaning: A Study of the Influence of Language upon Thought and of the Science of Symbolism. Harcourt, Brace.

Alessandro Suglia

ATNLP Week 9/ Lecture 25

School of
informatics

8

原 PPT : Perceptually Grounded Natural Language Processing

2. 先抓住核心

这节课怎么入脑

这节课围绕“Multimodal AI 是什么？”：Multimodal AI 通过机器学习整合多种数据类型，例如文本、图像、音频或视频，以提升理解、预测和决策。

考点问法：Multimodal AI 是什么？

人话版：Multimodal AI 通过机器学习整合多种数据类型，例如文本、图像、音频或视频，以提升理解、预测和决策。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：本讲主要关注哪两种模态？

人话版：从 NLP 角度关注 language 和 vision 的结合，即 Vision+Language Models。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Vision+Language Model 是什么？

人话版：VLM 整合视觉和语言数据，使模型能基于图像和文本完成理解、生成和决策任务。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。


考点问法：为什么需要 multimodal models？

人话版：语言意义不只来自文本，现实理解依赖视觉、动作、社会互动和环境经验。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Text-only representation 的局限是什么？

人话版：它只能从文本共现中学习意义，无法直接接触感知世界、物体属性和行动后果。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Grounding 与 Symbol Grounding



原 PPT : Evidence in favour of Multimodal/Grounded NLP

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“Grounding 在 communication 中是什么意思？”。考试版答案可以先说：指对话双方共享的 mutual knowledge、beliefs 和 assumptions，使交流得以成功。进一步看，如果符号只通过其他符号定义，符号意义如何最终连接到现实世界或感知经验。

- 考点问法：Grounding 在 communication 中是什么意思？。答题抓手：指对话双方共享的 mutual knowledge、beliefs 和 assumptions，使交流得以成功。
- 考点问法：Symbol grounding problem 是什么？。答题抓手：如果符号只通过其他符号定义，符号意义如何最终连接到现实世界或感知经验。
- 考点问法：Chinese Room argument 想说明什么？。答题抓手：仅按规则操作符号不一定等于真正理解符号意义。

4. Experience Grounds Language

Limits of text-based language representations

- In previous lectures, you've learned that current NLP approaches learn the meaning of words from text only.
- But this contradicts the theoretical evidence discussed in this lecture and raises a few important questions:
 1. What are the limits of text-based representations?
 2. Should we be learning this way?
 3. Is it data-efficient/effective?
 4. Why should models learn this way, but not humans?

Alessandro Suglia

ATNLP Week 9/ Lecture 25

School of
informatics

10

原 PPT : Limits of text-based language representations

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“Experience Grounds Language 的核心观点是什么？”。考试版答案可以先说：语言学习依赖学习者可访问的世界经验，不同 world scope 提供不同数据和能力。进一步看，描述学习者能访问的数据和环境范围，例如只读文本、看图像、能行动、能与人合作等。

- 考点问法：Experience Grounds Language 的核心观点是什么？。答题抓手：语言学习依赖学习者可访问的世界经验，不同 world scope 提供不同数据和能力。
- 考点问法：World scope 是什么？。答题抓手：描述学习者能访问的数据和环境范围，例如只读文本、看图像、能行动、能与人合作等。
- 考点问法：“不能从 radio/Internet 学语言”在讲义中是什么意思？。答题抓手：如果任务可在无感知条件下完成，就不能说明学习者已进入需要视觉或听觉的更高 world scope。

5. VLM Tasks 与数据集

LLM's answer to this problem

- We can just **increase** data and model size to get better models
- When trained with specific types of data (e.g., instructions), they can perform complex NLP tasks such as question answering
- However, they are trained with **trillions of tokens** making them extremely inefficient learners
 - What can we do to improve on this?

Alessandro Suglia

ATNLP Week 9/ Lecture 25

School of
informatics

11


原 PPT : LLM's answer to this problem

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“VLM 常见任务有哪些？”。考试版答案可以先说：image captioning、visual question answering、visual grounding、referring expression、visual storytelling 和 visual dialogue。进一步看，给定图像，模型生成描述图像内容的自然语言句子。

- 考点问法：VLM 常见任务有哪些？。答题抓手：image captioning、visual question answering、visual grounding、referring expression、visual storytelling 和 visual dialogue。
- 考点问法：Image captioning 是什么？。答题抓手：给定图像，模型生成描述图像内容的自然语言句子。
- 考点问法：早期 image captioning 模型如何工作？。答题抓手：用 CNN 提取图像表示，并用该表示初始化 RNN language model 的 hidden state。

6. 视觉表示与模型设计




原 PPT : Experience Grounds Language

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“早期视觉信息如何表示？”。考试版答案可以先说：早期使用 symbolic features；后来转向通过 computer vision 自动学习视觉表示。进一步看，从像素中学习局部和层级特征，生成 feature maps 或 pooled features。

- 考点问法：早期视觉信息如何表示？。答题抓手：早期使用 symbolic features；后来转向通过 computer vision 自动学习视觉表示。
- 考点问法：CNN 在视觉表示中做什么？。答题抓手：从像素中学习局部和层级特征，生成 feature maps 或 pooled features。
- 考点问法：Vision Transformer 的基本思想是什么？。答题抓手：把图像切成 patches，把每个 patch 当作 token，用 Transformer 处理视觉序列。

7. Training Objectives




原 PPT : Multimodal Artificial Intelligence

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“Masked Image Modelling 是什么？”。考试版答案可以先说：随机遮蔽图像 patches，让模型重构视觉表示或像素/feature。进一步看，经典 next-token prediction 或 masked language modelling，用于学习语言生成或理解。

- 考点问法：Masked Image Modelling 是什么？。答题抓手：随机遮蔽图像 patches，让模型重构视觉表示或像素/feature。
- 考点问法：Language Modelling loss 是什么？。答题抓手：经典 next-token prediction 或 masked language modelling，用于学习语言生成或理解。
- 考点问法：Image-Text Matching 是什么？。答题抓手：给定图像和 caption，判断二者是否匹配的二分类任务。

8. Evaluation



原 PPT : Experience Grounds Language

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“Extrinsic evaluation 是什么？”。考试版答案可以先说：用具体下游任务或应用数据集评价 VLM 表现。进一步看，指标明确、能力聚焦、与具体应用直接相关。

- 考点问法：Extrinsic evaluation 是什么？。答题抓手：用具体下游任务或应用数据集评价 VLM 表现。
- 考点问法：Task-specific evaluation 的优点是什么？。答题抓手：指标明确、能力聚焦、与具体应用直接相关。
- 考点问法：Task-specific evaluation 的局限是什么？。答题抓手：结果不一定能迁移到其他任务或表示质量。

考试速记版

- Multimodal AI 是什么？：Multimodal AI 通过机器学习整合多种数据类型，例如文本、图像、音频或视频，以提升理解、预测和决策。
- 本讲主要关注哪两种模态？：从 NLP 角度关注 language 和 vision 的结合，即 Vision+Language Models。
- Vision+Language Model 是什么？：VLM 整合视觉和语言数据，使模型能基于图像和文本完成理解、生成和决策任务。
- 为什么需要 multimodal models？：语言意义不只来自文本，现实理解依赖视觉、动作、社会互动和环境经验。
- Text-only representation 的局限是什么？：它只能从文本共现中学习意义，无法直接接触感知世界、物体属性和行动后果。
- “Meaning is multimodal” 是什么意思？：词义与视觉、动作、感知、社会互动等多种经验相关，而不只是符号之间的关系。
- 为什么简单扩大 LLM 数据和规模不完全解决 grounding 问题？：规模能提升文本能力，但学习仍主要来自符号文本，效率低且缺少直接感知信号。
- VLM 的核心承诺是什么？：把语言和视觉对齐，让模型获得更接近感知世界的表示与推理能力。
- Grounding 在 communication 中是什么意思？：指对话双方共享的 mutual knowledge、beliefs 和 assumptions，使交流得以成功。
- Symbol grounding problem 是什么？：如果符号只通过其他符号定义，符号意义如何最终连接到现实世界或感知经验。

一段稳妥考场回答

Multimodal AI 是什么？：Multimodal AI 通过机器学习整合多种数据类型，例如文本、图像、音频或视频，以提升理解、预测和决策。本讲主要关注哪两种模态？：从 NLP 角度关注 language 和 vision 的结合，即 Vision+Language Models。Vision+Language Model 是什么？：VLM 整合视觉和语言数据，使模型能基于图像和文本完成理解、生成和决策任务。为什么需要 multimodal models？：语言意义不只来自文本，现实理解依赖视觉、动作、社会互动和环境经验。