


Multimodal Generative AI Models

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。



原 PPT : Multimodal Generative AI Models

Visual Encoder → Projector 与训练目标 → SmolVLM 架构 → SmolVLM 训练阶段 → Evaluation 与结果 → Future Research

这节课一句话

这节课围绕“本讲的核心目标是什么？”：理解 frontier VLM 如何设计、实现和训练，尤其是 visual prefix-based VLM。

1. 原 PPT 主线

先把这几页当作地图：标题页告诉我们主题，outline 或 challenge 页告诉我们为什么这节课存在，后面的模型、数据或评测页则给出考试最容易追问的细节。读这类 lecture 时，不要急着背术语，先问三件事：它要解决什么问题，提出了什么机制，哪里会失败。

Outline

Aim: Understand how frontier VLMs are designed, implemented and trained

Outline:

- Recap of why we care about Perceptually-grounded NLP models
- Training pipeline for VLMs
- SmolVLM: Deep-dive into Visual prefix VLMs
- An overview of the SOTA open weights ecosystem
- Future avenues on VLM research

Alessandro Suglia

ATNLP Week 9 / Lecture 26


School of Informatics

2

原 PPT : Outline

Recap: Evidence in favour of Multimodal/Grounded NLP

a Movement



b Passive reading of action words



Pulvermüller, F. (2005). Brain mechanisms linking language and action. *Nature reviews neuroscience*, 6(7), 576-582.


Alessandro Suglia

ATNLP Week 9 / Lecture 26

School of Informatics

4

原 PPT : Recap: Evidence in favour of Multimodal/Grounded NLP



原 PPT : Main Approaches for Designing VLMs

2. 先抓住核心

这节课怎么入脑

这节课围绕“本讲的核心目标是什么？”：理解 frontier VLM 如何设计、实现和训练，尤其是 visual prefix-based VLM。

考点问法：本讲的核心目标是什么？

人话版：理解 frontier VLM 如何设计、实现和训练，尤其是 visual prefix-based VLM。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 trade off。

考点问法：Visual prefix-based VLM 是什么？

人话版：把视觉编码器输出投影成 LLM 可处理的视觉 prefix tokens，让文本 LLM 在视觉上下文条件下生成语言。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Visual prefix 架构包含哪些主要组件？

人话版：pretrained vision encoder、projector、text-only LLM backbone，以及 image-text training data。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。


考点问法：为什么 visual prefix 架构流行？

人话版：它复用强大的 pretrained LLM 和 vision encoder，只需学习模态对齐和任务适配，工程上简单高效。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

考点问法：Visual prefix 中 language expert 是什么？

人话版：预训练语言模型，用作生成和推理 backbone。精确作答时，先给定义，再解释为什么重要，最后补一个限制或 tradeoff。

3. Visual Encoder



原 PPT : Training pipeline

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“Visual encoder 通常是什么？”。考试版答案可以先说：预训练 Vision Transformer 或视觉-语言 contrastive encoder。进一步看，例如 reconstruction loss，让模型重构被遮蔽或压缩的视觉信息。

- 考点问法：Visual encoder 通常是什么？。答题抓手：预训练 Vision Transformer 或视觉-语言 contrastive encoder。
- 考点问法：Vision-only pretraining 可以用什么目标？。答题抓手：例如 reconstruction loss，让模型重构被遮蔽或压缩的视觉信息。
- 考点问法：Vision+Language pretraining 可以用什么目标？。答题抓手：contrastive loss，用 image-caption pairs 拉近匹配图文表示、推远不匹配表示。

4. Projector 与训练目标




原 PPT : Deep-dive into visual prefix-based VLMs

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“Projector 为什么必要？”。考试版答案可以先说：视觉 encoder 输出维度通常不同于 LLM hidden size，需要映射到 LLM 可接收的空间。进一步看，可用 feedforward neural network、cross-attention with learnable queries 等方法。

- 考点问法：Projector 为什么必要？。答题抓手：视觉 encoder 输出维度通常不同于 LLM hidden size，需要映射到 LLM 可接收的空间。
- 考点问法：Projector 可以如何实现？。答题抓手：可用 feedforward neural network、cross-attention with learnable queries 等方法。
- 考点问法：Projector 输出的 tokens 在 LLM 中扮演什么角色？。答题抓手：它们作为视觉 prefix tokens，提供图像上下文。

5. SmolVLM 架构



原 PPT : Visual prefix-based VLMs – The intuition

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“为什么讲义关注 SmolVLM？” 。考试版答案可以先说：它是 open source/open weight VLM，便于复现、研究和面向资源受限场景部署。进一步看，闭源模型难以复现和分析，不利于科研比较、进步和下游适配。

- 考点问法：为什么讲义关注 SmolVLM？。答题抓手：它是 open source/open weight VLM，便于复现、研究和面向资源受限场景部署。
- 考点问法：“Closed AI Models Make Bad Baselines” 的含义是什么？。答题抓手：闭源模型难以复现和分析，不利于科研比较、进步和下游适配。
- 考点问法：SmolVLM 的 backbone 思路是什么？。答题抓手：用 SigLIP 作为视觉 encoder，用 SmolLM2 作为语言 backbone，并通过 projector 接入视觉 tokens。

6. SmolVLM 训练阶段

Visual prefix-based VLMs – The intuition

- Assume that you have access to two modality experts:
 - The language model
 - The vision encoder (Transformer)
- Use the pre-trained architecture
- Design a projector representation they are compatible
- Train the language model to generate tokens via cross-entropy loss
 - The same loss we use for training text-only LLMs

This is the model design adopted by most model providers!

Why prefix?

prefix

vision Model

brown horse

Alessandro Suglia ATNLP Week 9/ Lecture 26 informatics 9


原 PPT : Visual prefix-based VLMs – The intuition

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“SmolVLM 训练分为哪三个阶段？”。考试版答案可以先说：adaptation stage、image stage、video stage。进一步看，训练 projector 使视觉表示能适配语言模型 backbone。

- 考点问法：SmolVLM 训练分为哪三个阶段？。答题抓手：adaptation stage、image stage、video stage。
- 考点问法：Adaptation stage 的目标是什么？。答题抓手：训练 projector 使视觉表示能适配语言模型 backbone。
- 考点问法：Adaptation stage 中通常如何处理 LLM？。答题抓手：保持 language model frozen，重点学习 projector，并可能对 vision encoder 使用 LoRA。

7. Evaluation 与结果



原 PPT : The visual encoder

人话直觉

评测像给模型体检：题目本身如果只服务高资源语言或单一文化，体检报告就会看起来漂亮但漏掉真正的病灶。这部分的核心问题是“SmoIVLM 使用什么工具做大规模评测？”。考试版答案可以先说：VLMEvalKit。进一步看，在较小显存占用下保持较强性能，体现 computational efficiency。

- 考点问法：SmoIVLM 使用什么工具做大规模评测？。答题抓手：VLMEvalKit。
- 考点问法：SmoIVLM 评测强调什么优势？。答题抓手：在较小显存占用下保持较强性能，体现 computational efficiency。
- 考点问法：为什么 language model capacity 会影响视觉任务？。答题抓手：许多视觉任务需要语言推理、OCR 后理解、指令跟随和答案生成，LLM capacity 仍很关键。

8. Future Research

Common Pretrained Visual Contrastive Encoders

- Combines a vision encoder with a language model
- It is trained with image-caption pairs datasets
- The objective is a contrastive loss that forces the model to bring **similar embeddings close** and **dissimilar ones far apart**
- Several SOTA variants:
 - OpenAI CLIP
 - Google SigLIP

Zhai, Xiaohua, et al. "SigLip loss for language image pre-training." Proceedings of the IEEE/CVF International conference on computer vision. 2023.
Radford, Alec, et al. "Learning transferable visual models from natural language supervision." International conference on machine learning. Pmlr, 2021.

Alessandro Suglia informatics 14

原 PPT : Common Pretrained Visual Contrastive Encoders

人话直觉

建模选择像设计一台多人共用的机器：哪些零件共享、哪些零件单独调，会决定 transfer 是帮忙还是互相打架。这部分的核心问题是“VLM 未来研究方向有哪些？”。考试版答案可以先说：细粒度视觉理解、object-centric representations、多粒度视觉表示、VLM 内部机制、多模态真实世界系统。进一步看，模型是否真正融合视觉和语言，还是主要依赖语言模型，只把视觉当弱提示。

- 考点问法：VLM 未来研究方向有哪些？。答题抓手：细粒度视觉理解、object-centric representations、多粒度视觉表示、VLM 内部机制、多模态真实世界系统。
- 考点问法：“Is it really a VLM or language with some vision?” 想问什么？。答题抓手：模型是否真正融合视觉和语言，还是主要依赖语言模型，只把视觉当弱提示。
- 考点问法：为什么 mechanistic interpretability 对 VLM 重要？。答题抓手：能帮助理解两个模态如何表示、融合，以及训练后内部 representations 如何变化。

- 本讲的核心目标是什么？：理解 frontier VLM 如何设计、实现和训练，尤其是 visual prefix-based VLM。
- Visual prefix-based VLM 是什么？：把视觉编码器输出投影成 LLM 可处理的视觉 prefix tokens，让文本 LLM 在视觉上下文条件下生成语言。
- Visual prefix 架构包含哪些主要组件？：pretrained vision encoder、projector、text-only LLM backbone，以及 image-text training data。
- 为什么 visual prefix 架构流行？：它复用强大的 pretrained LLM 和 vision encoder，只需学习模态对齐和任务适配，工程上简单高效。
- Visual prefix 中 language expert 是什么？：预训练语言模型，用作生成和推理 backbone。
- Visual prefix 中 vision expert 是什么？：预训练视觉模型，通常是 Vision Transformer 或视觉-语言 contrastive encoder。
- Projector 的作用是什么？：把 vision encoder 的视觉 tokens 映射到 LLM hidden size 和表示空间，使 LLM 能处理它们。
- Visual prefix VLM 通常用什么 loss 训练？：next-token prediction 的 cross-entropy loss，与文本 LLM 类似。
- Visual encoder 通常是什么？：预训练 Vision Transformer 或视觉-语言 contrastive encoder。
- Vision-only pretraining 可以用什么目标？：例如 reconstruction loss，让模型重构被遮蔽或压缩的视觉信息。

一段稳妥考场回答

本讲的核心目标是什么？：理解 frontier VLM 如何设计、实现和训练，尤其是 visual prefix-based VLM。Visual prefix-based VLM 是什么？：把视觉编码器输出投影成 LLM 可处理的视觉 prefix tokens，让文本 LLM 在视觉上下文条件下生成语言。Visual prefix 架构包含哪些主要组件？：pretrained vision encoder、projector、text-only LLM backbone，以及 image-text training data。为什么 visual prefix 架构流行？：它复用强大的 pretrained LLM 和 vision encoder，只需学习模态对齐和任务适配，工程上简单高效。